



Thèse universitaire présentée à l'Université Paris Dauphine dans
le cadre de l'obtention du diplôme de **Master 2 MIAGE**

Modélisation du temps de travail des équipes Back Office de BNP Paribas

David ROUFÉ

Entreprise: BNP PARIBAS

Tutrice d'alternance : NEGRE Elsa

Tuteur en entreprise : RAHMANI Abdelaziz

Septembre, 2026

Table des matières

Thanks	v
1 Introduction	1
2 Contexte	6
2.1 Contexte organisationnel	6
2.1.1 Organisation du département GCO (Global Credit Operations)	6
2.1.2 Organisation de l'équipe Strategic Transformation & Data Analytics	7
2.1.3 Organisation générale de la banque	8
2.2 Typologie des événements opérationnels	9
2.3 Définition du concept de charge de travail	13
3 État de l'art	17
3.1 Du coût des activités au coût par événement : ABC et TDABC	18
3.1.1 Le principe de l'Activity-Based Costing	18
3.1.2 Le Time-Driven ABC : deux paramètres, une équation	19
3.2 Mesurer le temps par événement	20
3.2.1 L'étude des temps (Taylor) : chronométrer et normaliser	20
3.2.2 Le MTM : des temps prédéterminés, mais pour des gestes	22
3.2.3 Le Process Mining : lire le temps dans les traces système	23
3.3 Prédire le coût d'un deal futur : méthodes de modélisation . .	24
3.3.1 La régression linéaire multiple : le modèle de référence	24
3.3.2 Les arbres de décision (CART) : capturer les interactions	25
3.3.3 Random Forest et gradient boosting : agréger pour fiabiliser	26
3.4 Les solutions professionnelles : ce que le marché résout, ce qu'il laisse ouvert	27
3.5 Synthèse : un gap resserré sur l'intrant temps du TDABC . . .	28
4 Formalisation et construction d'une mesure de la charge de travail	29
4.1 Premier arbitrage : l'événement comme unité, contre l'équipe et le deal	29

4.2	Deuxième arbitrage : deux objets, non un — Event Processing et Aftercare	30
4.3	Troisième arbitrage : remplacer le facteur d’allure par la séniorité	31
4.4	Quatrième arbitrage : mesurer un travail dont la mesure menace ceux qui l’exécutent	32
4.5	Cinquième arbitrage : raccorder le temps standard à la volumétrie réelle	34
4.6	Synthèse : une mesure fiable, juste, comparable, acceptable et industrialisable	34
5	Analyse et exploitation de la charge de travail pour l’aide à la décision	35
5.1	Reconstruire le coût rétrospectif d’un deal	35
5.2	Identifier les facteurs explicatifs de la charge	37
5.3	Construire un modèle prédictif du coût	38
5.3.1	Modéliser l’Event Processing : arbres et ensembles	38
5.3.2	Modéliser l’Aftercare : la régression, pour l’interprétabilité	39
5.3.3	Recomposer le coût prédit	39
6	Conclusion	40
	Bibliography	40

Table des figures

1	Chaîne de valeur du crédit syndiqué : organisation verticale et supervision transversale	7
2	Structure hiérarchique de l'équipe (FR = France, PT = Portugal)	8
3	Cycle de vie des événements opérationnels en Loan Servicing. Les flèches pleines représentent le flux nominal ; les flèches en pointillés indiquent les boucles de retour.	10
4	Répartition de la charge entre traitement manuel, partiellement automatisé et entièrement automatisé (RPA), par famille d'événements ; estimation issue d'entretiens avec les équipes Loan Servicing de GCO. Les modifications contractuelles restent quasi exclusivement manuelles.	13
5	Chaîne de mesure, de la charge unitaire au coût du deal. La charge unitaire T_s agrège le <i>booking</i> Loan IQ (stable, ~ 20 min) et l' <i>aftercare</i> (variable selon la complexité). Multipliée par le volume d'événements N de la période, elle donne la charge totale W_N ; valorisée au coût horaire chargé w_s , différencié par site, elle donne le coût opérationnel du deal. Seul le volume N porte la variabilité saisonnière ; la charge unitaire reste stable.	16
6	Protocole de l'étude des temps (Taylor, 1911). Les étapes 2 et 3 — observation directe et jugement d'allure — sont celles qui résistent le moins à un back office distribué.	22

Liste des tableaux

1	Cycle de vie opérationnel d'un crédit syndiqué	9
2	Synthèse des familles d'événements opérationnels en Loan Servicing	11

Remerciements

Je remercie ...

1 Introduction

Contexte général

Le secteur bancaire traverse depuis deux décennies une transformation profonde de ses fonctions opérationnelles. La pression réglementaire croissante (Bâle III), l'intensification concurrentielle et l'accélération des capacités de l'intelligence artificielle ont conduit les banques de financement et d'investissement (BFI) à repenser l'organisation de leurs activités de Back Office. Cette transformation répond à un impératif économique central : réduire le *cost to serve*, c'est-à-dire le coût unitaire de traitement des processus opérationnels. Chez BNP Paribas, cet impératif a été formalisé à travers des plans stratégiques successifs. Le plan *GTS2025* (*Growth, Technology, Sustainability*), lancé en 2022, a placé la technologie et l'industrialisation au cœur du modèle opérationnel, avec un objectif explicite de génération de *hard savings* — le Groupe visant alors 2,7 milliards d'euros d'économies à horizon 2025. Au sein de CIB, cette ambition s'est déclinée à travers le programme *GB Indus* (*Global Banking Modernisation & Industrialisation*), visant à industrialiser les processus opérationnels d'un métier présent dans une cinquantaine de pays. La trajectoire se prolonge et se mesure à l'aune du *coefficient d'exploitation* — le rapport entre les charges d'exploitation et le produit net bancaire (PNB), qui exprime la part des revenus absorbée par les coûts de fonctionnement : plus il est bas, plus la banque est efficiente. Lors de la publication des résultats du deuxième trimestre 2026, le Groupe a fixé l'objectif d'un coefficient d'exploitation inférieur à 56 % d'ici 2028 — avec une amélioration d'environ deux points par an à partir de 2027, portée par un programme structurel de réduction des coûts, une simplification de l'organisation et une intensification de l'usage de l'intelligence artificielle — et vise à terme un ratio proche de 50 %. Depuis 2020, cette dynamique s'est encore accélérée sous l'effet de forces convergentes qui redessinent le paysage des opérations bancaires.

La première est la généralisation du *nearshoring* et de l'*offshoring* des fonctions opérationnelles. Confrontées à une pression constante sur les coûts, les BFI ont massivement délocalisé une partie de leurs activités de traitement vers des centres de services partagés situés à Lisbonne, Varsovie, Mumbai ou Montréal — des localisations où les coûts salariaux et immobiliers demeurent inférieurs de 30 à 50 % aux *benchmarks* des places de Londres

ou Paris. Ce mouvement a fragmenté les chaînes de traitement, multiplié les fuseaux horaires et les *handovers* (passations) entre équipes, et complexifié considérablement le pilotage de la charge de travail. Là où un manager supervisait autrefois une équipe co-localisée de dix opérateurs, il doit désormais coordonner des ressources réparties sur plusieurs sites, avec des niveaux de compétence, d'ancienneté et de productivité hétérogènes.

La deuxième force est l'irruption de l'intelligence artificielle et de l'automatisation dans les processus opérationnels. Le déploiement de solutions de *Robotic Process Automation* (RPA) a permis d'automatiser les tâches les plus répétitives — extractions de données, contrôles de cohérence, alimentation de systèmes. Plus récemment, l'émergence de l'IA générative ouvre des perspectives de transformation plus profondes : rédaction automatisée de *facility letters*, extraction intelligente de clauses contractuelles, assistance à la prise de décision sur les cas complexes ou encore bases de données RAG subsistant les experts métier... Ces technologies ne suppriment pas la charge de travail humaine ; elles en modifient la nature. Les tâches routinières se réduisent, tandis que le travail résiduel se concentre sur les opérations à forte valeur ajoutée — précisément celles qui sont les plus complexes, les plus variables et les plus difficiles à mesurer. Ce mouvement est massif : à l'échelle du secteur, près de 83 % des acteurs des services financiers devraient avoir adopté des technologies d'intelligence artificielle dans les cinq ans.

C'est dans cet environnement en mutation rapide que se positionne notre recherche. Au sein des fonctions transversales comme le Back Office, la question de la valeur produite se pose en des termes fondamentalement différents de ceux du Front Office : là où les équipes commerciales mesurent directement les revenus qu'elles génèrent — le *gain* d'un deal leur est connu —, les équipes opérationnelles ne disposent pas de cette visibilité sur ce qu'elles apportent. En revanche, elles savent qu'elles représentent un coût, généré majoritairement par les ressources humaines qui les composent ; mais ce coût lui-même reste largement inconnu à l'échelle d'un deal, faute d'instrument pour le mesurer. C'est cette lacune que notre recherche entend combler. En reconstruisant le coût opérationnel d'un contrat de crédit à partir de la charge de travail qu'il impose aux équipes *Loan Servicing*, on rend enfin ce coût comparable au gain connu du Front Office — ouvrant la voie à une mesure de la rentabilité réelle du deal. La charge de travail n'est donc pas ici l'objet final, mais le levier : la grandeur intermédiaire qu'il faut savoir mesurer pour accéder au coût, puis à la rentabilité.

Les équipes de *Loan Servicing* occupent une position centrale dans cette

logique : elles assurent le traitement opérationnel de l'ensemble des événements survenant durant la vie d'un contrat de crédit, depuis le tirage initial (*drawdown*) jusqu'au remboursement final, en passant par les amendements contractuels, les ajustements de taux et les opérations de restructuration. Ces équipes opèrent sous une double contrainte : les exigences de qualité et de conformité imposent un traitement rigoureux dans le respect de délais contractuels stricts, tandis que la volumétrie et la complexité des opérations varient considérablement sous l'effet de cycles commerciaux, de saisonnalités financières et de chocs exogènes. Cette tension entre exigence de qualité constante et variabilité de la charge, dans un contexte où chaque poste représente un coût visible et soumis à des objectifs de réduction planifiés, constitue le défi managérial que ce mémoire se propose d'adresser.

Contexte organisationnel

Ce travail de recherche s'inscrit dans le cadre d'une mission réalisée au sein du département *Global Credit Operations* (GCO) de BNP PARIBAS. Le département GCO gère l'ensemble des opérations de crédit à destination d'États, d'institutions financières et de contreparties corporates. Dans la chaîne de traitement d'un deal, plusieurs équipes interviennent successivement : le Front Office lors de la signature et de l'origination, le Middle Office pour les informations réglementaires et contractuelles, et les équipes Back Office — plus précisément les équipes *Loan Servicing* (LS) — qui assurent le traitement des informations dans le progiciel Loan IQ.

L'organisation de GCO illustre les tendances sectorielles décrites ci-dessus. Certaines activités de traitement ont été délocalisées, les premières briques d'automatisation (macros VBA, RPA) ont été déployées, et l'équipe *Strategic Transformation & Data Analytics* — à laquelle nous sommes rattachés — porte les projets de transformation digitale et d'exploitation des données. Parmi ces projets, la création d'interfaces automatisées (*Power of Attorney, facility letters*), le développement de KPI à destination du *high management*, et surtout la conception d'une mesure fiable de la charge de travail des équipes Back Office.

La charge de travail est ici appréhendée comme un objet complexe, résultant de la diversité des événements opérationnels, de leur fréquence, de leur variabilité et de leurs contraintes. Elle ne peut être observée directement sans un travail préalable de formalisation et d'instrumentation — travail d'autant plus nécessaire que l'automatisation croissante modifie en continu

le périmètre du travail humain.

Problématique et enjeux

L'enjeu opérationnel est considérable. En l'absence d'une mesure robuste de la charge de travail, le pilotage de l'activité repose sur des estimations empiriques et sur l'expérience des managers — une approche qui atteint ses limites face à la complexité croissante des opérations, à la dispersion géographique des équipes et à la transformation des tâches par l'automatisation. Les conséquences d'un pilotage déficient sont multiples : allocation sous-optimale des ressources humaines entre sites *onshore* et *nearshore*, incapacité à anticiper les pics d'activité, augmentation des risques opérationnels (délais de traitement, erreurs, reprises), dégradation des conditions de travail et accélération du *turnover*.

Ce constat conduit à formuler la problématique suivante :

Comment la charge de travail des équipes Back Office peut-elle être formalisée en une mesure quantitative fiable au service de l'aide à la décision organisationnelle ?

Cette question de recherche se décline en trois sous-questions, ordonnées selon une progression logique allant de la mesure à la décision :

1. **Mesurer.** Comment construire un protocole de collecte des temps de traitement adapté aux opérations de crédit informatisées, qui tienne compte de la variabilité liée à la complexité des deals, aux conditions opérationnelles et à la répartition géographique des équipes ?
2. **Modéliser.** Quels modèles statistiques et d'apprentissage automatique permettent d'expliquer et de prédire la charge de travail à partir des caractéristiques observables des opérations ?
3. **Décider.** Comment traduire cette mesure prédictive en outil d'aide à la décision pour l'allocation des ressources entre sites et l'anticipation des pics d'activité ?

Démarche méthodologique

Pour répondre à cette problématique, nous adoptons une démarche de *design science* (Hevner *et al.*, 2004), dont l'objectif est la construction et l'évaluation d'un artefact — ici, un modèle de mesure et de prédiction de la

charge de travail — dans un contexte organisationnel réel. Cette démarche se déploie en quatre phases :

Phase 1 — Compréhension du processus. Nous procédons à une analyse approfondie de l’organisation des opérations de crédit et du rôle des équipes Loan Servicing, en identifiant la typologie des événements opérationnels et les facteurs de complexité qui les caractérisent.

Phase 2 — Revue de littérature. Nous recensons les approches existantes de mesure et de modélisation de la charge de travail, en mobilisant quatre champs disciplinaires : le génie industriel (études de temps, MTM), l’ergonomie cognitive (NASA-TLX), la science des données (régression, apprentissage automatique, Process Mining) et la Recherche Opérationnelle (théorie des files d’attente, optimisation).

Phase 3 — Formalisation et construction de la mesure. Nous définissons un protocole de collecte des temps de traitement (*clocking*), concevons la base de données des mesures et établissons les conditions de mesurabilité des opérations.

Phase 4 — Analyse et exploitation. Nous identifions les facteurs explicatifs de la charge de travail par des méthodes statistiques et d’apprentissage automatique, construisons un modèle prédictif et en dérivons des recommandations pour le pilotage opérationnel : allocation des ressources, anticipation des pics et prévision de la charge.

Annnonce du plan

Ce mémoire s’organise en cinq chapitres. Le **chapitre 1** présente le contexte organisationnel des opérations de crédit et caractérise l’objet d’étude — la charge de travail des équipes Loan Servicing dans un environnement marqué par le nearshoring et l’automatisation. Le **chapitre 2** propose un état de l’art des méthodes de mesure et de modélisation de la charge de travail, et identifie le *gap* que ce mémoire vise à combler. Le **chapitre 3** détaille la méthodologie de formalisation et de construction de la mesure, du protocole de collecte à la structuration de la base de données. Le **chapitre 4** expose l’analyse des données collectées, la construction du modèle prédictif et les apports pour le pilotage opérationnel. Enfin, le **chapitre 5** discute les limites de la démarche, les conditions de généralisation des résultats et les perspectives d’évolution — notamment l’intégration de l’IA générative comme levier de transformation de la charge de travail.

2 Contexte

2.1 Contexte organisationnel

2.1.1 Organisation du département GCO (Global Credit Operations)

Le département **Global Credit Operations** (GCO) de BNP Paribas structure ses activités autour de pôles complémentaires, chacun jouant un rôle clé dans la chaîne de traitement des opérations de crédit syndiqué. Le *crédit syndiqué* est un crédit accordé à une entreprise par un groupe de banques agissant conjointement, permettant de répartir le risque de financement tout en mobilisant des montants élevés [?].

- **Équipes transversales** : elles jouent un rôle de *surplomb*, en veillant à la cohérence et à la performance de l'ensemble de la chaîne opérationnelle. Elles pilotent les initiatives de transformation stratégique (automatisation des processus, intégration d'outils d'intelligence artificielle, déploiement de KPI de suivi), garantissent la conformité réglementaire, et produisent des analyses destinées au top management. Leur rôle est d'assurer la gouvernance et la standardisation des pratiques au niveau global.
- **Front Office (Origination & Syndication)** : il constitue le point d'entrée commercial et relationnel avec les clients. Le Front Office identifie les besoins de financement, conçoit la structure du crédit, négocie les conditions avec l'emprunteur et organise la syndication, c'est-à-dire la répartition du financement entre les différentes banques participantes. Il est à la fois force de proposition stratégique et interface principale avec le marché.
- **Middle Office (Credit Transaction Management)** : il agit comme *pivot de contrôle et de sécurisation*. Ses missions consistent à vérifier la bonne mise en place des conditions négociées (clauses contractuelles, covenants, pricing), à évaluer les risques associés à la transaction, à s'assurer de la qualité des données saisies dans les systèmes et à gérer les exceptions opérationnelles. Le Middle Office se situe entre la relation commerciale (FO) et l'exécution opérationnelle (BO), garantissant l'intégrité et la conformité des transactions.
- **Back Office (Loan Servicing Team)** : il représente le *cœur opérationnel* du dispositif. Responsable de l'exécution quotidienne, il prend

en charge le cycle de vie complet des crédits : décaissements (draw-downs), appels de fonds, paiements d'intérêts et de commissions, remboursements, gestion des échéances, ainsi que la clôture finale du prêt. Il assure également la maintenance des systèmes de gestion (tels que Loan IQ) et la production de reportings réglementaires et financiers.




FIGURE 1 – Chaîne de valeur du crédit syndiqué : organisation verticale et supervision transversale

2.1.2 Organisation de l'équipe Strategic Transformation & Data Analytics

L'équipe Strategic Transformation est composée de chefs de projet chargés de piloter la modernisation des opérations de crédit (automatisation, pilotage du changement stratégique).

L'équipe Data Analytics est référente sur la donnée : qualité, nettoyage, analyses statistiques ainsi que création de KPI en destination du high management.




FIGURE 2 – Structure hiérarchique de l’équipe (FR = France, PT = Portugal)

2.1.3 Organisation générale de la banque

Le secteur bancaire se divise en trois grandes catégories d’établissements :

- **Banque de détail** : services courants et prêts pour particuliers et PME.
- **Banque privée** : gestion de patrimoine pour une clientèle fortunée.
- **Banque de financement et d’investissement (CIB)** : financement structuré, marchés de capitaux, couverture des risques.

Ce mémoire se concentre sur la **CIB**, et plus précisément le *crédit syndiqué*, dont le cycle de vie opérationnel est schématisé ci-dessous :

Étape	Front Office	Middle Office	Back Office
Origination	Analyse du besoin, structuration	–	–
Structuration	Négociation, syndication	Évaluation des risques	–
Documentation	Coordination juridique	Vérification des clauses	Préparation contrats
Mise en place	Information client	Contrôle final des risques	Versements, confirmations
Vie du deal	Suivi relationnel	Monitoring des covenants	Reporting, échéances

TABLE 1 – Cycle de vie opérationnel d’un crédit syndiqué

2.2 Typologie des événements opérationnels

Le cycle de vie d’un crédit syndiqué génère un ensemble d’événements opérationnels dont le traitement incombe aux équipes Loan Servicing. Chaque événement correspond à une unité de travail discrète, déclenchée par une instruction du Front Office ou du Middle Office, et exécutée dans le progiciel Loan IQ selon des procédures standardisées. La diversité de ces événements — par leur nature, leur fréquence et leur complexité — constitue le premier déterminant structurel de la charge de travail.

On distingue cinq grandes familles d’événements, ordonnées selon la chronologie du cycle de vie du crédit.

Événements de mise en place (*setup*). Ils interviennent lors de l’entrée d’un nouveau deal dans le système. Le *deal setup* comprend la création de la facilité dans Loan IQ, le paramétrage des conditions contractuelles (devise, taux de référence, spreads, calendrier de remboursement, frais) et la vérification de cohérence avec la documentation juridique. Cette étape est à la fois volumineuse en saisie et exigeante en attention, car toute erreur de paramétrage se propage à l’ensemble des opérations ultérieures.

Événements de décaissement et de remboursement. Les tirages (*drawdowns*) et les remboursements (*repayments*) constituent le flux le plus récurrent du Loan Servicing. Un tirage correspond à la mise à disposition




FIGURE 3 – Cycle de vie des événements opérationnels en Loan Servicing. Les flèches pleines représentent le flux nominal ; les flèches en pointillés indiquent les boucles de retour.

effective des fonds au profit de l'emprunteur ; un remboursement, au retour partiel ou total du principal selon l'échéancier contractuel ou par anticipation. La complexité de ces opérations varie considérablement : un tirage en devise unique sur une facilité bilatérale est une opération routinière, là où un tirage sur une tranche syndiquée multidevise implique la coordination de plusieurs participants, le calcul de quotes-parts et la gestion de fuseaux horaires différents.

Événements de vie courante (*servicing*). Ils regroupent l'ensemble des opérations récurrentes liées à la gestion d'un crédit actif : paiements d'intérêts (*interest payments*), appels et paiements de commissions (*commitment fees*, *agency fees*), *rollovers* (renouvellement d'une période d'intérêt), fixings de taux et ajustements de spread. Ces événements, bien que souvent unitairement simples, représentent le volume le plus important en nombre d'occurrences quotidiennes. Leur charge est essentiellement liée à leur fréquence et à leur concentration calendaire — les fins de mois et fins de trimestre (*quarter-ends*) produisent des pics de volume considérables.

Événements de modification contractuelle. Les amendements (*amendments*), les *waivers* (renonciations temporaires à une clause) et les restructurations modifient les termes initiaux du contrat de crédit. Ces opé-

rations sont les plus complexes du portefeuille : elles nécessitent l'interprétation de clauses juridiques, la mise à jour simultanée de multiples paramètres dans le système et, fréquemment, des itérations avec le Middle Office et le département juridique. Le temps de traitement d'un amendement peut être dix à vingt fois supérieur à celui d'un tirage standard, ce qui rend sa contribution à la charge globale disproportionnée par rapport à sa fréquence.

Événements de clôture. Le remboursement final (*final repayment*) et la clôture du deal (*deal closure*) mettent fin au cycle de vie opérationnel. Ces événements impliquent le solde de l'ensemble des positions, la vérification de l'absence d'encours résiduel, la production de confirmations finales et l'archivage dans le système. Bien que ponctuels, ils requièrent un contrôle exhaustif qui les rend chronophages.

TABLE 2 – Synthèse des familles d'événements opérationnels en Loan Servicing

Famille	Événements types	Fréquence	Complexité	Automatisable
Mise en place	Deal setup, paramétrage facilité	Faible	Élevée	Partiel
Décaissement / Remboursement	Drawdowns, repayments, remb. anticipés	Élevée	Variable	Partiel
Vie courante	Intérêts, commissions, rollovers, fixings	Très élevée	Faible à modérée	Oui
Modifications	Amendements, waivers, restructurations	Faible	Très élevée	Non
Clôture	Final repayment, deal closure	Ponctuelle	Modérée	Partiel
Transversaux	Reprises, corrections, reporting ad hoc	Variable	Variable	Non

À ces cinq familles s'ajoutent des **événements transversaux** qui ne relèvent pas d'une étape spécifique du cycle de vie mais constituent une source significative de charge : les reprises et corrections (*rework*) consécutives à des erreurs de saisie ou à des données amont incomplètes, les demandes *ad hoc* de reporting, et les réconciliations de données entre systèmes. Ces événements sont particulièrement difficiles à anticiper et à standardiser, car ils résultent de dysfonctionnements plutôt que d'un processus nominal.

Les deux composantes de la charge : booking LIQ et aftercare. La charge d'un événement ne se réduit pas à sa saisie dans le progiciel Loan IQ. L'observation directe des équipes fait apparaître deux composantes distinctes, dont la mesure séparée est indispensable à une estimation fiable du coût. La première est le *booking LIQ* : le temps de traitement de l'événement dans le système — création de la transaction, paramétrage, saisie, validation. Ce temps est relativement stable d'un événement à l'autre, de l'ordre d'une vingtaine de minutes en moyenne, et varie peu selon le type d'opération. La seconde est l'*aftercare* : l'ensemble des tâches de post-traitement qui gravitent autour de l'événement sans être exécutées dans Loan IQ — contrôles de cohérence, réconciliations entre systèmes, contrôles de *closing*, audits, gestion des exceptions et interactions avec le Middle Office. Contrairement au booking, l'*aftercare* est fortement variable : il dépend du rôle de la banque (Agent, Participant, Bilatéral), de la complexité du deal et de la période. C'est cette composante, largement invisible dans les systèmes d'information, qui explique l'essentiel de la variabilité de la charge — et donc du coût — entre deals comparables en volume. Cette distinction est décisive : le temps de *booking*, seul enregistré dans Loan IQ, ne suffit pas à mesurer la charge réelle. Toute mesure fiable doit capturer les deux composantes, ce que le protocole de collecte présenté au chapitre ?? s'attache à faire.

L'automatisation modifie le périmètre de cette typologie. Les solutions de RPA déployées au sein de GCO ont permis d'automatiser partiellement certaines opérations à faible valeur ajoutée — extraction de données, pré-remplissage de champs dans Loan IQ, génération de confirmations standardisées. Ces tâches, qui figuraient autrefois dans la charge des opérateurs, sortent progressivement du périmètre du travail humain. En contrepartie, le travail résiduel se concentre sur les événements complexes, les cas d'exception et les contrôles qualitatifs — précisément les opérations dont le temps de traitement est le plus variable et le plus difficile à modéliser. Toute mesure de la




FIGURE 4 – Répartition de la charge entre traitement manuel, partiellement automatisé et entièrement automatisé (RPA), par famille d'événements ; estimation issue d'entretiens avec les équipes Loan Servicing de GCO. Les modifications contractuelles restent quasi exclusivement manuelles.

charge doit donc intégrer cette distinction entre événements automatisés, partiellement automatisés et manuels, sous peine de surestimer ou sous-estimer la charge réelle supportée par les équipes.

2.3 Définition du concept de charge de travail

Avant d'en donner une définition, il importe de rappeler pourquoi cette mesure est construite. La charge de travail n'est pas ici étudiée pour elle-même : elle constitue la grandeur intermédiaire qui permet de reconstruire le *coût opérationnel* d'un contrat de crédit, puis — rapporté au gain connu du Front Office — sa *rentabilité réelle*. Mesurer la charge, c'est mesurer la brique élémentaire du coût.

La charge de travail est un concept en apparence intuitif — chaque manager sait reconnaître une équipe « débordée » — mais dont la formalisation exige de lever une ambiguïté fondamentale : celle entre la charge *unitaire* d'un événement et la charge *totale* supportée par une équipe. Confondre les deux conduit à des raisonnements erronés ; les distinguer est la clé du modèle.

La charge de travail d'un événement opérationnel est le temps

de traitement effectif requis pour l'exécuter dans le respect des standards de qualité. Elle se compose de deux temps distincts : le booking dans Loan IQ (saisie et exécution de l'opération) et l'aftercare (contrôles, réconciliations et post-traitement consécutifs à l'opération). La charge totale supportée par une équipe sur une période donnée est la somme des charges unitaires des événements traités sur cette période : elle croît avec le volume d'événements, à charge unitaire constante.

Cette définition appelle deux précisions, articulées autour de la distinction unitaire / total.

La charge unitaire. Chaque événement opérationnel consomme une durée de travail qui dépend de sa nature (tirage, amendement, clôture), de ses caractéristiques intrinsèques (devise, syndication, clauses spécifiques) et des conditions d'exécution. Cette charge unitaire est **indépendante du volume** : un tirage standard requiert le même temps de traitement un jour creux ou en période de pic. Elle se décompose en deux temps complémentaires :

- le *booking* dans Loan IQ ($T_{LIQ,i}$) : la saisie et l'exécution de l'opération dans le progiciel, dont la durée moyenne observée est remarquablement stable, de l'ordre de vingt minutes quel que soit le type d'événement ;
- l'*aftercare* ($T_{AC,i}$) : les contrôles, réconciliations et post-traitements qui suivent le *booking*, dont la durée est bien plus variable et dépend fortement de la complexité du deal.

La charge unitaire d'un événement i est donc la somme de ces deux composantes :

$$T_{s,i} = T_{LIQ,i} + T_{AC,i} \quad (1)$$

Le temps brut ne suffit toutefois pas à mesurer chacune de ces composantes : un opérateur peut consacrer trente minutes à un *booking* standard parce qu'il est interrompu, ou l'exécuter en dix minutes sans interruption. Il faut donc, pour chaque composante, distinguer le *temps effectif de traitement* — réellement consacré à l'exécution — du *temps écoulé*, qui inclut interruptions et attentes :

$$T_{\text{eff}} = T_{\text{écoulé}} - T_{\text{interruptions}} - T_{\text{attente}} \quad (2)$$

C'est ce temps effectif, chronométré puis standardisé par type d'événement et par composante, que nous agrégeons dans $T_{s,i}$.

La charge totale. La charge supportée par une équipe sur une période $[t_0, t_1]$ est la somme des charges unitaires des événements traités sur cette période :

$$W_{[t_0, t_1]} = \sum_{i=1}^N T_{s,i} \quad (3)$$

où N est le volume d'événements traités. C'est cette charge totale — et elle seule — qui varie avec l'activité : les pics observés en fin de trimestre (*quarter-ends*) résultent de l'augmentation du volume N , non d'une variation de la charge unitaire $T_{s,i}$. Cette distinction est essentielle pour le pilotage : dimensionner une équipe, anticiper un pic ou arbitrer une allocation de ressources relève de la dynamique du **volume** et de la capacité de traitement disponible — questions traitées au chapitre ?? — et non de la mesure de la charge unitaire, qui en constitue seulement le facteur multiplicatif stable.




FIGURE 5 – Chaîne de mesure, de la charge unitaire au coût du deal. La charge unitaire T_s agrège le *booking* Loan IQ (stable, ~ 20 min) et l'*aftercare* (variable selon la complexité). Multipliée par le volume d'événements N de la période, elle donne la charge totale W_N ; valorisée au coût horaire chargé w_s , différencié par site, elle donne le coût opérationnel du deal. Seul le volume N porte la variabilité saisonnière ; la charge unitaire reste stable.

Cette décomposition éclaire un résultat central : le temps de *booking* dans Loan IQ, stable autour de vingt minutes, ne constitue qu'une composante marginale du coût total. Les deux véritables déterminants de la charge — et donc du coût — sont le **volume d'événements** d'un deal et le poids de son

aftercare, ce dernier variant fortement avec la complexité de l’opération. Réduire la charge à son seul temps de saisie conduirait ainsi à sous-estimer massivement le coût réel des deals les plus complexes.

De la charge au coût. Exprimée en unités de temps, la charge totale se convertit directement en coût opérationnel dès lors qu’on lui associe un coût horaire chargé w (salaire, charges et frais de structure), différencié par site pour refléter les écarts *onshore* / *nearshore* :

$$C = \sum_{i=1}^N T_{s,i} \times w_{s(i)} \quad (4)$$

où $w_{s(i)}$ est le coût horaire du site s traitant l’événement i . Rapporté au gain connu du Front Office, ce coût opérationnel ouvre la voie à une mesure de la *rentabilité réelle* du deal — objectif ultime développé au chapitre ?? . La charge de travail apparaît ainsi comme le **levier de mesure** du coût, et non comme une fin en soi.

La portée de cette formulation apparaît à l’échelle du deal : parce que le coût combine un volume d’événements et une charge unitaire elle-même pondérée par la complexité, deux deals peuvent présenter des coûts opérationnels dans un rapport de plusieurs dizaines. L’analyse empirique du chapitre ?? met en évidence une variance allant, sur une même année, de quelques milliers à plusieurs centaines de milliers d’euros par deal — confirmant, à l’échelle du contrat, l’écart de charge déjà observé à l’échelle de l’événement entre un tirage standard et un amendement complexe.

Cette formulation — charge unitaire stable, charge totale portée par le volume, coût obtenu par valorisation — fonde la démarche de ce mémoire : construire une mesure fiable de la charge unitaire par événement, articulant données de chronométrage, caractéristiques objectives des événements et facteurs contextuels, puis la recomposer en coût opérationnel au service du pilotage de la rentabilité.

3 État de l’art

Ce chapitre poursuit un objectif unique, subordonné à la finalité du mémoire : identifier, parmi les approches existantes, celles qui permettent d’établir une mesure fiable de la charge de travail des équipes Loan

Servicing et d'en déduire le coût d'un deal — rétrospectivement, pour un deal traité, et de façon prédictive, pour un deal futur. La charge de travail n'est pas étudiée pour elle-même : elle est la grandeur intermédiaire qui, mesurée puis valorisée, donne accès au coût, puis à la rentabilité. Cet objectif recoupe celui assigné à la mission : « estimer avec précision le coût associé à un nouveau deal » et obtenir « un coût par événement et par deal pour chaque équipe LS ».

Plutôt que de juxtaposer les disciplines, nous les ordonnons le long d'un fil unique — de la mesure du temps au coût — et n'évaluons chaque méthode que par sa contribution à ce fil, selon trois questions : mesure-t-elle le temps par événement ? résiste-t-elle à un back office nearshore, automatisé et hétérogène ? conduit-elle à un coût imputable au deal ? Le périmètre se resserre ainsi sur deux finalités articulées par un socle commun — le temps unitaire par événement : **mesurer** le coût d'un deal traité (§3.1–3.2), et le **prédire** pour un deal futur (§3.3).

3.1 Du coût des activités au coût par événement : ABC et TDABC

3.1.1 Le principe de l'Activity-Based Costing

Toute méthode de coût doit répondre à une question : comment répartir des charges *indirectes* — salaires d'un back office, systèmes, encadrement — sur les objets qui les consomment ? La comptabilité traditionnelle répond par des clés grossières : on répartit au prorata d'un volume ou d'heures de main-d'œuvre. Le défaut est connu : un deal simple à fort volume et un deal complexe à faible volume reçoivent une part de coût sans rapport avec les ressources qu'ils exigent réellement. L'*Activity-Based Costing* (ABC), formalisé par Kaplan et Cooper à la fin des années 1980, corrige ce biais en interposant les **activités** : on trace d'abord le coût des ressources vers les activités qu'elles servent (*resource drivers*), puis le coût des activités vers les objets qui les déclenchent (*activity drivers*) [?]. La littérature distingue à ce titre deux natures d'inducteurs : les *transaction drivers*, qui comptent le nombre de fois qu'une activité survient, et les *duration drivers*, qui mesurent le temps qu'elle consomme — ces derniers étant plus précis lorsque les occurrences d'une même activité n'ont pas toutes la même durée. En banque, l'ABC a montré qu'il révèle des clients ou produits dont le service consomme un back office disproportionné par rapport aux revenus qu'ils génèrent —

exactement notre problème de rentabilité par deal.

Pertinence et limite pour notre contexte. Le principe de l’ABC est directement pertinent : notre « objet » est le deal, nos « activités » sont les événements Loan Servicing, et nous cherchons un *duration driver* — le temps par événement. Mais l’ABC classique a une faiblesse qui le disqualifie en l’état : il estime le temps par activité au moyen d’**enquêtes déclaratives**, où chaque opérateur indique le pourcentage de son temps consacré à chaque tâche. Ces enquêtes sont coûteuses à mener, subjectives, et surtout se périment dès que les processus changent — ce qui, sous déploiement continu de RPA, est notre quotidien. De plus, l’ABC suppose implicitement que la capacité est utilisée à 100 %, et noie donc le coût de la capacité inutilisée dans des taux gonflés. Ces deux défauts — coût de maintenance et cécité à la capacité oisive — sont précisément ceux que la variante suivante corrige.

3.1.2 Le Time-Driven ABC : deux paramètres, une équation

Kaplan et Anderson introduisent en 2004 le *Time-Driven Activity-Based Costing* (TDABC), qui réduit toute la mécanique de l’ABC à **deux paramètres** par groupe de ressources [?]. Le premier est le **taux de coût de capacité** (*capacity cost rate*) : le coût total du groupe (salaires, encadrement, systèmes, locaux) divisé par sa *capacité pratique* — non pas le temps théoriquement disponible, mais celui réellement travaillé, estimé à environ 80–85 % du théorique une fois retranchés pauses, formations et aléas. On obtient un coût par minute. Le second est un ensemble d’**équations de temps** (*time equations*) qui estiment la durée d’une transaction à partir de ses caractéristiques : un temps de base, augmenté d’incrémentes pour chaque facteur qui l’allonge. La forme canonique est :

$$t = \beta_0 + \sum_k \beta_k x_k \quad (5)$$

où β_0 est le temps de base, x_k les caractéristiques de la transaction (par exemple : contrôle manuel requis, expédition à l’export) et β_k le temps additionnel qu’elles imposent. Le coût de l’objet est alors la somme, sur tous ses événements, du temps consommé multiplié par le taux de coût de capacité :

$$C = \sum_{i=1}^N t_i \times c_u \quad (6)$$

Cette équation est, à la notation près, **celle que notre analyse terrain a établie** — $C = (T_{\text{LIQ}} + T_{\text{AC}}) \times N \times w_s$ (chapitre 1). Le TDABC est donc le socle de notre finalité rétrospective. Il présente deux vertus supplémentaires décisives. D’une part, il rend *visible la capacité inutilisée* : comme on a valorisé la capacité *fournie*, la différence entre minutes disponibles et minutes réellement consommées apparaît comme une ligne propre — information cruciale pour dimensionner les équipes FR/PT. D’autre part, l’équation 6 est *nativement prédictive* : connaître les temps unitaires permet de simuler le coût d’un volume ou d’un mix futurs, ce qui fait le pont vers notre seconde finalité.

La limite critique — et c’est notre gap. La littérature postérieure, moins promotionnelle que les textes fondateurs, pointe une faiblesse unique mais décisive : *la précision du TDABC dépend entièrement de la qualité des estimations de temps*, et la méthode s’applique mal au *knowledge work* non routinier, où le temps d’une tâche est un mauvais proxy de la ressource consommée. Le cas le plus proche du nôtre est documenté en santé : Koster *et al.* (2023) montrent que l’hétérogénéité des patients rend les temps par activité non ponctuels mais variables, au point de devoir remplacer les estimations uniques par une logique floue capturant un intervalle du meilleur au pire cas [?]. La transposition est immédiate : nos deals sont à nos équipes ce que les patients multimorbides sont aux soignants — une population hétérogène pour laquelle un temps unitaire figé ne suffit pas. C’est exactement ce que la mission nomme « *wide possibilities of post operation process which make the workload difficult to predict* ». Estimer ce temps unitaire fiable, en environnement hétérogène et automatisé, est le verrou que ce mémoire doit lever — et qui justifie d’examiner les méthodes de mesure du temps.

3.2 Mesurer le temps par événement

3.2.1 L’étude des temps (Taylor) : chronométrer et normaliser

La méthode fondatrice de mesure du travail est l’*étude des temps*, formalisée par Taylor (1911) [?, ?]. Son principe : décomposer une tâche en éléments observables, chronométrer chacun sur plusieurs cycles pour obtenir un *temps observé* T_o , puis le corriger en deux étapes. On applique d’abord un **facteur d’allure** F_a — jugement porté par l’analyste sur le rythme de l’opérateur par rapport à une cadence « normale » (un opérateur rapide se

voit affecter $F_a > 1$) — pour obtenir un *temps normal* $T_n = T_o \times F_a$. On ajoute ensuite des **majorations** A pour les aléas incompressibles (fatigue, pauses, interruptions), d'où le *temps standard* :

$$T_s = T_o \times F_a \times (1 + A) \quad (7)$$

Ben-Gal *et al.* (2010) ont établi que ce principe reste valide dans les services, à condition d'adapter la granularité de décomposition aux tâches informatisées [?].

Pertinence et limites pour notre contexte. Le principe est le bon : il produit exactement le t_i qu'exige le TDABC, et l'idée de décomposer un traitement en événements chronométrables fonde notre *clocking*. Mais le *protocole* tayloriste échoue sur trois points précis dans un back office nearshore. *Premièrement*, le facteur d'allure F_a repose sur l'observation directe d'un analyste : dans des équipes réparties entre Paris et Lisbonne, cette observation est rarement praticable, et l'auto-déclaration réintroduit un biais de désirabilité sociale. *Deuxièmement*, l'étude des temps suppose une « méthode standard » stabilisée ; or l'automatisation redéfinit la façon d'exécuter un même événement d'un trimestre à l'autre, rendant tout temps standard rapidement obsolète. *Troisièmement*, elle suppose des tâches nettement délimitées, alors que le travail réel est entrelacé — plusieurs deals menés de front, interrompus par des requêtes *ad hoc* — ce qui brouille la mesure du temps effectif. Conclusion : on garde le principe (chronométrer par événement), on abandonne le protocole (observation + jugement d'allure) au profit d'une mesure ancrée dans les traces système.




FIGURE 6 – Protocole de l’étude des temps (Taylor, 1911). Les étapes 2 et 3 — observation directe et jugement d’allure — sont celles qui résistent le moins à un back office distribué.

3.2.2 Le MTM : des temps prédéterminés, mais pour des gestes

Frank et Lillian Gilbreth déplacent l’attention de la durée vers le *mouvement* : ils décomposent tout geste en unités élémentaires (les *therbligs* — saisir, positionner, relâcher). De là naît le *Methods-Time Measurement* (MTM), formalisé par Maynard *et al.* (1948) [?, ?] : un système de temps *prédéterminés* qui attribue *a priori* une valeur temporelle normalisée à chaque mouvement élémentaire, si bien qu’on peut estimer la durée d’une opération *avant* de l’exécuter, par simple addition, sans chronométrer.

Pertinence et limites pour notre contexte. L’attrait est réel : le MTM promettrait d’estimer t_i sans campagne de mesure. Mais il présuppose que le travail se réduit à des gestes physiques catalogables — vrai à l’atelier, faux au back office. Les « mouvements » d’un opérateur Loan Servicing sont des séquences *cognitives et numériques* : naviguer entre écrans Loan IQ, interpréter une clause, arbitrer entre instructions contradictoires. Leur durée ne dépend pas d’une mécanique gestuelle mais du *contenu informationnel* du deal : un tirage bilatéral en euros et un tirage syndiqué multidevise à vingt participants sollicitent les mêmes écrans pour des durées radicalement diffé-

rentes. Aucune table MTM générique ne capture cette variabilité. Le MTM confirme donc, par son échec, que notre référentiel de temps doit être *reconstitué empiriquement* à partir de données réelles, non dérivé d’un catalogue.

3.2.3 Le Process Mining : lire le temps dans les traces système

Le *Process Mining*, formalisé par van der Aalst (2016), résout le problème par un tout autre angle : au lieu d’observer l’opérateur, il exploite les **logs d’événements** déjà enregistrés par les systèmes d’information [?]. Chaque ligne de log fournit au minimum un triplet (*case_id*, activité, *timestamp*) : l’identifiant du cas (ici, le deal), l’activité réalisée, et l’horodatage. En recomposant ces triplets, le Process Mining *découvre* le processus réellement suivi (et non le processus théorique), mesure les durées entre activités, et met au jour ce que les cartographies déclaratives masquent : boucles de reprise, approbations redondantes, temps d’attente entre étapes. Jans *et al.* (2013) en démontrent la valeur dans une organisation financière pour l’analyse multifacette des processus et la détection d’anomalies [?].

Pertinence et limites pour notre contexte. C’est le candidat le plus solide pour alimenter le t_i du TDABC, car il lève les deux premières failles du chronométrage tayloriste : il ne requiert ni observateur ni jugement d’al-lure (il lit des horodatages objectifs), et il se met à jour automatiquement à mesure que les processus évoluent — répondant directement au problème de l’obsolescence sous automatisation. Mais il souffre d’une limite qui recoupe précisément la nôtre : l’horodatage mesure un **temps écoulé** entre deux transactions, non un **temps effectif** de travail. Entre le *timestamp* d’ouverture et celui de clôture d’un événement dans Loan IQ, l’opérateur a pu être interrompu, traiter un autre deal, ou attendre une validation. Le Process Mining fournit donc une *borne supérieure bruitée* du temps unitaire. D’où l’articulation que retient notre méthodologie, et qui constitue une réponse directe au gap : le Process Mining pour la *couverture exhaustive* de tous les événements, calibré par un *clocking* manuel ciblé qui mesure, sur un échantillon, le rapport entre temps effectif et temps écoulé.

3.3 Prédire le coût d'un deal futur : méthodes de modélisation

Mesurer le coût d'un deal traité résout la première finalité. La seconde — estimer le coût d'un deal *avant* son traitement, à partir de ses seules caractéristiques connues à la signature — prolonge naturellement le TDABC, dont l'équation de temps (5) est déjà une fonction que l'on peut *apprendre* sur l'historique. Là où le TDABC calcule un coût *a posteriori* en observant le volume et l'*aftercare* réellement consommés, un modèle prédictif estime :

$$\hat{C}_{\text{deal}} = f(x_1, \dots, x_p) \quad (8)$$

où f est appris sur les deals passés et où les x_j sont les caractéristiques disponibles dès la signature : nombre de prêteurs, devise, nombre de facilités, rôle (agent, participant, bilatéral), produit. Cette section examine les familles de modèles candidates pour f , de la plus interprétable à la plus performante, en pesant pour chacune le compromis *précision* / *interprétabilité* — compromis central, car un modèle destiné à arbitrer la rentabilité d'un deal devant le Front Office doit être non seulement juste, mais explicable.

3.3.1 La régression linéaire multiple : le modèle de référence

Le modèle le plus simple postule que le coût (ou le temps) est une combinaison linéaire des caractéristiques :

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \varepsilon \quad (9)$$

où Y est la variable à prédire, les β_j des coefficients estimés par moindres carrés, et ε un terme d'erreur. Sa force est l'**interprétabilité par conception** : chaque coefficient β_j se lit directement comme la contribution marginale d'un facteur — « un prêteur supplémentaire ajoute β minutes de traitement ». C'est un argument de poids pour la communication managériale, et cela répond directement au sous-objectif de la mission : « *understand the impact of each parameter of the LS workload* ».

Hypothèses et pourquoi elles se brisent ici. Cette lisibilité repose sur des hypothèses que notre contexte viole. La régression suppose la **linéarité** (l'effet d'un facteur est constant, quel que soit son niveau) et surtout l'**additivité** (l'effet total est la somme des effets individuels). Or nos données

terrain montrent des **interactions** : un deal *à la fois* syndiqué, multidevise et à clauses spéciales génère une charge supérieure à la somme des trois effets pris isolément — la complexité se *multiplie*, elle ne s’additionne pas. La régression sous-estimerait donc systématiquement les deals les plus complexes, précisément ceux dont le coût importe le plus. On peut ajouter manuellement des termes d’interaction ($x_1 \times x_2$), mais leur nombre explose et leur choix devient arbitraire. La régression reste donc un *étalon* de référence et un outil de communication, mais insuffisante comme modèle final.

3.3.2 Les arbres de décision (CART) : capturer les interactions

L’arbre de décision de type CART (*Classification and Regression Trees*) adopte une logique inverse : au lieu de poser une équation globale, il **partitionne récursivement** l’espace des caractéristiques. À chaque nœud, l’algorithme cherche la question binaire (par exemple « nombre de prêteurs > 50 ? ») qui sépare le mieux les données, puis recommence sur chaque sous-groupe, jusqu’à des feuilles où la prédiction est la moyenne des cas qu’y tombent. Pour une cible continue comme le temps, le « meilleur » découpage est celui qui **minimise la variance** intra-groupe — on cherche le seuil qui rend les deux sous-groupes les plus homogènes possible. La réduction de variance obtenue par un découpage s’écrit :

$$\Delta = \text{Var}(S) - \frac{|S_L|}{|S|} \text{Var}(S_L) - \frac{|S_R|}{|S|} \text{Var}(S_R) \quad (10)$$

où S est le groupe parent, S_L et S_R les deux sous-groupes issus du découpage, et $|\cdot|$ leur effectif. L’algorithme retient, à chaque nœud, le découpage qui maximise Δ .

Pertinence et limites. L’arbre a deux vertus majeures pour nous. Il capture **nativement les interactions** : en enchaînant « si rôle = agent *puis* si multidevise = oui », il modélise exactement l’effet multiplicatif que la régression manque, sans qu’on ait à le spécifier. Et il est **lisible** : un chemin de la racine à une feuille se lit comme une règle métier explicite. Mais un arbre unique souffre de deux défauts. Il est **instable** (une variation minime des données change toute sa structure — *high variance*), et il ne sait pas **extrapoler** : entraîné sur des deals de 2 à 1000 prêteurs, il plafonnera sa prédiction pour un deal à 1500 prêteurs à la valeur de sa feuille la plus haute. Seul, il sur-apprend et généralise mal : il faut l’agréger.

3.3.3 Random Forest et gradient boosting : agréger pour fiabiliser

Deux stratégies d'agrégation d'arbres dominent la pratique sur données tabulaires comme les nôtres. Le **Random Forest** entraîne des centaines d'arbres *en parallèle*, chacun sur un échantillon aléatoire des données et des variables, puis *moyenne* leurs prédictions :

$$\hat{f}(x) = \frac{1}{B} \sum_{b=1}^B T_b(x) \quad (11)$$

où T_b est le b -ième arbre. En moyennant des arbres décorrélés, la forêt annule leur instabilité individuelle : elle est robuste, demande peu de réglage, et fournit une mesure d'*importance des variables* (via la réduction de variance cumulée qu'apporte chaque variable) — utile pour hiérarchiser les inducteurs de charge. Le **gradient boosting** (dont XGBoost est l'implémentation de référence) procède au contraire *séquentiellement* : chaque nouvel arbre corrige les erreurs résiduelles des précédents. Cette correction ciblée le rend généralement plus précis que la forêt sur données tabulaires structurées, au prix d'un réglage plus délicat (un boosting mal réglé sur-apprend). Le compromis pratique est clair : Random Forest pour la robustesse et la simplicité de mise en œuvre ; gradient boosting pour la performance maximale quand on peut investir dans le réglage.

Le prix à payer : l'interprétabilité, et comment la restaurer. Ces ensembles gommant la lisibilité de l'arbre unique : on ne peut plus lire une règle, seulement constater une performance. C'est un vrai problème dans un contexte bancaire, où une estimation de coût opposée au Front Office doit être justifiable. La littérature sur l'*interpretable machine learning* répond par des méthodes d'explication *post-hoc*, appliquées après l'entraînement, indépendamment du modèle. La plus établie est celle des **valeurs de Shapley** (SHAP), issue de la théorie des jeux coopératifs [?]. L'idée : traiter chaque caractéristique comme un « joueur » contribuant à la prédiction, et lui allouer équitablement sa part de l'écart entre la prédiction et la moyenne. La valeur SHAP ϕ_j d'une variable j est sa contribution marginale moyenne, calculée sur tous les ordres d'entrée possibles des variables :

$$\phi_j = \sum_{S \subseteq N \setminus \{j\}} \frac{|S|! (|N| - |S| - 1)!}{|N|!} [f(S \cup \{j\}) - f(S)] \quad (12)$$

où N est l'ensemble des variables et S un sous-ensemble n'incluant pas j . Une propriété fondamentale rend SHAP idéal pour notre usage : les valeurs SHAP sont **additives** et somment exactement à l'écart entre la prédiction du deal et le coût moyen. On peut donc présenter au Front Office une décomposition intelligible : « ce deal coûte 180 K€, soit 90 K€ au-dessus de la moyenne ; +50 K€ viennent du nombre de prêteurs, +30 K€ du rôle d'agent, +10 K€ du multidevise ». On obtient ainsi le meilleur des deux mondes : la *précision* d'un modèle non linéaire et une *explication* par deal aussi lisible qu'une régression.

Le pilotage temporel, en appui. Enfin, la part de coût liée au *volume* et à sa saisonnalité (pics de *quarter-end*) relève de l'analyse de séries temporelles. Les modèles classiques (ARIMA, SARIMAX) y ajoutent des variables exogènes (pipeline commercial, calendrier réglementaire), mais la littérature récente souligne leurs limites — linéarité imposée, horizons fixes — et leur préfère désormais des ensembles d'arbres et des approches sous contrainte pour des demandes hétérogènes à horizon variable [?]. Ces approches restent en appui de nos deux finalités : elles prédisent le *volume* N , non le temps unitaire, qui demeure stable.

Une mise en garde de niveau. Deux erreurs guettent l'usage de ces modèles, et structurent notre méthodologie. D'abord, le modèle prédit le coût *total* d'un deal (fonction du volume et des caractéristiques), *non* le temps de *booking* unitaire, qui reste stable autour de vingt minutes : confondre les deux niveaux serait une faute d'analyse. Ensuite, et surtout, la qualité de toute prédiction est **bornée par celle de la mesure** : un modèle appris sur des temps unitaires mal estimés prédira un coût faux, quelle que soit sa sophistication. La seconde finalité est donc entièrement tributaire de la première — ce qui justifie l'ordre de ce chapitre et le poids que nous mettons sur la mesure du temps.

3.4 Les solutions professionnelles : ce que le marché résout, ce qu'il laisse ouvert

La question n'a pas échappé aux éditeurs, et deux familles de solutions éclairent par contraste notre contribution. Les plateformes de **Back-Office Workforce Management** (Verint, et les suites décrites par les intégrateurs

du secteur) capturent le temps de production réel des opérateurs à travers leurs applications pour équilibrer les charges, suivre les SLA et dimensionner les effectifs [?]. Elles adressent le *pilotage* de la charge, avec des gains documentés ; mais elles raisonnent en *capacité et débit*, non en *coût par objet* : elles disent si une équipe est surchargée, jamais ce que coûte un deal donné. À l'inverse, les **suites de costing** (CostPerform et le TDABC outillé) calculent un coût par activité et par objet, mais supposent l'intrant temps déjà résolu — elles industrialisent l'équation, pas la mesure du t_i .

Un courant professionnel récent, sur les projets d'IA en services financiers, formule la critique la plus utile à notre positionnement : la majorité des projets d'automatisation échouent faute d'avoir mesuré, *au niveau activité*, le travail réel avant d'automatiser — la donnée applicative (« six heures dans le système ») étant inexploitable pour décider, seule la donnée d'activité (« tant de minutes sur telle exception ») l'étant [?]. Ce constat conforte notre séquençage : la mesure fine du temps précède et conditionne toute optimisation. Aucune des deux familles d'outils ne construit le pont qui nous occupe — du temps unitaire mesuré jusqu'au coût, mesuré puis prédit, d'un deal de crédit syndiqué hétérogène.

3.5 Synthèse : un gap resserré sur l'intrant temps du TDABC

L'examen de la littérature ne débouche pas sur le constat commode qu'« aucun auteur n'a tout combiné ». Il désigne un manque unique et localisé. Le **TDABC fournit l'équation juste** (équation 6) pour reconstruire *et* prédire un coût par deal, et notre terrain la confirme. Mais il **suppose résolu son intrant le plus difficile**, le temps unitaire t_i , que la littérature critique désigne unanimement comme son talon d'Achille — d'autant plus en environnement hétérogène, où Koster *et al.* (2023) ont dû recourir à la logique floue pour absorber la variabilité des cas [?]. Or cet intrant se heurte, en opérations de crédit, à trois obstacles cumulatifs établis au fil du chapitre : *(i)* les méthodes classiques (Taylor, MTM) reposent sur une observation ou des tables inadaptées à un back office nearshore et automatisé ; *(ii)* le Process Mining lève cet obstacle mais ne livre qu'un temps écoulé bruité, non effectif ; *(iii)* la variabilité du coût ne vient pas du temps de *booking*, stable, mais du volume et de l'*aftercare*, que les caractéristiques du deal font varier de façon non additive.

Le *gap* se formule donc en une phrase : **il n'existe pas de protocole établi permettant d'estimer, pour des opérations de crédit syndiqué hétérogènes et partiellement automatisées, le temps unitaire fiable qu'exige le TDABC — en combinant la couverture des logs (Process Mining) et leur calibration par clocking — puis d'en déduire le coût d'un deal, mesuré rétrospectivement et prédit pour un deal futur au moyen d'un modèle non linéaire rendu interprétable.** Ce chaînon manquant gouverne les deux finalités à la fois : sans lui, ni la mesure ni la prédiction ne sont fiables. C'est lui, et lui seul, que notre contribution construit.

Notre recherche relève ainsi du *design science* [?] : elle produit un artefact — un protocole de mesure du temps unitaire et sa conversion en coût par deal, rétrospectif puis prédictif — dont la validité s'évalue par sa capacité à résoudre un problème organisationnel réel : rendre enfin comparable, deal par deal, le coût back office et le gain front office.

4 Formalisation et construction d'une mesure de la charge de travail

Construire une mesure n'est pas collecter des données : c'est trancher une série de décisions de conception, dont chacune engage la validité de tout ce qui suit. L'état de l'art a montré que le TDABC fournit l'équation du coût mais laisse ouvert son intrant — le temps unitaire par événement. Ce chapitre ne décrit pas une campagne de mesure ; il justifie les cinq arbitrages qui, ensemble, produisent un intrant fiable là où les méthodes existantes échouent : le choix de l'unité de mesure, la décomposition de la charge en deux objets de nature distincte, la neutralisation du biais d'allure par la séniorité, la conduite d'une collecte socialement sensible, et le raccordement de la mesure à la volumétrie. Chacun répond à une difficulté que ni Taylor, ni le MTM, ni le Process Mining ne résolvent seuls.

4.1 Premier arbitrage : l'événement comme unité, contre l'équipe et le deal

Le choix de l'unité de mesure détermine ce qu'on pourra reconstruire ensuite. Trois granularités étaient possibles, et deux sont des impasses. Me-

surer la charge au niveau de l'**équipe** — un total d'heures mensuel — est la donnée que fournissent naturellement les systèmes RH, mais elle est inexploitable pour notre finalité : on ne peut pas en redescendre au coût d'un deal, puisqu'un deal ne consomme qu'une fraction non identifiable de ce total. Mesurer directement au niveau du **deal** serait la cible, mais c'est circulaire : le coût d'un deal est justement l'inconnue ; on ne peut pas le chronométrer globalement sans avoir déjà décomposé ce qui le compose.

Le seul niveau qui rende le problème soluble est l'**événement opérationnel**. Il est à la fois assez fin pour être chronométrable de façon homogène, et assez structurant pour que tout deal se recompose comme la somme de ses événements. Ce choix n'est pas neutre : il impose que la charge soit *additive en événements*, hypothèse que nos données valident pour le booking (un événement de type donné a un temps stable) mais que nous devons nuancer pour l'aftercare (§4.2). C'est aussi ce qui aligne notre mesure sur le TDABC, dont l'unité est précisément l'activité dotée d'un *duration driver*. Retenir l'événement, c'est donc faire le pari qu'une charge complexe et continue peut être reconstruite à partir de briques discrètes et mesurables — pari que la suite du chapitre met à l'épreuve.

4.2 Deuxième arbitrage : deux objets, non un — Event Processing et Aftercare

La décision la plus lourde de conséquences est de refuser de traiter la charge unitaire comme un bloc homogène. Une lecture naïve mesurerait « le temps de traitement d'un événement » et s'arrêterait là. Nos observations imposent de le scinder en deux objets qui n'obéissent pas aux mêmes lois — et donc n'appellent ni la même mesure, ni le même modèle.

Le premier, l'**Event Processing** (le *booking* dans Loan IQ), se comporte comme une tâche standardisable : sa durée dépend de facteurs *qualitatifs* (type d'événement, rôle, produit, séniorité, équipe) et se révèle remarquablement stable — de l'ordre de vingt minutes, quel que soit le type. C'est le domaine du temps standard classique. Le second, l'**Aftercare**, obéit à une logique opposée : sa charge ne dépend pas du *type* d'un événement mais du *volume* de sollicitations que le deal engendre en aval — nombre de prêteurs, de facilités, de courriels de gestion, de réconciliations. Sa relation aux caractéristiques du deal est *proportionnelle et quantitative* là où celle du booking est catégorielle.

Cette dualité est le cœur analytique de notre construction, pour une raison précise : **confondre les deux objets rendrait la mesure fautive dans les deux sens**. Traiter l’aftercare comme un temps standard par type sous-estimerait massivement les gros deals syndiqués, dont l’aftercare explose avec le nombre de prêteurs ; inversement, traiter le booking comme une fonction du volume lui prêterait une variabilité qu’il n’a pas. La séparation n’est donc pas un raffinement esthétique : c’est ce qui permet, au chapitre 5, de leur appliquer deux familles de modèles adaptées à leur nature respective — des modèles à interactions (Random Forest, gradient boosting) pour les facteurs qualitatifs de l’Event Processing, une régression aux coefficients directement interprétables pour la relation proportionnelle de l’Aftercare, où « chaque prêteur supplémentaire ajoute X minutes ». La structure de la mesure préfigure ainsi la structure de la modélisation.

4.3 Troisième arbitrage : remplacer le facteur d’allure par la séniorité

Le principe tayloriste du temps standard reste valide : chronométrer un temps observé, puis le corriger pour le ramener à une référence comparable. Mais l’état de l’art a isolé son point de rupture — le **facteur d’allure** F_a , jugement de l’analyste sur le rythme de l’opérateur, subjectif par construction et impraticable entre des équipes réparties sur deux pays. C’est le verrou méthodologique central, et le résoudre est notre principale contribution instrumentale.

La solution consiste à substituer au jugement d’allure une **variable observable et objective : la séniorité de l’opérateur**. Là où Taylor pose $T_n = T_o \times F_a$ avec F_a estimé à l’œil, nous posons :

$$T_s = T_o \times \sigma \tag{13}$$

où σ est un facteur de normalisation dérivé du niveau de séniorité. Ce déplacement change la nature de la mesure : le temps standard cesse de dépendre de qui observe pour ne dépendre que de qui exécute, caractérisé par une donnée reproductible. Trois justifications le fondent. *Empiriquement*, l’écart de vitesse entre un opérateur junior récemment formé et un senior est réel et systématique ; l’ignorer biaiserait toute comparaison entre équipes. *Contextuellement*, cette correction est indispensable précisément à cause du near-shoring : le transfert vers Lisbonne s’accompagne d’une juniorisation globale

des équipes, si bien qu'un temps non normalisé confondrait un deal complexe avec un deal traité par une équipe junior. *Méthodologiquement*, remplacer un jugement par une variable rend la mesure *auditable* — un tiers peut reproduire la correction, ce qui était impossible avec F_a .

Il faut toutefois assumer la limite de ce choix : la séniorité doit elle-même être quantifiée par une convention (niveaux d'expérience, ancienneté sur le poste), et cette convention introduit sa propre part d'arbitraire. Nous préférons cet arbitraire-là — explicite, documenté, reproductible — au jugement d'allure implicite qu'il remplace. Le gain net est une mesure comparable entre Paris et Lisbonne, condition *sine qua non* de toute analyse d'allocation entre sites.

4.4 Quatrième arbitrage : mesurer un travail dont la mesure menace ceux qui l'exécutent

Les trois arbitrages précédents étaient techniques. Celui-ci est social, et il conditionne la validité de tous les autres : aucune finesse méthodologique ne rachète des temps collectés dans la défiance. Or notre mesure naît d'une tension qu'il serait malhonnête de taire.

Un fondement sensible. Ce projet ne mesure pas la charge par curiosité académique : il s'inscrit dans une démarche de *cost to serve* dont la finalité assumée est la réduction des coûts — *hard savings* et *cost avoidance* — alignée sur les objectifs d'efficacité du Groupe (plan GTS). Mesurer le coût d'un deal, c'est *in fine* mesurer le coût des équipes qui le traitent. Et ces équipes le savent. Chronométrer un opérateur Loan Servicing revient donc à l'observer sur le terrain même où se décide, à terme, le dimensionnement — voire la localisation — de son poste, dans un contexte de nearshoring où les transferts d'activité de Paris vers Lisbonne sont une réalité vécue, non une hypothèse. Le *clocking* n'est pas un acte neutre : c'est une mesure perçue, à juste titre, comme potentiellement menaçante par ceux qui la subissent.

Pourquoi cette tension est un problème de mesure, pas seulement d'éthique. On pourrait croire que l'enjeu est purement déontologique. Il est aussi, et d'abord, *méthodologique*. Un opérateur qui perçoit le chronométrage comme un instrument de justification de suppressions de postes a un intérêt rationnel à en fausser le résultat : ralentir pour gonfler les temps,

éviter les cas complexes pendant l’observation, ou simplement se crispier au point de ne plus travailler à son rythme normal. C’est exactement le *biais de réactivité* (effet Hawthorne) : le fait d’être observé modifie le comportement observé. Dans notre cas, ce biais n’est pas aléatoire mais *orienté* — la crainte pousse structurellement vers la surestimation des temps. Une mesure sociale mal conduite ne produit donc pas seulement du malaise : elle produit des données biaisées dans une direction connue, ce qui invaliderait le coût reconstruit.

Les partis retenus pour désamorcer le biais. Nous en tirons plusieurs choix de conduite de la collecte, qui font partie intégrante du protocole. *Premièrement*, dissocier explicitement la mesure de l’évaluation individuelle : le clocking porte sur des *types d’événements*, non sur des personnes, et les temps sont agrégés par type, jamais restitués nominativement. La normalisation par la séniorité (§4.3) sert aussi cet objectif : en corrigeant l’écart junior/senior, elle retire à l’opérateur individuel l’enjeu d’être « jugé lent ». *Deuxièmement*, expliquer la finalité réelle : présenter la mesure non comme un contrôle de productivité mais comme un instrument de *reconnaissance* de la charge — objectiver la charge d’aftercare invisible, justifier des besoins en effectifs, chiffrer la valeur d’une automatisation qui allège les tâches pénibles. La mesure peut servir les équipes autant que les menacer, et le dire honnêtement est la condition d’une collecte sincère. *Troisièmement*, accepter que l’accès au terrain soit un processus lent et négocié : obtenir des créneaux d’observation suppose la coopération de managers et d’opérateurs qui n’y ont pas d’intérêt immédiat, ce qui explique en partie l’étalement de la campagne sur quatre mois.

Une limite assumée. Nous ne prétendons pas avoir neutralisé ce biais, seulement l’avoir contenu et rendu explicite. C’est là un écart irréductible avec la mesure d’une machine, et il faut l’inscrire au bilan de validité de l’étude : nos temps sont ceux d’opérateurs conscients d’être mesurés, dans un contexte qu’ils savent lié à la maîtrise des coûts. Reconnaître cette limite vaut mieux que la masquer derrière une fausse objectivité ; elle rappelle que mesurer un travail humain n’est jamais un acte purement technique, et que la fiabilité d’une telle mesure se joue autant dans la relation avec les équipes que dans la rigueur du chronomètre.

4.5 Cinquième arbitrage : raccorder le temps standard à la volumétrie réelle

Un temps standard par événement ne dit rien, seul, du coût d'un deal : il faut le multiplier par le *nombre* d'événements que le deal génère. La dernière décision de conception est donc le raccordement de la mesure (issue du clocking) à la volumétrie (issue des systèmes) — deux mondes de granularité et de source différentes qu'il faut joindre sans introduire de biais.

Ce raccordement repose sur une division du travail entre trois sources, chacune pour ce qu'elle mesure le mieux. Le **clocking** — notre campagne d'observation — fournit le temps standard par type d'événement, la seule grandeur qui exige une mesure humaine du temps effectif. **Loan IQ** fournit la volumétrie et les caractéristiques structurelles de chaque deal, que les logs enregistrent exhaustivement. **Ambre** objective la part de réconciliation rattachable à l'aftercare. La jointure sur l'identifiant de deal et le type d'événement produit alors, pour chaque deal, l'ensemble de ses événements valorisés en temps standard et qualifiés par leurs attributs.

L'intérêt analytique de cette architecture est qu'elle sépare proprement ce qui est *mesuré une fois* (le temps standard, coûteux à obtenir, stable dans le temps) de ce qui est *compté en continu* (le volume, gratuit, actualisé par les systèmes). Le clocking n'a donc pas à être répété pour chaque deal : mesuré une fois par type d'événement, il se déploie sur l'ensemble du portefeuille via la volumétrie. C'est ce qui rend la mesure *industrialisable* — une campagne d'observation bornée dans le temps suffit à valoriser des années d'historique et, par extension, à alimenter la prédiction de deals futurs. La base ainsi constituée — un enregistrement par événement, relié à un deal, valorisé et qualifié — est l'artefact que le chapitre 5 exploite selon ses deux finalités : agrégation pour le coût rétrospectif, apprentissage pour le coût prédictif.

4.6 Synthèse : une mesure fiable, juste, comparable, acceptable et industrialisable

Les cinq arbitrages se répondent. Le choix de l'événement rend la charge recomposable ; la séparation Event Processing / Aftercare la rend juste ; la normalisation par la séniorité la rend comparable entre sites ; la conduite attentive de la collecte la rend socialement acceptable et non biaisée ; le raccordement à la volumétrie la rend industrialisable. Aucune méthode existante ne réunissait ces propriétés : le chronométrage tayloriste classique achoppait

sur le biais d'allure, le MTM sur l'inadaptation de ses tables, le Process Mining sur le temps écoulé et l'angle mort de l'aftercare, et aucune ne thématissait la sensibilité sociale d'une mesure adossée à la réduction des coûts. La contribution de ce chapitre n'est pas d'avoir mesuré, mais d'avoir conçu un dispositif qui produit un temps unitaire fiable là où chaque approche isolée échouait — l'intrant que le TDABC supposait donné, et sans lequel ni la mesure ni la prédiction du coût (chapitre 5) ne tiendraient.

5 Analyse et exploitation de la charge de travail pour l'aide à la décision

La mesure construite au chapitre 4 — une base d'événements valorisés en temps standard, qualifiés par leurs caractéristiques et raccordés à la volumétrie réelle — n'a de valeur que par ce qu'elle permet de décider. Ce chapitre l'exploite selon les deux finalités du mémoire. Il reconstruit d'abord le coût *rétrospectif* d'un deal traité (§5.1), identifie ensuite les facteurs qui déterminent la charge (§5.2), puis en dérive un modèle *prédictif* du coût d'un deal futur (§5.3). Il montre enfin comment cette double mesure alimente le pilotage opérationnel (§??), avant d'en discuter les limites et les prolongements (§??).

5.1 Reconstruire le coût rétrospectif d'un deal

La première exploitation est directe : appliquer l'équation du TDABC à la base de mesures. Pour un deal donné, le coût opérationnel est la somme, sur tous ses événements, du temps standard valorisé au coût horaire chargé du site qui le traite :

$$C_{\text{deal}} = \sum_{i=1}^N T_{s,i} \times w_{s(i)} = \underbrace{\sum_{i=1}^N T_{\text{EP},i} \times w_{s(i)}}_{\text{Event Processing}} + \underbrace{T_{\text{AC}} \times w_s}_{\text{Aftercare}} \quad (14)$$

où N est le volume d'événements du deal, $T_{s,i}$ le temps standard de l'événement i , et $w_{s(i)}$ le coût horaire chargé du site s le traitant. Les deux composantes du chapitre 4 y apparaissent séparément : le coût d'*Event Processing*,

somme des bookings valorisés, et le coût d'*Aftercare*, fonction du volume de sollicitations aval du deal.

L'agrégation, du booking au coût. Concrètement, chaque type d'événement porte un temps moyen issu du clocking (de l'ordre de vingt minutes pour le booking, avec des écarts selon le type : un drawdown plus long qu'un paiement d'intérêt), et chaque deal porte un compte d'événements par type issu de Loan IQ. Leur produit, sommé et valorisé, donne le coût. La force de cette reconstruction est qu'elle rend visible ce qui était opaque : on peut désormais dire non seulement qu'un deal « coûte cher », mais *pourquoi* — combien de minutes viennent du booking, combien de l'*aftercare*, quelle part est imputable au volume et quelle part à la complexité.

Un résultat structurant : la dispersion extrême des coûts. Appliquée au portefeuille, cette reconstruction révèle une dispersion considérable du coût par deal. Un deal simple — rôle de participant, peu de prêteurs, monodevise, faible volume — se traite pour l'équivalent de quelques milliers d'euros et une fraction d'équivalent temps plein. Un deal complexe — rôle d'agent, plusieurs centaines de prêteurs, multidevise, volume d'événements élevé — peut atteindre plusieurs centaines de milliers d'euros et mobiliser plusieurs équivalents temps plein sur l'année. Cet écart, d'un à plusieurs dizaines, est le résultat le plus important de la mesure rétrospective : il établit que le coût opérationnel n'est pas une constante par deal, mais une grandeur hautement variable, et que cette variabilité est *explicable* par les caractéristiques du deal — ce que la section suivante démontre.

Ce que la mesure débloque. En rendant ce coût comparable au gain connu du Front Office, la reconstruction rétrospective répond au constat fondateur du projet : contrairement au Front Office, dont l'activité se mesure en revenus (P&L), le Back Office ne se mesurait qu'en coût global, jamais par deal. Le coût par deal ouvre ainsi trois usages immédiats, développés en §?? : chiffrer l'impact des initiatives de réduction des coûts au management (objectifs GTS), comparer le coût de traitement entre Paris et Lisbonne pour évaluer le *cost avoidance* du nearshoring, et identifier les deals à coût anormalement élevé.

5.2 Identifier les facteurs explicatifs de la charge

Reconstruire le coût ne suffit pas : pour le *prédire* et l'*expliquer* au management, il faut savoir quels paramètres le déterminent, et avec quel poids. C'est l'objet du sous-objectif de la mission : « *understand the impact of each parameter of the LS workload* ». La séparation des deux composantes (chapitre 4) impose ici de distinguer deux ensembles de facteurs, de nature différente.

Les facteurs de l'Event Processing : qualitatifs et catégoriels. Le temps de booking dépend de variables essentiellement *qualitatives*, dont le nombre de modalités est fini :

- le **type d'événement** (drawdown, fee, repricing, transfer, adjustment, accrual, paper clip...), le facteur le plus discriminant ;
- le **rôle** de la banque (agent, participant, bilatéral) ;
- le **produit** et la **ligne de métier** ;
- l'**équipe** et la **séniorité** de l'opérateur, qui capturent l'effet site et l'effet expérience.

Ces facteurs agissent de façon *non additive* : l'effet du rôle d'agent n'est pas le même selon le type d'événement, et se combine avec lui. C'est cette structure d'interactions qui oriente, en §5.3, le choix de modèles à base d'arbres.

Les facteurs de l'Aftercare : quantitatifs et proportionnels. Le temps d'aftercare, lui, dépend de variables *quantitatives* qui mesurent le volume de gestion aval engendré par le deal :

- le **nombre de prêteurs** (*lenders*) ;
- le **nombre d'événements** du deal ;
- le **nombre de courriels** de gestion (*mails in Hobart*) ;
- le **nombre de facilités**.

Leur relation à la charge est approximativement *proportionnelle* : plus un deal compte de prêteurs, plus il génère de documents, de confirmations et de réconciliations à traiter. Cette proportionnalité est une propriété précieuse : elle rend la relation modélisable par une régression aux coefficients directement interprétables — « chaque prêteur supplémentaire ajoute X minutes d'aftercare » — langage immédiatement actionnable pour le management.

Cette dichotomie — facteurs qualitatifs en interaction pour l'Event Processing, facteurs quantitatifs proportionnels pour l'Aftercare — n'est pas

un constat secondaire : elle commande deux stratégies de modélisation distinctes, ce qui distingue notre approche d’un modèle unique appliqué indistinctement à toute la charge.

5.3 Construire un modèle prédictif du coût

La seconde finalité — prédire le coût d’un deal *avant* son traitement — consiste à apprendre, sur l’historique des deals, la fonction qui relie leurs caractéristiques à leur charge. Fidèle à la dualité établie, nous construisons **deux modèles distincts**, chacun adapté à la nature de sa composante, puis les recombinaisons en un coût total prédit.

5.3.1 Modéliser l’Event Processing : arbres et ensembles

Les facteurs de l’Event Processing étant qualitatifs et en interaction, une régression linéaire échouerait — son hypothèse d’additivité (chapitre 3) ne tient pas. Nous retenons donc des **méthodes à base d’arbres**, qui capturent nativement les interactions. Un arbre de décision partitionne récursivement les événements selon les questions qui minimisent la variance du temps intra-groupe (par exemple « type = drawdown ? » puis « rôle = agent ? »), produisant des règles lisibles. Mais un arbre unique étant instable, nous recourons à deux stratégies d’agrégation :

- le **Random Forest**, qui moyenne des centaines d’arbres entraînés sur des échantillons aléatoires, $\hat{f}(x) = \frac{1}{B} \sum_{b=1}^B T_b(x)$; robuste, peu sensible au réglage, il fournit une mesure d’importance des variables qui hiérarchise les facteurs de charge ;
- le **gradient boosting** (XGBoost), qui construit les arbres séquentiellement, chacun corrigeant les erreurs du précédent ; généralement plus précis sur données tabulaires, au prix d’un réglage plus fin.

Le compromis est classique : Random Forest pour la robustesse et la lecture des importances, gradient boosting pour la performance maximale. Dans les deux cas, l’interprétabilité perdue par l’agrégation est restaurée *a posteriori* par les valeurs SHAP (chapitre 3), qui décomposent chaque prédiction en contributions additives — permettant de présenter au management, pour un deal donné, la part de coût imputable à chaque facteur.

5.3.2 Modéliser l’Aftercare : la régression, pour l’interprétabilité

Pour l’Aftercare, le choix s’inverse. La relation étant proportionnelle et les variables quantitatives, une **régression** est non seulement suffisante mais préférable : elle est plus lisible qu’un ensemble d’arbres, et sa lisibilité est ici un objectif, non un compromis. Le modèle de base s’écrit :

$$T_{AC} = \beta_0 + \beta_1 n_{lenders} + \beta_2 n_{events} + \beta_3 n_{mails} + \beta_4 n_{facilities} + \varepsilon \quad (15)$$

où chaque coefficient β_k se lit directement comme le temps d’aftercare ajouté par une unité supplémentaire du facteur correspondant. Là où la relation présente une courbure — par exemple un effet d’échelle au-delà d’un certain nombre de prêteurs — une **régression polynomiale** l’absorbe sans sacrifier l’interprétabilité. Ce choix illustre un principe de notre démarche : on n’emploie un modèle complexe que là où la nature du phénomène l’exige (Event Processing), et on préserve la simplicité là où elle suffit et sert la communication (Aftercare).

5.3.3 Recomposer le coût prédit

Les deux modèles se recombinent en un coût total prédit pour un deal caractérisé par son vecteur d’attributs x :

$$\hat{C}_{deal} = \left[\hat{f}_{EP}(x) \times N + \hat{T}_{AC}(x) \right] \times w_s \quad (16)$$

où $\hat{f}_{EP}$ est le modèle à base d’arbres de l’Event Processing, $\hat{T}_{AC}$ la régression de l’Aftercare, N le volume d’événements attendu et w_s le coût horaire du site. Cette équation est le produit central du mémoire du côté prédictif : elle permet, dès la signature d’un deal — lorsqu’on connaît son rôle, sa devise, son nombre de prêteurs et de facilités, sans avoir traité le moindre événement — d’estimer ce qu’il coûtera aux opérations. La performance de ces modèles s’évalue par les métriques usuelles de régression (erreur absolue moyenne, RMSE, R^2), en distinguant l’erreur sur chaque composante pour diagnostiquer laquelle limite la précision globale.

6 Conclusion

Bibliography

- [1] Brian W. Kernighan and Dennis M. Ritchie. 1988. The C Programming Language (2nd. ed.). Prentice Hall Professional Technical Reference.
- [2] Olivier Cailloux. Elicitation indirecte de modèles de tri multicritère. Autre. Ecole Centrale Paris, 2012. Français. ⟨NNT : 2012ECAP0043⟩. ⟨tel-00773683v2⟩