



Thèse universitaire présentée à l'Université Paris Dauphine dans
le cadre de l'obtention du diplôme de **Master 2 MIAGE**

Modélisation du temps de travail des équipes Back Office de BNP Paribas

David ROUFÉ

Entreprise: BNP PARIBAS

Tutrice d'alternance : NEGRE Elsa

Tuteur en entreprise : RAHMANI Abdelaziz

Septembre, 2026

Table des matières

Thanks	vi
1 Introduction	1
2 Contexte	6
2.1 Contexte organisationnel	6
2.1.1 Organisation du département GCO (Global Credit Operations)	6
2.1.2 Organisation de l'équipe Strategic Transformation & Data Analytics	7
2.1.3 Organisation générale de la banque	8
2.2 Typologie des événements opérationnels	8
2.3 Définition du concept de charge de travail	13
3 État de l'art	17
3.1 Les méthodes classiques de mesure du travail	17
3.1.1 L'étude des temps et le management scientifique	17
3.1.2 L'étude des mouvements et les systèmes de temps pré-déterminés	20
3.2 La charge de travail : un construit multidimensionnel	22
3.2.1 Dimensions objectives et subjectives de la charge	22
3.2.2 Le NASA Task Load Index (NASA-TLX)	23
3.3 L'adaptation des indicateurs industriels aux services : le cas de l'OEE	25
3.3.1 Principes et structure de l'OEE	25
3.3.2 Limites de transposition et adaptations nécessaires	25
3.4 Approches de modélisation prédictive	26
3.4.1 Modèles statistiques classiques	26
3.4.2 Méthodes d'apprentissage automatique	27
3.5 Process Mining et excellence opérationnelle en milieu bancaire	28
3.5.1 Le Process Mining comme outil de diagnostic de la charge	28
3.5.2 Le Lean Management appliqué aux opérations de BFI	29
3.6 Planification des effectifs et aide à la décision	30
3.6.1 Modèles de Recherche Opérationnelle	30
3.6.2 Approches prédictives et anticipation des pics	30

3.7	Synthèse critique et positionnement de la recherche	31
3.7.1	Cartographie du champ et identification du <i>gap</i>	31
3.7.2	Contribution attendue	33
4	Conclusion	35
	Bibliography	35

Table des figures

1	Chaîne de valeur du crédit syndiqué : organisation verticale et supervision transversale	7
2	Structure géographique de l'équipe (FR = France, PT = Portugal)	8
3	Cycle de vie des événements opérationnels en Loan Servicing. Les flèches pleines représentent le flux nominal ; les flèches en pointillés indiquent les boucles de retour.	9
4	Répartition estimée de la charge entre traitement manuel, partiellement automatisé et entièrement automatisé (RPA), par famille d'événements. Les modifications contractuelles restent quasi exclusivement manuelles.	12
5	Les quatre dimensions constitutives de la charge de travail en opérations de crédit. Le cercle central représente le construit latent W que ce mémoire vise à formaliser.	14
6	Illustration de la relation entre flux d'arrivée des événements $\lambda(t)$ et capacité de traitement $c \cdot \mu$. Les zones ombrées correspondent aux périodes de surcharge ($\rho > 1$), typiquement associées aux <i>quarter-ends</i>	16
7	Protocole de l'étude des temps selon Taylor (1911), adapté de Groover (2007).	19
8	Taxonomie des mesures de la charge de travail, adaptée de Wickens (2008).	22
9	Flux simplifié du traitement d'un deal en opérations de crédit, tel que reconstruit par <i>Process Mining</i> . Les boucles de reprise constituent des sources cachées de charge additionnelle.	29
10	Cartographie des quatre champs disciplinaires contribuant à la mesure de la charge de travail en Back Office bancaire. Le cercle central représente le cadre intégré que ce mémoire vise à construire.	32

Liste des tableaux

1	Cycle de vie opérationnel d'un crédit syndiqué	9
---	--	---

2	Synthèse des familles d'événements opérationnels en Loan Servicing	11
3	Comparaison des méthodes classiques de mesure du travail . .	21
4	Les six sous-échelles du NASA-TLX et leur pertinence pour le Back Office bancaire	24
5	Performance comparée des modèles prédictifs sur données RH, d'après Shaik <i>et al.</i> (2025)	27

Remerciements

Je remercie ...

1 Introduction

Contexte général

Le secteur bancaire traverse depuis deux décennies une transformation profonde de ses fonctions opérationnelles. La pression réglementaire croissante, l'intensification concurrentielle et l'accélération des volumes de transactions ont conduit les banques de financement et d'investissement (BFI) à repenser l'organisation de leurs activités de Back Office. Cette transformation répond à un impératif économique central : réduire le *cost to serve*, c'est-à-dire le coût unitaire de traitement de chaque opération. Chez BNP Paribas, cet impératif a été formalisé à travers des plans stratégiques successifs. Le plan *GTS2025 (Growth, Technology, Sustainability)*, lancé en 2022, a placé la technologie et l'industrialisation au cœur du modèle opérationnel, avec un objectif explicite de génération de *hard savings*. Au sein de CIB, cette ambition s'est déclinée à travers le programme *GB Indus (Global Banking Modernisation & Industrialisation)*, visant à industrialiser les processus opérationnels d'un métier présent dans une cinquantaine de pays. Le plan 2027 - 2030, en cours de préparation, prolonge cette trajectoire en engageant un programme structurel de transformation des activités de support — revue des processus de bout en bout, mutualisation des infrastructures, simplification applicative et intensification de l'usage de l'intelligence artificielle — avec l'objectif d'amener le coefficient d'exploitation du Groupe sous les 56. Depuis 2020, cette dynamique s'est encore accélérée sous l'effet de trois forces convergentes qui redessinent le paysage des opérations bancaires.

La première est la généralisation du *nearshoring* et de l'*offshoring* des fonctions opérationnelles. Confrontées à une pression constante sur les coûts, les BFI ont massivement délocalisé une partie de leurs activités de traitement vers des centres de services partagés situés à Lisbonne, Varsovie, Mumbai ou Montréal. Ce mouvement a fragmenté les chaînes de traitement, multiplié les fuseaux horaires et les *handovers* (passations) entre équipes, et complexifié considérablement le pilotage de la charge de travail. Là où un manager supervisait autrefois une équipe co-localisée de dix opérateurs, il doit désormais coordonner des ressources réparties sur plusieurs sites, avec des niveaux de compétence, d'ancienneté et de productivité hétérogènes.

La deuxième force est l'irruption de l'intelligence artificielle et de l'automatisation dans les processus opérationnels. Le déploiement de solutions

de *Robotic Process Automation* (RPA) a permis d'automatiser les tâches les plus répétitives — extractions de données, contrôles de cohérence, alimentation de systèmes. Plus récemment, l'émergence de l'IA générative ouvre des perspectives de transformation plus profondes : rédaction automatisée de *facility letters*, extraction intelligente de clauses contractuelles, assistance à la prise de décision sur les cas complexes. Ces technologies ne suppriment pas la charge de travail humaine ; elles en modifient la nature. Les tâches routinières se réduisent, tandis que le travail résiduel se concentre sur les opérations à forte valeur ajoutée — précisément celles qui sont les plus complexes, les plus variables et les plus difficiles à mesurer.

La troisième est la perte d'attractivité du secteur et la guerre des talents. Les métiers du Back Office bancaire peinent à recruter et à fidéliser, en particulier auprès des jeunes générations qui valorisent l'équilibre vie professionnelle / vie personnelle et la qualité de vie au travail. Dans ce contexte, une charge de travail mal répartie ou non anticipée ne produit pas seulement des risques opérationnels : elle génère de l'attrition, de la démotivation et une perte de compétences critiques. Le pilotage de la charge devient ainsi un enjeu de ressources humaines autant que d'efficacité opérationnelle.

C'est dans cet environnement en mutation rapide que se positionne notre recherche. Au sein des fonctions transversales comme le Back Office, la question de la valeur produite se pose en des termes fondamentalement différents de ceux du Front Office : là où les équipes commerciales peuvent mesurer directement les revenus qu'elles génèrent, les équipes opérationnelles ne disposent pas de cette visibilité. En revanche, elles connaissent précisément leur coût — un coût généré majoritairement par les ressources humaines qui composent ces équipes. Cette asymétrie place le pilotage de la charge de travail au cœur de la démonstration de valeur : faute de pouvoir prouver combien elles rapportent, ces équipes doivent démontrer qu'elles optimisent ce qu'elles coûtent. C'est précisément ce que les plans stratégiques successifs exigent d'elles à travers les objectifs de *cost savings* et de *hard savings*. Les équipes en charge du traitement des opérations de crédit — communément désignées sous le terme de *Loan Servicing* — occupent une position centrale dans cette logique : elles assurent le traitement opérationnel de l'ensemble des événements survenant durant la vie d'un contrat de crédit, depuis le tirage initial (*drawdown*) jusqu'au remboursement final, en passant par les amendements contractuels, les ajustements de taux et les opérations de restructuration. Ces équipes opèrent sous une double contrainte : les exigences de qualité et de conformité imposent un traitement rigoureux dans le respect de délais

contractuels stricts, tandis que la volumétrie et la complexité des opérations varient considérablement sous l’effet de cycles commerciaux, de saisonnalités financières et de chocs exogènes. Cette tension entre exigence de qualité constante et variabilité de la charge, dans un contexte où chaque poste représente un coût visible et soumis à des objectifs de réduction planifiés, constitue le défi managérial que ce mémoire se propose d’adresser.

Contexte organisationnel

Ce travail de recherche s’inscrit dans le cadre d’une mission réalisée au sein du département *Global Credit Operations* (GCO) de BNP PARIBAS. Le département GCO gère l’ensemble des opérations de crédit à destination d’États, d’institutions financières et de contreparties corporates. Dans la chaîne de traitement d’un deal, plusieurs équipes interviennent successivement : le Front Office lors de la signature et de l’origination, le Middle Office pour les informations réglementaires et contractuelles, et les équipes Back Office — plus précisément les équipes *Loan Servicing* (LS) — qui assurent le traitement des informations dans le progiciel Loan IQ.

L’organisation de GCO illustre les tendances sectorielles décrites ci-dessus. Certaines activités de traitement ont été délocalisées, les premières briques d’automatisation (macros VBA, RPA) ont été déployées, et l’équipe *Strategic Transformation & Data Analytics* — à laquelle nous sommes rattachés — porte les projets de transformation digitale et d’exploitation des données. Parmi ces projets, la création d’interfaces automatisées (*Power of Attorney, facility letters*), le développement de KPI à destination du *high management*, et surtout la conception d’une mesure fiable de la charge de travail des équipes Back Office.

La charge de travail est ici appréhendée comme un objet complexe, résultant de la diversité des événements opérationnels, de leur fréquence, de leur variabilité et de leurs contraintes. Elle ne peut être observée directement sans un travail préalable de formalisation et d’instrumentation — travail d’autant plus nécessaire que l’automatisation croissante modifie en continu le périmètre du travail humain.

Problématique et enjeux

L’enjeu opérationnel est considérable. En l’absence d’une mesure robuste de la charge de travail, le pilotage de l’activité repose sur des estimations

empiriques et sur l'expérience des managers — une approche qui atteint ses limites face à la complexité croissante des opérations, à la dispersion géographique des équipes et à la transformation des tâches par l'automatisation. Les conséquences d'un pilotage déficient sont multiples : allocation sous-optimale des ressources humaines entre sites *onshore* et *nearshore*, incapacité à anticiper les pics d'activité, augmentation des risques opérationnels (délais de traitement, erreurs, reprises), dégradation des conditions de travail et accélération du *turnover*.

Ce constat conduit à formuler la problématique suivante :

Comment la charge de travail des équipes Back Office peut-elle être formalisée en une mesure quantitative fiable au service de l'aide à la décision organisationnelle ?

Cette question de recherche se décline en trois sous-questions, ordonnées selon une progression logique allant de la mesure à la décision :

1. **Mesurer.** Comment construire un protocole de collecte des temps de traitement adapté aux opérations de crédit informatisées, qui tienne compte de la variabilité liée à la complexité des deals, aux conditions opérationnelles et à la répartition géographique des équipes ?
2. **Modéliser.** Quels modèles statistiques et d'apprentissage automatique permettent d'expliquer et de prédire la charge de travail à partir des caractéristiques observables des opérations ?
3. **Décider.** Comment traduire cette mesure prédictive en outil d'aide à la décision pour l'allocation des ressources entre sites et l'anticipation des pics d'activité ?

Démarche méthodologique

Pour répondre à cette problématique, nous adoptons une démarche de *design science* (Hevner *et al.*, 2004), dont l'objectif est la construction et l'évaluation d'un artefact — ici, un modèle de mesure et de prédiction de la charge de travail — dans un contexte organisationnel réel. Cette démarche se déploie en quatre phases :

Phase 1 — Compréhension du processus. Nous procédons à une analyse approfondie de l'organisation des opérations de crédit et du rôle des équipes Loan Servicing, en identifiant la typologie des événements opérationnels et les facteurs de complexité qui les caractérisent.

Phase 2 — Revue de littérature. Nous recensons les approches existantes de mesure et de modélisation de la charge de travail, en mobilisant quatre champs disciplinaires : le génie industriel (études de temps, MTM), l’ergonomie cognitive (NASA-TLX), la science des données (régression, apprentissage automatique, Process Mining) et la Recherche Opérationnelle (théorie des files d’attente, optimisation).

Phase 3 — Formalisation et construction de la mesure. Nous définissons un protocole de collecte des temps de traitement (*clocking*), concevons la base de données des mesures et établissons les conditions de mesurabilité des opérations.

Phase 4 — Analyse et exploitation. Nous identifions les facteurs explicatifs de la charge de travail par des méthodes statistiques et d’apprentissage automatique, construisons un modèle prédictif et en dérivons des recommandations pour le pilotage opérationnel : allocation des ressources, anticipation des pics et prévision de la charge.

Annnonce du plan

Ce mémoire s’organise en cinq chapitres. Le **chapitre 1** présente le contexte organisationnel des opérations de crédit et caractérise l’objet d’étude — la charge de travail des équipes Loan Servicing dans un environnement marqué par le nearshoring et l’automatisation. Le **chapitre 2** propose un état de l’art des méthodes de mesure et de modélisation de la charge de travail, et identifie le *gap* que ce mémoire vise à combler. Le **chapitre 3** détaille la méthodologie de formalisation et de construction de la mesure, du protocole de collecte à la structuration de la base de données. Le **chapitre 4** expose l’analyse des données collectées, la construction du modèle prédictif et les apports pour le pilotage opérationnel. Enfin, le **chapitre 5** discute les limites de la démarche, les conditions de généralisation des résultats et les perspectives d’évolution — notamment l’intégration de l’IA générative comme levier de transformation de la charge de travail.

2 Contexte

2.1 Contexte organisationnel

2.1.1 Organisation du département GCO (Global Credit Operations)

Le département **Global Credit Operations** (GCO) de BNP Paribas structure ses activités autour de pôles complémentaires, chacun jouant un rôle clé dans la chaîne de traitement des opérations de crédit syndiqué. Le *crédit syndiqué* est un crédit accordé à une entreprise par un groupe de banques agissant conjointement, permettant de répartir le risque de financement tout en mobilisant des montants élevés [?].

- **Équipes transversales** : elles jouent un rôle de *surplomb*, en veillant à la cohérence et à la performance de l'ensemble de la chaîne opérationnelle. Elles pilotent les initiatives de transformation stratégique (automatisation des processus, intégration d'outils d'intelligence artificielle, déploiement de KPI de suivi), garantissent la conformité réglementaire, et produisent des analyses destinées au top management. Leur rôle est d'assurer la gouvernance et la standardisation des pratiques au niveau global.
- **Front Office (Origination & Syndication)** : il constitue le point d'entrée commercial et relationnel avec les clients. Le Front Office identifie les besoins de financement, conçoit la structure du crédit, négocie les conditions avec l'emprunteur et organise la syndication, c'est-à-dire la répartition du financement entre les différentes banques participantes. Il est à la fois force de proposition stratégique et interface principale avec le marché.
- **Middle Office (Credit Transaction Management)** : il agit comme *pivot de contrôle et de sécurisation*. Ses missions consistent à vérifier la bonne mise en place des conditions négociées (clauses contractuelles, covenants, pricing), à s'assurer de la qualité des données saisies dans les systèmes et à gérer les exceptions opérationnelles. Le Middle Office se situe entre la relation commerciale (FO) et l'exécution opérationnelle (BO), garantissant l'intégrité et la conformité des transactions.
- **Back Office (Loan Servicing Team)** : il représente le *cœur opérationnel* du dispositif. Responsable de l'exécution quotidienne, il prend

en charge le cycle de vie complet des crédits : décaissements (draw-downs), appels de fonds, paiements d'intérêts et de commissions, remboursements, gestion des échéances, ainsi que la clôture finale du prêt. Il assure également la maintenance des systèmes de gestion (tels que Loan IQ) et la production de reportings réglementaires et financiers.




FIGURE 1 – Chaîne de valeur du crédit syndiqué : organisation verticale et supervision transversale

2.1.2 Organisation de l'équipe Strategic Transformation & Data Analytics

L'équipe Strategic Transformation est composée de chefs de projet et de product owners chargés de piloter la modernisation des opérations de crédit (automatisation, rationalisation des flux).

L'équipe Data Analytics est référente sur la donnée : qualité, nettoyage, analyses statistiques ainsi que création de KPI en destination du high management.




FIGURE 2 – Structure géographique de l’équipe (FR = France, PT = Portugal)

2.1.3 Organisation générale de la banque

Le secteur bancaire se divise en trois grandes catégories d’établissements :

- **Banque de détail** : services courants et prêts pour particuliers et PME.
- **Banque privée** : gestion de patrimoine pour une clientèle fortunée.
- **Banque de financement et d’investissement (CIB)** : financement structuré, marchés de capitaux, couverture des risques.

Ce mémoire se concentre sur la **CIB**, et plus précisément le *crédit syndiqué*, dont le cycle de vie opérationnel est schématisé ci-dessous :

2.2 Typologie des événements opérationnels

Le cycle de vie d’un crédit syndiqué génère un ensemble d’événements opérationnels dont le traitement incombe aux équipes Loan Servicing. Chaque événement correspond à une unité de travail discrète, déclenchée par une instruction du Front Office ou du Middle Office, et exécutée dans le progiciel Loan IQ selon des procédures standardisées. La diversité de ces événements — par leur nature, leur fréquence et leur complexité — constitue le premier déterminant structurel de la charge de travail.

On distingue cinq grandes familles d’événements, ordonnées selon la chro-

Étape	Front Office	Middle Office	Back Office
Origination	Analyse du besoin, structuration	–	–
Structuration	Négociation, syndication	Évaluation des risques	–
Documentation	Coordination juridique	Vérification des clauses	Préparation contrats
Mise en place	Information client	Contrôle final des risques	Versements, confirmations
Vie du deal	Suivi relationnel	Monitoring des covenants	Reporting, échéances

TABLE 1 – Cycle de vie opérationnel d’un crédit syndiqué

nologie du cycle de vie du crédit.




FIGURE 3 – Cycle de vie des événements opérationnels en Loan Servicing. Les flèches pleines représentent le flux nominal ; les flèches en pointillés indiquent les boucles de retour.

Événements de mise en place (*setup*). Ils interviennent lors de l’entrée d’un nouveau deal dans le système. Le *deal setup* comprend la création de la facilité dans Loan IQ, le paramétrage des conditions contractuelles (devise, taux de référence, spreads, calendrier de remboursement, frais) et la vérification de cohérence avec la documentation juridique. Cette étape est à la fois volumineuse en saisie et exigeante en attention, car toute erreur de paramétrage se propage à l’ensemble des opérations ultérieures.

Événements de décaissement et de remboursement. Les tirages (*drawdowns*) et les remboursements (*repayments*) constituent le flux le plus récurrent du Loan Servicing. Un tirage correspond à la mise à disposition effective des fonds au profit de l'emprunteur ; un remboursement, au retour partiel ou total du principal selon l'échéancier contractuel ou par anticipation. La complexité de ces opérations varie considérablement : un tirage en devise unique sur une facilité bilatérale est une opération routinière, là où un tirage sur une tranche syndiquée multidevise implique la coordination de plusieurs participants, le calcul de quotes-parts et la gestion de fuseaux horaires différents.

Événements de vie courante (*servicing*). Ils regroupent l'ensemble des opérations récurrentes liées à la gestion d'un crédit actif : paiements d'intérêts (*interest payments*), appels et paiements de commissions (*commitment fees, agency fees*), *rollovers* (renouvellement d'une période d'intérêt), fixings de taux et ajustements de spread. Ces événements, bien que souvent unitairement simples, représentent le volume le plus important en nombre d'occurrences quotidiennes. Leur charge est essentiellement liée à leur fréquence et à leur concentration calendaire — les fins de mois et fins de trimestre (*quarter-ends*) produisent des pics de volume considérables.

Événements de modification contractuelle. Les amendements (*amendments*), les *waivers* (renonciations temporaires à une clause) et les restructurations modifient les termes initiaux du contrat de crédit. Ces opérations sont les plus complexes du portefeuille : elles nécessitent l'interprétation de clauses juridiques, la mise à jour simultanée de multiples paramètres dans le système et, fréquemment, des itérations avec le Middle Office et le département juridique. Le temps de traitement d'un amendement peut être dix à vingt fois supérieur à celui d'un tirage standard, ce qui rend sa contribution à la charge globale disproportionnée par rapport à sa fréquence.

Événements de clôture. Le remboursement final (*final repayment*) et la clôture du deal (*deal closure*) mettent fin au cycle de vie opérationnel. Ces événements impliquent le solde de l'ensemble des positions, la vérification de l'absence d'encours résiduel, la production de confirmations finales et l'archivage dans le système. Bien que ponctuels, ils requièrent un contrôle exhaustif qui les rend chronophages.

TABLE 2 – Synthèse des familles d'événements opérationnels en Loan Servicing

Famille	Événements types	Fréquence	Complexité	Automatisable
Mise en place	Deal setup, paramétrage facilité	Faible	Élevée	Partiel
Décaissement / Remboursement	Drawdowns, repayments, remb. anticipés	Élevée	Variable	Partiel
Vie courante	Intérêts, commissions, rollovers, fixings	Très élevée	Faible à modérée	Oui
Modifications	Amendements, waivers, restructurations	Faible	Très élevée	Non
Clôture	Final repayment, deal closure	Ponctuelle	Modérée	Partiel
Transversaux	Reprises, corrections, reporting ad hoc	Variable	Variable	Non

À ces cinq familles s'ajoutent des **événements transversaux** qui ne relèvent pas d'une étape spécifique du cycle de vie mais constituent une source significative de charge : les reprises et corrections (*rework*) consécutives à des erreurs de saisie ou à des données amont incomplètes, les demandes *ad hoc* de reporting, et les réconciliations de données entre systèmes. Ces événements sont particulièrement difficiles à anticiper et à standardiser, car ils résultent de dysfonctionnements plutôt que d'un processus nominal.




FIGURE 4 – Répartition estimée de la charge entre traitement manuel, partiellement automatisé et entièrement automatisé (RPA), par famille d'événements. Les modifications contractuelles restent quasi exclusivement manuelles.

L'automatisation modifie le périmètre de cette typologie. Les solutions de RPA déployées au sein de GCO ont permis d'automatiser partiellement certaines opérations à faible valeur ajoutée — extraction de données, pré-remplissage de champs dans Loan IQ, génération de confirmations standardisées. Ces tâches, qui figuraient autrefois dans la charge des opérateurs, sortent progressivement du périmètre du travail humain. En contrepartie, le travail résiduel se concentre sur les événements complexes, les cas d'exception et les contrôles qualitatifs — précisément les opérations dont le temps de traitement est le plus variable et le plus difficile à modéliser. Toute mesure de la charge doit donc intégrer cette distinction entre événements automatisés, partiellement automatisés et manuels, sous peine de surestimer ou sous-estimer la charge réelle supportée par les équipes.

2.3 Définition du concept de charge de travail

La charge de travail est un concept en apparence intuitif — chaque manager sait reconnaître une équipe « débordée » — mais dont la formalisation se heurte à une difficulté fondamentale : elle n’est pas directement observable. Contrairement au volume d’événements traités, qui est un fait enregistré dans les systèmes d’information, ou au nombre d’heures travaillées, qui relève de la gestion administrative, la charge de travail est un *construit* — une grandeur latente qui doit être inférée à partir d’indicateurs observables.

Dans le cadre de ce mémoire, nous définissons la charge de travail comme suit :

La charge de travail est la quantité totale d’effort — temporel et cognitif — requise pour traiter l’ensemble des événements opérationnels assignés à une équipe ou à un opérateur sur une période donnée, dans le respect des standards de qualité et des délais contractuels.

Cette définition appelle plusieurs précisions, articulées autour de quatre propriétés constitutives.

Dimension temporelle. La charge se mesure d’abord en temps de traitement. Chaque événement opérationnel consomme une durée de travail qui dépend de sa nature (tirage, amendement, clôture), de ses caractéristiques intrinsèques (devise, syndication, clauses spécifiques) et des conditions opérationnelles (jour de la semaine, proximité d’un *quarter-end*, disponibilité des systèmes). Le temps de traitement constitue la variable de réponse centrale de notre modèle. Mais le temps brut ne suffit pas : un opérateur peut consacrer trente minutes à un tirage standard parce qu’il est interrompu par des réunions, ou traiter un amendement complexe en quarante-cinq minutes parce qu’il maîtrise parfaitement la procédure. Il faut donc distinguer le *temps effectif de traitement* — le temps réellement consacré à l’exécution de l’opération — du *temps écoulé*, qui inclut les interruptions et les temps d’attente :

$$T_{\text{eff}} = T_{\text{écoulé}} - T_{\text{interruptions}} - T_{\text{attente}} \quad (1)$$

Dimension cognitive. Deux opérations de durée comparable peuvent imposer des niveaux d’exigence mentale radicalement différents. Un *rollover*




FIGURE 5 – Les quatre dimensions constitutives de la charge de travail en opérations de crédit. Le cercle central représente le construit latent W que ce mémoire vise à formaliser.

sur une facilité bilatérale en euros est une opération quasi-mécanique ; un amendement sur un crédit syndiqué à vingt participants, avec modification simultanée du calendrier de remboursement, du spread et des covenants financiers, mobilise la mémoire de travail, le jugement et l’attention soutenue de l’opérateur. Cette dimension, que Wickens (2008) qualifie de charge cognitive, ne peut être captée par le seul chronométrage. Elle se manifeste par un taux d’erreur plus élevé, une fatigue accrue et, à moyen terme, par l’attrition des équipes soumises de manière chronique à des opérations à forte intensité cognitive.

On peut formaliser un *temps standard pondéré* T_s^* intégrant un coefficient de complexité cognitive κ_i pour chaque type d’événement i :

$$T_{s,i}^* = T_{s,i} \times \kappa_i, \quad \kappa_i \geq 1 \quad (2)$$

où $T_{s,i}$ est le temps standard chronométré et κ_i un facteur dérivé des évaluations NASA-TLX ou de la complexité objective du deal (nombre de participants, multidevise, clauses spéciales).

Dimension contextuelle. La charge dépend non seulement du flux d’événements, mais aussi des ressources disponibles pour l’absorber. Une journée de cinquante tirages est gérable pour une équipe de dix opérateurs expérimentés ; elle devient critique si trois opérateurs sont en formation et deux en congé. La charge n’est donc pas une propriété intrinsèque du flux de travail : elle résulte du rapport entre les sollicitations et les capacités de traitement — un ratio que la théorie des files d’attente formalise par l’intensité de trafic :

$$\rho = \frac{\lambda}{c \cdot \mu} \quad (3)$$

où λ est le taux d’arrivée des événements, c le nombre d’opérateurs disponibles et μ le taux de service moyen. Un ratio $\rho > 1$ indique une surcharge structurelle ; un ratio ρ approchant 1 signale un système fonctionnant à la limite de sa capacité, vulnérable au moindre aléa.

Dimension dynamique. La charge fluctue sous l’effet de cycles calendaires (fins de mois, *quarter-ends*, closings annuels), de chocs exogènes (annonces de taux directeurs, restructurations sectorielles) et de la transformation continue des processus par l’automatisation. Une mesure ponctuelle de




FIGURE 6 – Illustration de la relation entre flux d'arrivée des événements $\lambda(t)$ et capacité de traitement $c \cdot \mu$. Les zones ombrées correspondent aux périodes de surcharge ($\rho > 1$), typiquement associées aux *quarter-ends*.

la charge n’a de valeur que si elle s’inscrit dans un dispositif de suivi longitudinal permettant d’en capturer les tendances et la saisonnalité.

Ces quatre propriétés — temporelle, cognitive, contextuelle et dynamique — justifient l’impossibilité de réduire la charge de travail à un indicateur unique et statique. On peut néanmoins exprimer la charge agrégée W d’une équipe sur une période $[t_0, t_1]$ sous la forme :

$$W = \sum_{i=1}^N T_{s,i}^* = \sum_{i=1}^N T_{s,i} \times \kappa_i \quad (4)$$

où N est le nombre d’événements traités sur la période et $T_{s,i}^*$ le temps standard pondéré de l’événement i tel que défini en équation (2). Cette formulation constitue le point de départ du cadre de mesure que les chapitres suivants développeront.

Elles fondent la démarche de ce mémoire, qui vise à construire une mesure composite articulant données de chronométrage, caractéristiques objectives des événements et facteurs contextuels, dans un cadre prédictif capable de rendre compte de la variabilité observée.

3 État de l’art

Ce chapitre recense les travaux fondateurs et contemporains relatifs à la mesure, la formalisation et la modélisation de la charge de travail dans les organisations de services, avec un ancrage particulier dans le secteur des opérations bancaires. L’objectif est double : établir le socle théorique sur lequel repose notre démarche de quantification, et identifier les lacunes que ce mémoire entend combler — à savoir l’absence d’un cadre intégré combinant mesure temporelle, prise en compte de la complexité cognitive et modélisation prédictive, spécifiquement appliqué aux équipes Back Office en opérations de crédit.

3.1 Les méthodes classiques de mesure du travail

3.1.1 L’étude des temps et le management scientifique

La question de la mesure objective du travail trouve son origine dans les travaux de Frederick Winslow Taylor, dont l’ouvrage fondateur *The Prin-*

principles of Scientific Management (1911) pose le postulat selon lequel toute activité productive peut être décomposée en éléments discrets, chronométrables et optimisables. Le protocole tayloriste repose sur un enchaînement méthodique : définition de la méthode standard, décomposition de la tâche en éléments de travail, chronométrage par observation directe, évaluation de l’allure de l’opérateur par rapport à une performance de référence, et enfin application de majorations (fatigue, besoins personnels, aléas machines) pour calculer un *temps standard* [10].

Le temps standard T_s se formalise selon l’équation suivante :

$$T_s = T_n \times (1 + A) \quad (5)$$

où T_n représente le temps normal (temps observé ajusté par le facteur d’allure) et A le coefficient de majorations exprimé en pourcentage. Le temps normal est lui-même dérivé du temps observé T_o et du facteur d’allure F_a :

$$T_n = T_o \times F_a \quad (6)$$

Si cette approche a été initialement conçue pour le travail manufacturier, son applicabilité aux activités de services a été démontrée dès les années 2000. Ben-Gal *et al.* (2010) confirment que les études de temps conservent leur validité dans les organisations de services, à condition d’adapter la granularité de décomposition aux spécificités des tâches cognitives et informatisées [12]. Dans le contexte des opérations bancaires, chaque événement de la vie d’un crédit — qu’il s’agisse d’un tirage (*drawdown*), d’un remboursement (*repayment*) ou d’un amendement contractuel — constitue une unité de travail susceptible d’être chronométrée et standardisée.

Toutefois, l’approche tayloriste a fait l’objet de critiques substantielles. Nyland (1996) souligne que les études de temps reposent sur l’interprétation individuelle de l’analyste quant à ce que fait réellement le travailleur, introduisant une subjectivité que Taylor lui-même n’a jamais pleinement résolue [6]. Par ailleurs, la vision instrumentale du comportement humain — réduisant le travailleur à un exécutant dont il faut maximiser la productivité — a conduit au développement d’approches complémentaires intégrant les facteurs humains.




FIGURE 7 – Protocole de l'étude des temps selon Taylor (1911), adapté de Groover (2007).

Limites dans le contexte des opérations de crédit. L'application du chronométrage tayloriste aux équipes Loan Servicing de GCO se heurte à trois difficultés structurelles que la littérature ne traite pas explicitement. Premièrement, le travail des opérateurs est intrinsèquement fragmenté : un même opérateur peut gérer simultanément plusieurs deals à des stades différents, être interrompu par des requêtes ad hoc du Middle Office ou par des dysfonctionnements systèmes, ce qui rend la délimitation du *temps effectif* de traitement (T_{eff}) bien plus ambiguë que dans un environnement manufacturier. Deuxièmement, la notion de « méthode standard » suppose que le processus soit stabilisé ; or, dans un contexte de déploiement continu de solutions RPA et de refonte des workflows Loan IQ, la méthode d'exécution d'un même événement évolue d'un trimestre à l'autre. Toute mesure chronométrique risque donc d'être rapidement obsolète si elle n'est pas intégrée dans un dispositif de mise à jour continue. Troisièmement, le facteur d'allure (F_a), qui repose sur le jugement d'un analyste observant l'opérateur, est difficilement praticable dans une organisation nearshore répartie entre Paris et Lisbonne : l'observation directe est rarement possible, et l'auto-déclaration introduit des

biais de désirabilité sociale. Ces limites ne remettent pas en cause le principe du chronométrage — qui reste le fondement de toute mesure temporelle — mais imposent de repenser son protocole d’implémentation pour l’adapter à un environnement de services informatisés, distribué et en transformation permanente.

3.1.2 L’étude des mouvements et les systèmes de temps prédéterminés

En complément des travaux de Taylor, Frank et Lillian Gilbreth développent une approche centrée non plus sur la durée, mais sur la nature des gestes effectués. Leur décomposition en « therbligs » — unités élémentaires de mouvement — introduit un principe fondamental : le temps requis pour accomplir une tâche est fonction directe de la méthode employée [2]. Cette contribution constitue le fondement conceptuel du *Methods-Time Measurement* (MTM).

Le MTM, formalisé par Maynard, Schwab et Stegemerten (1948), représente l’aboutissement de cette logique. Il s’agit d’un système de temps prédéterminés (*Predetermined Motion Time System* — PMTS) qui attribue des valeurs temporelles normalisées à chaque mouvement élémentaire, permettant d’estimer le temps standard d’une opération *a priori*, sans recourir au chronométrage [3]. L’Association MTM décrit cette approche comme un « langage de processus » utilisé comme standard mondial pour la conception du travail humain.

La transposition du MTM aux environnements de services informatisés soulève cependant des difficultés méthodologiques. La notion de « mouvement élémentaire » doit être redéfinie pour intégrer des actions numériques : ouverture d’une transaction dans un progiciel, navigation entre écrans, saisie de données, vérification de conformité. Si le principe demeure valide — décomposer pour standardiser —, les tables de temps MTM classiques ne sont pas directement applicables. Il s’agit alors de construire des référentiels de temps spécifiques au contexte opérationnel étudié, ce que notre démarche de « clocking » vise précisément à accomplir.

TABLE 3 – Comparaison des méthodes classiques de mesure du travail

Critère	Étude des temps (Taylor)	Étude des mou- vements (Gilbreth)	MTM (Maynard)
Principe	Chronométrage direct des tâches	Analyse cinématique des gestes	Temps prédéterminés par mouvement
Données requises	Observations terrain	Enregistrements vidéo	Décomposition méthodologique
Type de mesure	<i>A posteriori</i>	<i>A posteriori</i>	<i>A priori</i>
Subjectivité	Élevée (facteur d'allure)	Modérée	Faible
Applicabilité services	Démontrée (Ben-Gal, 2010)	Limitée (gestes physiques)	À adapter (actions numériques)
Limite principale	Dépendance à l'observateur	Coût de mise en œuvre	Tables non transposables

Limites dans le contexte des opérations de crédit. La transposition du MTM aux opérations de crédit rencontre un obstacle fondamental : les « mouvements élémentaires » du travail informatisé ne sont pas des gestes physiques standardisables, mais des séquences d'actions cognitives et numériques — navigation entre écrans Loan IQ, interprétation de clauses contractuelles, arbitrage entre instructions contradictoires du Front Office. Le temps de ces actions dépend moins de la mécanique gestuelle que du contenu informationnel du deal : un tirage bilatéral en euros et un tirage syndiqué multi-devises à vingt participants mobilisent les mêmes écrans mais des niveaux de réflexion radicalement différents. Aucune table de temps prédéterminés ne peut capturer cette variabilité. Le principe de décomposition reste pertinent, mais le référentiel de temps doit être reconstruit empiriquement à partir de données opérationnelles réelles, et non dérivé d'un catalogue générique de mouvements.

3.2 La charge de travail : un construit multidimensionnel

3.2.1 Dimensions objectives et subjectives de la charge

La charge de travail ne se réduit pas à une mesure temporelle. La littérature en ergonomie et en psychologie du travail distingue trois catégories de mesures : les mesures de performance (output réalisé, taux d’erreur, temps de cycle), les mesures physiologiques (fréquence cardiaque, activité électrodermale) et les mesures subjectives (évaluation déclarative par l’opérateur). Wickens (2008) formalise cette distinction en montrant que la charge objective — le volume et la complexité des sollicitations imposées à l’opérateur — ne coïncide pas nécessairement avec la charge subjective — l’effort perçu pour y répondre [11].

Cette distinction est fondamentale dans le contexte des opérations de crédit. Deux événements peuvent requérir un temps de traitement comparable dans Loan IQ tout en générant des niveaux de charge cognitive radicalement différents : un tirage standard sur une facilité bilatérale en euros constitue une opération routinière, tandis qu’un amendement sur un crédit syndiqué multidevise implique une mobilisation attentionnelle bien supérieure. Toute mesure de la charge qui ignorerait cette dimension qualitative serait incomplète.




FIGURE 8 – Taxonomie des mesures de la charge de travail, adaptée de Wickens (2008).

3.2.2 Le NASA Task Load Index (NASA-TLX)

Développé par Sandra Hart au NASA Ames Research Center dans les années 1980, le NASA Task Load Index (NASA-TLX) s’est imposé comme l’instrument de référence mondiale pour l’évaluation subjective de la charge de travail. Il repose sur une procédure d’évaluation multidimensionnelle qui dérive un score global à partir de la moyenne pondérée de six sous-échelles : exigence mentale, exigence physique, exigence temporelle, performance perçue, effort et frustration [5].

Le score global pondéré W du NASA-TLX se calcule selon :

$$W = \frac{\sum_{i=1}^6 w_i \cdot s_i}{\sum_{i=1}^6 w_i} \quad (7)$$

où s_i est le score brut (0–100) de la sous-échelle i et w_i son poids déterminé par comparaison par paires. L’instrument a été validé dans une grande diversité d’environnements : cockpits d’aéronefs, postes de commandement, contrôle de processus industriels, et plus récemment dans les environnements de travail tertiaires.

Sa force réside dans sa capacité à capturer des dimensions que le chronométrage ne saisit pas : la pression temporelle liée aux *deadlines* de settlement, la charge cognitive induite par la vérification de données complexes, ou la frustration générée par des systèmes d’information inadaptés.

Dans le cadre de notre recherche, le NASA-TLX constitue un outil complémentaire à la mesure temporelle. Il permettrait de pondérer les temps standards par un coefficient de complexité perçue, transformant une mesure purement chronométrique en un indicateur composite intégrant la dimension cognitive du travail. Néanmoins, comme toute mesure déclarative, il est sujet aux biais de désirabilité sociale et à la variabilité interindividuelle, ce qui impose de le croiser systématiquement avec des données objectives.

TABLE 4 – Les six sous-échelles du NASA-TLX et leur pertinence pour le Back Office bancaire

Sous-échelle	Définition	Application Back Office
Exigence mentale	Activité mentale requise (réflexion, décision, calcul)	Vérification de clauses, deals complexes
Exigence physique	Activité physique requise	Faible (travail informatisé)
Exigence temporelle	Pression liée au rythme imposé	Deadlines de settlement, quarter-ends
Performance	Auto-évaluation du niveau de réussite	Taux d'erreur perçu, satisfaction
Effort	Intensité de travail pour atteindre le niveau de performance	Effort de concentration soutenu
Frustration	Stress, découragement, irritation	Systèmes lents, erreurs données amont

Limites dans le contexte des opérations de crédit. Le déploiement du NASA-TLX dans un Back Office bancaire nearshore soulève des contraintes pratiques rarement discutées dans la littérature. D'une part, les équipes Loan Servicing de GCO sont réparties entre la France et le Portugal, avec des profils d'ancienneté, de formation et de culture professionnelle hétérogènes : la « charge perçue » d'un amendement complexe ne sera pas évaluée de la même manière par un opérateur senior parisien et par un analyste junior lisboète récemment formé. Le biais interculturel et le biais d'expérience risquent de compromettre la comparabilité des scores. D'autre part, le NASA-TLX a été conçu pour évaluer des tâches discrètes et bornées dans le temps (une mission de vol, une session de contrôle) ; or, le travail de Loan Servicing est un flux continu d'événements entrelacés, ce qui rend difficile l'association d'un score de charge à un événement isolé.

Ces limites orientent le positionnement méthodologique de ce mémoire : plutôt que de déployer le NASA-TLX comme instrument principal de mesure,

nous le concevons comme un outil de calibration ponctuel, susceptible de valider ou de pondérer les temps standards chronométrés par un coefficient de complexité cognitive (κ_i), sans en faire le socle du dispositif de mesure.

3.3 L'adaptation des indicateurs industriels aux services : le cas de l'OEE

3.3.1 Principes et structure de l'OEE

L'*Overall Equipment Effectiveness* (OEE), issu du modèle TPM (*Total Productive Maintenance*) formalisé par Nakajima (1988), décompose la performance productive en trois facteurs multiplicatifs [4] :

$$\text{OEE} = \underbrace{\frac{T_{\text{fonct.}}}{T_{\text{planifié}}}}_{\text{Disponibilité}} \times \underbrace{\frac{Q_{\text{réelle}}}{Q_{\text{théorique}}}}_{\text{Performance}} \times \underbrace{\frac{Q_{\text{conforme}}}{Q_{\text{totale}}}}_{\text{Qualité}} \quad (8)$$

Un OEE de 100 % signifie que l'équipement ne produit que des pièces conformes, à sa cadence nominale, sans aucun temps d'arrêt. Cet indicateur est aujourd'hui considéré comme le standard de mesure de la productivité manufacturière.

L'intérêt de l'OEE pour notre problématique réside dans sa structure analytique : en décomposant la performance en trois dimensions orthogonales, il permet d'identifier précisément l'origine des pertes de productivité. Appliqué à un poste de travail Back Office, le cadre se transpose de la manière suivante :

- **Disponibilité** : ratio entre le temps effectivement consacré au traitement des événements et le temps planifié de travail, déduction faite des réunions, formations, pauses et interruptions non productives.
- **Performance** : cadence réelle de traitement comparée à une cadence théorique dérivée des temps standards.
- **Qualité** : proportion d'événements traités sans reprise ni correction ultérieure (*first-time-right*).

3.3.2 Limites de transposition et adaptations nécessaires

La littérature récente souligne les limites de l'OEE dans les environnements à forte variabilité. Dans les processus multiproduits ou semi-artisanaux, la définition d'une cadence idéale unique est souvent irréaliste.

Cette observation est directement pertinente pour les opérations de crédit, où chaque deal présente des caractéristiques contractuelles propres (devise, syndication, clauses spécifiques) qui rendent la notion de cadence nominale problématique.

Deux adaptations sont proposées par la littérature pour surmonter cette difficulté. La première consiste à définir des standards par famille d’opérations homogènes plutôt qu’un standard global — approche que nous retenons dans notre méthodologie en distinguant des catégories d’événements (tirages simples, tirages complexes, amendements, remboursements anticipés, etc.). La seconde, plus radicale, propose de se concentrer sur les seules dimensions de disponibilité et de performance, en utilisant des ratios de productivité relatifs plutôt qu’absolus.

3.4 Approches de modélisation prédictive

3.4.1 Modèles statistiques classiques

La modélisation de la charge de travail par des approches statistiques vise à établir une relation fonctionnelle entre des variables explicatives observables et une variable de réponse. La régression linéaire multiple constitue le modèle de base :

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p + \varepsilon \quad (9)$$

où Y est le temps de traitement, X_j les variables explicatives (type d’événement, caractéristiques du deal, contexte temporel), β_j les coefficients de régression et ε le terme d’erreur. Les coefficients β_j indiquent directement la contribution marginale de chaque facteur à la charge totale, ce qui rend le modèle particulièrement adapté aux fins de communication managériale.

La régression logistique, quant à elle, modélise la probabilité de dépassement d’un seuil critique de charge :

$$P(Y = 1 \mid \mathbf{X}) = \frac{1}{1 + e^{-(\beta_0 + \beta^T \mathbf{X})}} \quad (10)$$

Shaik *et al.* (2025) démontrent l’efficacité de cette approche dans un contexte RH, obtenant une *accuracy* de 83,7 % pour la prédiction du *turnover*, un phénomène structurellement lié à la surcharge chronique [18].

Néanmoins, ces modèles linéaires reposent sur des hypothèses de linéarité et d’indépendance des résidus qui peuvent s’avérer restrictives. Dans les

opérations bancaires, les interactions entre facteurs de complexité (un deal syndiqué *et* multidevise *et* avec des clauses spéciales génère une charge supérieure à la somme des effets individuels) limitent le pouvoir explicatif des modèles additifs.

3.4.2 Méthodes d'apprentissage automatique

Les arbres de décision constituent une alternative non paramétrique qui capture naturellement les effets d'interaction et les non-linéarités. Leur principe — partitionner récursivement l'espace des *features* selon les seuils maximisant la réduction d'impureté de Gini — produit des règles interprétables directement actionnables.

Le *Random Forest*, agrégation de B arbres entraînés sur des sous-échantillons aléatoires, résout le problème d'instabilité des arbres individuels. La prédiction finale est obtenue par vote majoritaire (classification) ou moyenne (régression) :

$$\hat{f}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B T_b(\mathbf{x}) \quad (11)$$

où T_b est la prédiction du b -ième arbre. L'importance de chaque variable j est quantifiée par la réduction cumulée d'impureté de Gini :

$$\text{Importance}(j) = \sum_{b=1}^B \sum_{t \in T_b} \Delta G(j, t) \quad (12)$$

TABLE 5 – Performance comparée des modèles prédictifs sur données RH, d'après Shaik *et al.* (2025)

Modèle	Accuracy	Précision	Rappel	F1-Score	AUC
Régression logistique	83,7 %	78,2 %	72,5 %	75,2 %	0,81
Random Forest	88,6 %	84,7 %	80,4 %	82,5 %	0,89
SVM (noyau RBF)	85,1 %	80,3 %	76,0 %	78,1 %	0,84

Les *Support Vector Machines* (SVM), avec un noyau à base radiale (RBF), offrent une troisième voie en cherchant l'hyperplan optimal de séparation dans un espace de dimension supérieure. Le noyau RBF est défini par :

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2) \quad (13)$$

La littérature recommande une approche duale : scorer avec un modèle complexe et expliquer les prédictions avec des méthodes d’interprétabilité *post-hoc*, notamment les valeurs SHAP (*SHapley Additive exPlanations*), qui décomposent chaque prédiction en contributions individuelles des *features* [15] :

$$\phi_j = \sum_{S \subseteq N \setminus \{j\}} \frac{|S|! (|N| - |S| - 1)!}{|N|!} [f(S \cup \{j\}) - f(S)] \quad (14)$$

3.5 Process Mining et excellence opérationnelle en milieu bancaire

3.5.1 Le Process Mining comme outil de diagnostic de la charge

Le *Process Mining*, formalisé par Van der Aalst (2016), constitue une approche *data-driven* qui reconstruit les flux opérationnels réels à partir des logs d’événements des systèmes d’information [14]. Contrairement aux méthodes traditionnelles d’amélioration des processus — qui reposent sur des ateliers, des entretiens et des cartographies déclaratives —, le *Process Mining* analyse des milliers, voire des millions, de transactions réelles pour révéler comment le travail circule effectivement entre les systèmes et les acteurs.

Dans le secteur financier, cette approche a démontré sa capacité à identifier des inefficiences invisibles aux méthodes conventionnelles : reprises cachées, approbations redondantes, boucles de processus et temps d’attente disproportionnés entre étapes. Jans *et al.* (2013) documentent l’analyse multifacette des processus métier en organisation financière, confirmant la valeur ajoutée du *Process Mining* pour la détection d’anomalies processuelles [13].

Pour notre problématique, le *Process Mining* offre un double apport. D’une part, il permet de cartographier objectivement le parcours réel d’un deal dans Loan IQ — de l’origination au settlement — et d’identifier les étapes génératrices de charge disproportionnée. D’autre part, en structurant les données en triplets (case_id, activité, timestamp), il fournit la matière première nécessaire à l’alimentation des modèles prédictifs décrits dans la section précédente.




FIGURE 9 – Flux simplifié du traitement d’un deal en opérations de crédit, tel que reconstruit par *Process Mining*. Les boucles de reprise constituent des sources cachées de charge additionnelle.

3.5.2 Le Lean Management appliqué aux opérations de BFI

Le Lean Management, initialement développé dans l’industrie automobile par Toyota, a fait l’objet d’une adoption massive dans les opérations bancaires à partir du début des années 2000. Angelichev (2024), consultant chez Capco, dresse un bilan actualisé de cette adoption en Banque de Financement et d’Investissement (BFI) et conclut que « le Lean Management est toujours autant d’actualité qu’il y a 20 ans », ses champs d’application s’étant élargis bien au-delà du *cost-cutting* originel [16].

Quatre apports du Lean sont particulièrement pertinents pour notre recherche. Premièrement, le *Value Stream Mapping* fournit un cadre de cartographie des flux de valeur qui complète utilement le *Process Mining* par une lecture orientée « gaspillages » (*muda*). Deuxièmement, la standardisation des processus — principe fondamental du Lean — est un prérequis à toute mesure fiable de la charge : on ne peut chronométrer une opération que si sa méthode d’exécution est stabilisée. Troisièmement, le cadrage des besoins d’automatisation (RPA, macros VBA) est indissociable de la mesure de la charge, puisqu’il vise à réduire les tâches à faible valeur ajoutée qui gonflent artificiellement les temps de traitement. Quatrièmement, l’intégration du pilotage par KPI dans les rituels managériaux (réunions quotidiennes, tableaux visuels) constitue le véhicule opérationnel par lequel la mesure de charge se transforme en outil de pilotage.

Operae Partners documente par ailleurs la transformation Lean du Back Office de BNL (filiale italienne de BNP Paribas) comme cas de référence sec-

toriel, démontrant que les gains d'efficacité obtenus dans un environnement d'opérations de crédit sont substantiels et durables lorsque la démarche est déployée de manière structurée.

3.6 Planification des effectifs et aide à la décision

3.6.1 Modèles de Recherche Opérationnelle

La finalité ultime de la mesure de la charge de travail est de servir l'aide à la décision en matière d'allocation des ressources. La Recherche Opérationnelle offre un arsenal de modèles mathématiques conçus à cet effet [8].

La théorie des files d'attente est particulièrement adaptée à notre contexte. Elle modélise le Back Office comme un système de serveurs (les opérateurs) traitant des requêtes (les événements opérationnels) dont le taux d'arrivée λ suit une loi de Poisson et le temps de service μ une loi exponentielle. Le modèle d'Erlang C donne la probabilité qu'un événement doive attendre :

$$P_w = \frac{\frac{(c\rho)^c}{c!} \cdot \frac{1}{1-\rho}}{\sum_{k=0}^{c-1} \frac{(c\rho)^k}{k!} + \frac{(c\rho)^c}{c!} \cdot \frac{1}{1-\rho}} \quad (15)$$

où c est le nombre d'opérateurs et $\rho = \lambda/(c\mu)$ l'intensité de trafic. Ce modèle permet de répondre à la question : « combien d'opérateurs faut-il pour absorber un flux prévu de X événements par jour avec un temps de traitement moyen de Y minutes et un délai maximal acceptable de Z heures ? »

La programmation linéaire optimise l'affectation des ressources sous contraintes multiples : polyvalence des opérateurs, horaires de travail, montée en compétence progressive des nouveaux arrivants.

3.6.2 Approches prédictives et anticipation des pics

Au-delà du dimensionnement statique, l'anticipation dynamique des pics de charge constitue un enjeu opérationnel majeur. Les opérations de crédit sont soumises à une saisonnalité prononcée : les fins de trimestre (*quarter-ends*) et les fins d'exercice fiscal génèrent des concentrations d'événements — *closings*, remboursements massifs, ajustements de taux — qui peuvent tripler la charge quotidienne.

L'analyse de séries temporelles (modèles ARIMA, Prophet de Meta) permet de capturer ces composantes cycliques et d'en extraire des prévisions à

horizon de deux à quatre semaines, délai compatible avec un redéploiement interne des ressources. L’enrichissement de ces modèles par des variables exogènes — nombre de deals en pipeline commercial, annonces de taux directeurs, calendrier réglementaire — ajoute un pouvoir prédictif sur les chocs non récurrents. Madanchian *et al.* (2024) confirment que la combinaison de *features* temporelles et contextuelles améliore significativement la capacité prédictive des modèles de *workforce planning* [17].

3.7 Synthèse critique et positionnement de la recherche

3.7.1 Cartographie du champ et identification du *gap*

L’examen de la littérature fait apparaître que la mesure de la charge de travail en Back Office bancaire se situe à la confluence de quatre champs disciplinaires distincts, chacun apportant une perspective complémentaire mais aucun ne fournissant à lui seul un cadre complet (figure 10).




FIGURE 10 – Cartographie des quatre champs disciplinaires contribuant à la mesure de la charge de travail en Back Office bancaire. Le cercle central représente le cadre intégré que ce mémoire vise à construire.

Le **génie industriel** (Taylor, Gilbreth, MTM) fournit les protocoles de chronométrage et la logique de décomposition en temps standards, mais ne prend pas en compte la dimension cognitive du travail de service. L'**ergonomie cognitive** (NASA-TLX, modèles de ressources attentionnelles de Wickens) intègre la complexité perçue et les facteurs humains, mais ne produit pas de mesures directement exploitables pour le dimensionnement des effectifs. La **science des données** (régression, Random Forest, Process Mining) permet la modélisation prédictive et l'extraction de *patterns*, mais requiert en amont une formalisation rigoureuse des données d'entrée — formalisation que la littérature ne documente pas spécifiquement pour les opérations de crédit. La **Recherche Opérationnelle** (files d'attente, simulation, optimisation) transforme la mesure en outil décisionnel, mais suppose que cette mesure existe déjà de manière fiable et structurée.

Le *gap* identifié est le suivant : il n'existe pas, dans la littérature académique ou professionnelle consultée, de cadre intégré qui combine (1) un protocole de mesure temporelle adapté aux opérations de crédit informatisées, (2) une prise en compte structurée des facteurs de complexité, (3) une modélisation prédictive alimentée par des données opérationnelles réelles, et (4) une traduction en recommandations d'allocation des ressources.

3.7.2 Contribution attendue

Notre recherche se positionne comme une contribution appliquée à l'intersection de ces quatre champs. Elle vise à démontrer qu'il est possible de formaliser la charge de travail des équipes Loan Servicing en une mesure quantitative composite — intégrant le temps de traitement chronométré, les facteurs de complexité objectifs (caractéristiques du deal) et la variabilité contextuelle (jour, période, opérateur) — et de l'exploiter via un modèle prédictif pour alimenter l'aide à la décision stratégique en matière d'allocation des ressources et d'anticipation des pics d'activité.

La démarche s'inscrit dans une logique de *design science* [9] : elle produit un artefact — le modèle de mesure et son exploitation analytique — dont la validité est évaluée par sa capacité à résoudre un problème organisationnel concret, dans un contexte opérationnel réel.

Références

- [1] Taylor, F.W. (1911). *The Principles of Scientific Management*. New York : Harper & Brothers.
- [2] Gilbreth, F.B. & Gilbreth, L.M. (1917). *Applied Motion Study*. New York : Sturgis & Walton.
- [3] Maynard, H.B., Stegemerten, G.J. & Schwab, J.L. (1948). *Methods-Time Measurement*. New York : McGraw-Hill.
- [4] Nakajima, S. (1988). *Introduction to TPM : Total Productive Maintenance*. Cambridge : Productivity Press.
- [5] Hart, S.G. & Staveland, L.E. (1988). Development of NASA-TLX : Results of empirical and theoretical research. *Advances in Psychology*, 52, 139–183.

- [6] Nyland, C. (1996). Taylorism, John R. Commons, and the Hoxie Report. *Journal of Economic Issues*, 30(4), 985–1016.
- [7] Zandin, K.B. (2001). *Maynard's Industrial Engineering Handbook*. 5e éd. New York : McGraw-Hill.
- [8] DTIC (2004). A Review of Operations Research Applications in Workforce Planning. *Defense Technical Information Center*, Report ADA432084.
- [9] Hevner, A.R., March, S.T., Park, J. & Ram, S. (2004). Design science in information systems research. *MIS Quarterly*, 28(1), 75–105.
- [10] Groover, M.P. (2007). *Work Systems and the Methods, Measurement, and Management of Work*. Upper Saddle River : Pearson Prentice Hall.
- [11] Wickens, C.D. (2008). Multiple resources and mental workload. *Human Factors*, 50(3), 449–455.
- [12] Ben-Gal, I., Herer, Y. & Raz, T. (2010). Applying time and motion study principles in service organizations. *Industrial Engineering & Management*.
- [13] Jans, M., Alles, M. & Vasarhelyi, M. (2013). Process mining for the multi-faceted analysis of business processes in a financial services organization. *Expert Systems with Applications*, 40(8), 3085–3093.
- [14] Van der Aalst, W.M.P. (2016). *Process Mining : Data Science in Action*. Berlin : Springer.
- [15] Lundberg, S.M. & Lee, S.I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30.
- [16] Angelichev, G. (2024). Le Lean Management dans les services Opérations des BFI : idées reçues, besoins et solutions. *Capco Intelligence*.
- [17] Madanchian, M. *et al.* (2024). Predictive factors of employee turnover intention : A systematic literature review. *Sustainability*, 16(4).
- [18] Shaik, D.K. *et al.* (2025). Predictive modeling for HR decision-making : A study of employee turnover. *Journal of Marketing & Social Research*, 2(4), 92–98.

4 Conclusion

Bibliography

- [1] Brian W. Kernighan and Dennis M. Ritchie. 1988. The C Programming Language (2nd. ed.). Prentice Hall Professional Technical Reference.
- [2] Olivier Cailloux. Elicitation indirecte de modèles de tri multicritère. Autre. Ecole Centrale Paris, 2012. Français. ⟨NNT : 2012ECAP0043⟩. ⟨tel-00773683v2⟩