



Thèse universitaire présentée à l'Université Paris Dauphine dans
le cadre de l'obtention du diplôme de **Master 2 MIAGE**

Modélisation du temps de travail des équipes Back Office de BNP Paribas

David ROUFÉ

Entreprise: BNP PARIBAS

Tutrice d'alternance : NEGRE Elsa

Tuteur en entreprise : RAHMANI Abdelaziz

Septembre, 2026

Table des matières

Thanks	v
1 Introduction	1
2 Contexte	6
2.1 Contexte organisationnel	6
2.1.1 Organisation du département GCO (Global Credit Operations)	6
2.1.2 Organisation de l'équipe Strategic Transformation & Data Analytics	7
2.1.3 Organisation générale de la banque	8
2.2 Typologie des événements opérationnels	9
2.3 Définition du concept de charge de travail	13
3 État de l'art	17
3.1 Du coût des activités au coût par événement : ABC et TDABC	18
3.1.1 Le principe de l'Activity-Based Costing	18
3.1.2 Le Time-Driven ABC : deux paramètres, une équation	19
3.2 Mesurer le temps par événement	20
3.2.1 L'étude des temps (Taylor) : chronométrer et normaliser	20
3.2.2 Le MTM : des temps prédéterminés, mais pour des gestes	22
3.2.3 Le Process Mining : lire le temps dans les traces système	23
3.3 Prédire le coût d'un deal futur : méthodes de modélisation . .	24
3.3.1 La régression linéaire multiple : le modèle de référence	24
3.3.2 Les arbres de décision (CART) : capturer les interactions	25
3.3.3 Random Forest et gradient boosting : agréger pour fiabiliser	26
3.4 Les solutions professionnelles : ce que le marché résout, ce qu'il laisse ouvert	27
3.5 Synthèse : un gap resserré sur l'intrant temps du TDABC . . .	28
4 Formalisation et construction d'une mesure empirique de la charge de travail	29
4.1 Premier arbitrage : l'événement comme unité, contre l'équipe et le deal	30

4.2	Deuxième arbitrage : deux objets, non un — Event Processing et Aftercare	31
4.3	Troisième arbitrage : écarter la séniorité comme correction de vitesse	32
4.4	Quatrième arbitrage : mesurer un travail dont la mesure menace ceux qui l'exécutent	33
4.5	Cinquième arbitrage : raccorder le temps standard à la volumétrie réelle	34
4.6	Synthèse : une mesure empirique robuste et industrialisable . .	34
5	Modélisation prédictive du coût opérationnel	35
5.1	Reconstruire le coût rétrospectif d'un deal	35
5.2	Identifier les facteurs explicatifs de la charge	37
5.3	Construire un modèle prédictif du coût	38
5.3.1	Modéliser le volume d'événements : Random Forest et XGBoost	38
5.3.2	Modéliser l'Aftercare : régression pour l'interprétabilité	39
5.3.3	Recomposer le coût prédit	39
5.4	Pilotage opérationnel et usages décisionnels	40
5.5	Limites et prolongements	40
6	Conclusion	41
	Bibliography	41

Table des figures

1	Chaîne de valeur du crédit syndiqué : organisation verticale et supervision transversale	7
2	Structure hiérarchique de l'équipe (FR = France, PT = Portugal)	8
3	Cycle de vie des événements opérationnels en Loan Servicing. Les flèches pleines représentent le flux nominal ; les flèches en pointillés indiquent les boucles de retour.	10
4	Répartition de la charge entre traitement manuel, partiellement automatisé et entièrement automatisé (RPA), par famille d'événements ; estimation issue d'entretiens avec les équipes Loan Servicing de GCO. Les modifications contractuelles restent quasi exclusivement manuelles.	13
5	Chaîne de mesure, de la charge unitaire au coût du deal. La charge unitaire T_s agrège le <i>booking</i> Loan IQ (stable, ~ 20 min) et l' <i>aftercare</i> (variable selon la complexité). Multipliée par le volume d'événements N de la période, elle donne la charge totale W_N ; valorisée au coût horaire chargé w_s , différencié par site, elle donne le coût opérationnel du deal. Seul le volume N porte la variabilité saisonnière ; la charge unitaire reste stable.	16
6	Protocole de l'étude des temps (Taylor, 1911). Les étapes 2 et 3 — observation directe et jugement d'allure — sont celles qui résistent le moins à un back office distribué.	22
7	Décomposition du traitement d'un événement : Event Processing constant et Aftercare transversal	32
8	Impact de la complexité structurale sur le coût opérationnel et la charge Back Office	36
9	Architecture à deux étages du modèle prédictif du coût par deal	38

Liste des tableaux

1	Cycle de vie opérationnel d'un crédit syndiqué	9
2	Synthèse des familles d'événements opérationnels en Loan Servicing	11

Remerciements

Je remercie ...

1 Introduction

Contexte général

Le secteur bancaire traverse depuis deux décennies une transformation profonde de ses fonctions opérationnelles. La pression réglementaire croissante (Bâle III), l'intensification concurrentielle et l'accélération des capacités de l'intelligence artificielle ont conduit les banques de financement et d'investissement (BFI) à repenser l'organisation de leurs activités de Back Office. Cette transformation répond à un impératif économique central : réduire le *cost to serve*, c'est-à-dire le coût unitaire de traitement des processus opérationnels. Chez BNP Paribas, cet impératif a été formalisé à travers des plans stratégiques successifs. Le plan *GTS2025* (*Growth, Technology, Sustainability*), lancé en 2022, a placé la technologie et l'industrialisation au cœur du modèle opérationnel, avec un objectif explicite de génération de *hard savings* — le Groupe visant alors 2,7 milliards d'euros d'économies à horizon 2025. Au sein de CIB, cette ambition s'est déclinée à travers le programme *GB Indus* (*Global Banking Modernisation & Industrialisation*), visant à industrialiser les processus opérationnels d'un métier présent dans une cinquantaine de pays. La trajectoire se prolonge et se mesure à l'aune du *coefficient d'exploitation* — le rapport entre les charges d'exploitation et le produit net bancaire (PNB), qui exprime la part des revenus absorbée par les coûts de fonctionnement : plus il est bas, plus la banque est efficiente. Lors de la publication des résultats du deuxième trimestre 2026, le Groupe a fixé l'objectif d'un coefficient d'exploitation inférieur à 56 % d'ici 2028 — avec une amélioration d'environ deux points par an à partir de 2027, portée par un programme structurel de réduction des coûts, une simplification de l'organisation et une intensification de l'usage de l'intelligence artificielle — et vise à terme un ratio proche de 50 %. Depuis 2020, cette dynamique s'est encore accélérée sous l'effet de forces convergentes qui redessinent le paysage des opérations bancaires.

La première est la généralisation du *nearshoring* et de l'*offshoring* des fonctions opérationnelles. Confrontées à une pression constante sur les coûts, les BFI ont massivement délocalisé une partie de leurs activités de traitement vers des centres de services partagés situés à Lisbonne, Varsovie, Mumbai ou Montréal — des localisations où les coûts salariaux et immobiliers demeurent inférieurs de 30 à 50 % aux *benchmarks* des places de Londres

ou Paris. Ce mouvement a fragmenté les chaînes de traitement, multiplié les fuseaux horaires et les *handovers* (passations) entre équipes, et complexifié considérablement le pilotage de la charge de travail. Là où un manager supervisait autrefois une équipe co-localisée de dix opérateurs, il doit désormais coordonner des ressources réparties sur plusieurs sites, avec des niveaux de compétence, d'ancienneté et de productivité hétérogènes.

La deuxième force est l'irruption de l'intelligence artificielle et de l'automatisation dans les processus opérationnels. Le déploiement de solutions de *Robotic Process Automation* (RPA) a permis d'automatiser les tâches les plus répétitives — extractions de données, contrôles de cohérence, alimentation de systèmes. Plus récemment, l'émergence de l'IA générative ouvre des perspectives de transformation plus profondes : rédaction automatisée de *facility letters*, extraction intelligente de clauses contractuelles, assistance à la prise de décision sur les cas complexes ou encore bases de données RAG subsistant les experts métier... Ces technologies ne suppriment pas la charge de travail humaine ; elles en modifient la nature. Les tâches routinières se réduisent, tandis que le travail résiduel se concentre sur les opérations à forte valeur ajoutée — précisément celles qui sont les plus complexes, les plus variables et les plus difficiles à mesurer. Ce mouvement est massif : à l'échelle du secteur, près de 83 % des acteurs des services financiers devraient avoir adopté des technologies d'intelligence artificielle dans les cinq ans.

C'est dans cet environnement en mutation rapide que se positionne notre recherche. Au sein des fonctions transversales comme le Back Office, la question de la valeur produite se pose en des termes fondamentalement différents de ceux du Front Office : là où les équipes commerciales mesurent directement les revenus qu'elles génèrent — le *gain* d'un deal leur est connu —, les équipes opérationnelles ne disposent pas de cette visibilité sur ce qu'elles apportent. En revanche, elles savent qu'elles représentent un coût, généré majoritairement par les ressources humaines qui les composent ; mais ce coût lui-même reste largement inconnu à l'échelle d'un deal, faute d'instrument pour le mesurer. C'est cette lacune que notre recherche entend combler. En reconstruisant le coût opérationnel d'un contrat de crédit à partir de la charge de travail qu'il impose aux équipes *Loan Servicing*, on rend enfin ce coût comparable au gain connu du Front Office — ouvrant la voie à une mesure de la rentabilité réelle du deal. La charge de travail n'est donc pas ici l'objet final, mais le levier : la grandeur intermédiaire qu'il faut savoir mesurer pour accéder au coût, puis à la rentabilité.

Les équipes de *Loan Servicing* occupent une position centrale dans cette

logique : elles assurent le traitement opérationnel de l'ensemble des événements survenant durant la vie d'un contrat de crédit, depuis le tirage initial (*drawdown*) jusqu'au remboursement final, en passant par les amendements contractuels, les ajustements de taux et les opérations de restructuration. Ces équipes opèrent sous une double contrainte : les exigences de qualité et de conformité imposent un traitement rigoureux dans le respect de délais contractuels stricts, tandis que la volumétrie et la complexité des opérations varient considérablement sous l'effet de cycles commerciaux, de saisonnalités financières et de chocs exogènes. Cette tension entre exigence de qualité constante et variabilité de la charge, dans un contexte où chaque poste représente un coût visible et soumis à des objectifs de réduction planifiés, constitue le défi managérial que ce mémoire se propose d'adresser.

Contexte organisationnel

Ce travail de recherche s'inscrit dans le cadre d'une mission réalisée au sein du département *Global Credit Operations* (GCO) de BNP PARIBAS. Le département GCO gère l'ensemble des opérations de crédit à destination d'États, d'institutions financières et de contreparties corporates. Dans la chaîne de traitement d'un deal, plusieurs équipes interviennent successivement : le Front Office lors de la signature et de l'origination, le Middle Office pour les informations réglementaires et contractuelles, et les équipes Back Office — plus précisément les équipes *Loan Servicing* (LS) — qui assurent le traitement des informations dans le progiciel Loan IQ.

L'organisation de GCO illustre les tendances sectorielles décrites ci-dessus. Certaines activités de traitement ont été délocalisées, les premières briques d'automatisation (macros VBA, RPA) ont été déployées, et l'équipe *Strategic Transformation & Data Analytics* — à laquelle nous sommes rattachés — porte les projets de transformation digitale et d'exploitation des données. Parmi ces projets, la création d'interfaces automatisées (*Power of Attorney, facility letters*), le développement de KPI à destination du *high management*, et surtout la conception d'une mesure fiable de la charge de travail des équipes Back Office.

La charge de travail est ici appréhendée comme un objet complexe, résultant de la diversité des événements opérationnels, de leur fréquence, de leur variabilité et de leurs contraintes. Elle ne peut être observée directement sans un travail préalable de formalisation et d'instrumentation — travail d'autant plus nécessaire que l'automatisation croissante modifie en continu

le périmètre du travail humain.

Problématique et enjeux

L'enjeu opérationnel est considérable. En l'absence d'une mesure robuste de la charge de travail, le pilotage de l'activité repose sur des estimations empiriques et sur l'expérience des managers — une approche qui atteint ses limites face à la complexité croissante des opérations, à la dispersion géographique des équipes et à la transformation des tâches par l'automatisation. Les conséquences d'un pilotage déficient sont multiples : allocation sous-optimale des ressources humaines entre sites *onshore* et *nearshore*, incapacité à anticiper les pics d'activité, augmentation des risques opérationnels (délais de traitement, erreurs, reprises), dégradation des conditions de travail et accélération du *turnover*.

Ce constat conduit à formuler la problématique suivante :

Comment la charge de travail des équipes Back Office peut-elle être formalisée en une mesure quantitative fiable au service de l'aide à la décision organisationnelle ?

Cette question de recherche se décline en trois sous-questions, ordonnées selon une progression logique allant de la mesure à la décision :

1. **Mesurer.** Comment construire un protocole de collecte des temps de traitement adapté aux opérations de crédit informatisées, qui tienne compte de la variabilité liée à la complexité des deals, aux conditions opérationnelles et à la répartition géographique des équipes ?
2. **Modéliser.** Quels modèles statistiques et d'apprentissage automatique permettent d'expliquer et de prédire la charge de travail à partir des caractéristiques observables des opérations ?
3. **Décider.** Comment traduire cette mesure prédictive en outil d'aide à la décision pour l'allocation des ressources entre sites et l'anticipation des pics d'activité ?

Démarche méthodologique

Pour répondre à cette problématique, nous adoptons une démarche de *design science* (Hevner *et al.*, 2004), dont l'objectif est la construction et l'évaluation d'un artefact — ici, un modèle de mesure et de prédiction de la

charge de travail — dans un contexte organisationnel réel. Cette démarche se déploie en quatre phases :

Phase 1 — Compréhension du processus. Nous procédons à une analyse approfondie de l’organisation des opérations de crédit et du rôle des équipes Loan Servicing, en identifiant la typologie des événements opérationnels et les facteurs de complexité qui les caractérisent.

Phase 2 — Revue de littérature. Nous recensons les approches existantes de mesure et de modélisation de la charge de travail, en mobilisant quatre champs disciplinaires : le génie industriel (études de temps, MTM), l’ergonomie cognitive (NASA-TLX), la science des données (régression, apprentissage automatique, Process Mining) et la Recherche Opérationnelle (théorie des files d’attente, optimisation).

Phase 3 — Formalisation et construction de la mesure. Nous définissons un protocole de collecte des temps de traitement (*clocking*), concevons la base de données des mesures et établissons les conditions de mesurabilité des opérations.

Phase 4 — Analyse et exploitation. Nous identifions les facteurs explicatifs de la charge de travail par des méthodes statistiques et d’apprentissage automatique, construisons un modèle prédictif et en dérivons des recommandations pour le pilotage opérationnel : allocation des ressources, anticipation des pics et prévision de la charge.

Annnonce du plan

Ce mémoire s’organise en cinq chapitres. Le **chapitre 1** présente le contexte organisationnel des opérations de crédit et caractérise l’objet d’étude — la charge de travail des équipes Loan Servicing dans un environnement marqué par le nearshoring et l’automatisation. Le **chapitre 2** propose un état de l’art des méthodes de mesure et de modélisation de la charge de travail, et identifie le *gap* que ce mémoire vise à combler. Le **chapitre 3** détaille la méthodologie de formalisation et de construction de la mesure, du protocole de collecte à la structuration de la base de données. Le **chapitre 4** expose l’analyse des données collectées, la construction du modèle prédictif et les apports pour le pilotage opérationnel. Enfin, le **chapitre 5** discute les limites de la démarche, les conditions de généralisation des résultats et les perspectives d’évolution — notamment l’intégration de l’IA générative comme levier de transformation de la charge de travail.

2 Contexte

2.1 Contexte organisationnel

2.1.1 Organisation du département GCO (Global Credit Operations)

Le département **Global Credit Operations** (GCO) de BNP Paribas structure ses activités autour de pôles complémentaires, chacun jouant un rôle clé dans la chaîne de traitement des opérations de crédit syndiqué. Le *crédit syndiqué* est un crédit accordé à une entreprise par un groupe de banques agissant conjointement, permettant de répartir le risque de financement tout en mobilisant des montants élevés [2].

- **Équipes transversales** : elles jouent un rôle de *surplomb*, en veillant à la cohérence et à la performance de l'ensemble de la chaîne opérationnelle. Elles pilotent les initiatives de transformation stratégique (automatisation des processus, intégration d'outils d'intelligence artificielle, déploiement de KPI de suivi), garantissent la conformité réglementaire, et produisent des analyses destinées au top management. Leur rôle est d'assurer la gouvernance et la standardisation des pratiques au niveau global.
- **Front Office (Origination & Syndication)** : il constitue le point d'entrée commercial et relationnel avec les clients. Le Front Office identifie les besoins de financement, conçoit la structure du crédit, négocie les conditions avec l'emprunteur et organise la syndication, c'est-à-dire la répartition du financement entre les différentes banques participantes. Il est à la fois force de proposition stratégique et interface principale avec le marché.
- **Middle Office (Credit Transaction Management)** : il agit comme *pivot de contrôle et de sécurisation*. Ses missions consistent à vérifier la bonne mise en place des conditions négociées (clauses contractuelles, covenants, pricing), à évaluer les risques associés à la transaction, à s'assurer de la qualité des données saisies dans les systèmes et à gérer les exceptions opérationnelles. Le Middle Office se situe entre la relation commerciale (FO) et l'exécution opérationnelle (BO), garantissant l'intégrité et la conformité des transactions.
- **Back Office (Loan Servicing Team)** : il représente le *cœur opérationnel* du dispositif. Responsable de l'exécution quotidienne, il prend

en charge le cycle de vie complet des crédits : décaissements (draw-downs), appels de fonds, paiements d'intérêts et de commissions, remboursements, gestion des échéances, ainsi que la clôture finale du prêt. Il assure également la maintenance des systèmes de gestion (tels que Loan IQ) et la production de reportings réglementaires et financiers.




FIGURE 1 – Chaîne de valeur du crédit syndiqué : organisation verticale et supervision transversale

2.1.2 Organisation de l'équipe Strategic Transformation & Data Analytics

L'équipe Strategic Transformation est composée de chefs de projet chargés de piloter la modernisation des opérations de crédit (automatisation, pilotage du changement stratégique).

L'équipe Data Analytics est référente sur la donnée : qualité, nettoyage, analyses statistiques ainsi que création de KPI en destination du high management.




FIGURE 2 – Structure hiérarchique de l’équipe (FR = France, PT = Portugal)

2.1.3 Organisation générale de la banque

Le secteur bancaire se divise en trois grandes catégories d’établissements :

- **Banque de détail** : services courants et prêts pour particuliers et PME.
- **Banque privée** : gestion de patrimoine pour une clientèle fortunée.
- **Banque de financement et d’investissement (CIB)** : financement structuré, marchés de capitaux, couverture des risques.

Ce mémoire se concentre sur la **CIB**, et plus précisément le *crédit syndiqué*, dont le cycle de vie opérationnel est schématisé ci-dessous :

Étape	Front Office	Middle Office	Back Office
Origination	Analyse du besoin, structuration	–	–
Structuration	Négociation, syndication	Évaluation des risques	–
Documentation	Coordination juridique	Vérification des clauses	Préparation contrats
Mise en place	Information client	Contrôle final des risques	Versements, confirmations
Vie du deal	Suivi relationnel	Monitoring des covenants	Reporting, échéances

TABLE 1 – Cycle de vie opérationnel d’un crédit syndiqué

2.2 Typologie des événements opérationnels

Le cycle de vie d’un crédit syndiqué génère un ensemble d’événements opérationnels dont le traitement incombe aux équipes Loan Servicing. Chaque événement correspond à une unité de travail discrète, déclenchée par une instruction du Front Office ou du Middle Office, et exécutée dans le progiciel Loan IQ selon des procédures standardisées. La diversité de ces événements — par leur nature, leur fréquence et leur complexité — constitue le premier déterminant structurel de la charge de travail.

On distingue cinq grandes familles d’événements, ordonnées selon la chronologie du cycle de vie du crédit.

Événements de mise en place (*setup*). Ils interviennent lors de l’entrée d’un nouveau deal dans le système. Le *deal setup* comprend la création de la facilité dans Loan IQ, le paramétrage des conditions contractuelles (devise, taux de référence, spreads, calendrier de remboursement, frais) et la vérification de cohérence avec la documentation juridique. Cette étape est à la fois volumineuse en saisie et exigeante en attention, car toute erreur de paramétrage se propage à l’ensemble des opérations ultérieures.

Événements de décaissement et de remboursement. Les tirages (*drawdowns*) et les remboursements (*repayments*) constituent le flux le plus récurrent du Loan Servicing. Un tirage correspond à la mise à disposition




FIGURE 3 – Cycle de vie des événements opérationnels en Loan Servicing. Les flèches pleines représentent le flux nominal ; les flèches en pointillés indiquent les boucles de retour.

effective des fonds au profit de l’emprunteur ; un remboursement, au retour partiel ou total du principal selon l’échéancier contractuel ou par anticipation. La complexité de ces opérations varie considérablement : un tirage en devise unique sur une facilité bilatérale est une opération routinière, là où un tirage sur une tranche syndiquée multidevise implique la coordination de plusieurs participants, le calcul de quotes-parts et la gestion de fuseaux horaires différents.

Événements de vie courante (*servicing*). Ils regroupent l’ensemble des opérations récurrentes liées à la gestion d’un crédit actif : paiements d’intérêts (*interest payments*), appels et paiements de commissions (*commitment fees*, *agency fees*), *rollovers* (renouvellement d’une période d’intérêt), fixings de taux et ajustements de spread. Ces événements, bien que souvent unitairement simples, représentent le volume le plus important en nombre d’occurrences quotidiennes. Leur charge est essentiellement liée à leur fréquence et à leur concentration calendaire — les fins de mois et fins de trimestre (*quarter-ends*) produisent des pics de volume considérables.

Événements de modification contractuelle. Les amendements (*amendments*), les *waivers* (renonciations temporaires à une clause) et les restructurations modifient les termes initiaux du contrat de crédit. Ces opé-

rations sont les plus complexes du portefeuille : elles nécessitent l'interprétation de clauses juridiques, la mise à jour simultanée de multiples paramètres dans le système et, fréquemment, des itérations avec le Middle Office et le département juridique. Le temps de traitement d'un amendement peut être dix à vingt fois supérieur à celui d'un tirage standard, ce qui rend sa contribution à la charge globale disproportionnée par rapport à sa fréquence.

Événements de clôture. Le remboursement final (*final repayment*) et la clôture du deal (*deal closure*) mettent fin au cycle de vie opérationnel. Ces événements impliquent le solde de l'ensemble des positions, la vérification de l'absence d'encours résiduel, la production de confirmations finales et l'archivage dans le système. Bien que ponctuels, ils requièrent un contrôle exhaustif qui les rend chronophages.

TABLE 2 – Synthèse des familles d'événements opérationnels en Loan Servicing

Famille	Événements types	Fréquence	Complexité	Automatisable
Mise en place	Deal setup, paramétrage facilité	Faible	Élevée	Partiel
Décaissement / Remboursement	Drawdowns, repayments, remb. anticipés	Élevée	Variable	Partiel
Vie courante	Intérêts, commissions, rollovers, fixings	Très élevée	Faible à modérée	Oui
Modifications	Amendements, waivers, restructurations	Faible	Très élevée	Non
Clôture	Final repayment, deal closure	Ponctuelle	Modérée	Partiel
Transversaux	Reprises, corrections, reporting ad hoc	Variable	Variable	Non

À ces cinq familles s'ajoutent des **événements transversaux** qui ne relèvent pas d'une étape spécifique du cycle de vie mais constituent une source significative de charge : les reprises et corrections (*rework*) consécutives à des erreurs de saisie ou à des données amont incomplètes, les demandes *ad hoc* de reporting, et les réconciliations de données entre systèmes. Ces événements sont particulièrement difficiles à anticiper et à standardiser, car ils résultent de dysfonctionnements plutôt que d'un processus nominal.

Les deux composantes de la charge : booking LIQ et aftercare. La charge d'un événement ne se réduit pas à sa saisie dans le progiciel Loan IQ. L'observation directe des équipes fait apparaître deux composantes distinctes, dont la mesure séparée est indispensable à une estimation fiable du coût. La première est le *booking LIQ* : le temps de traitement de l'événement dans le système — création de la transaction, paramétrage, saisie, validation. Ce temps est relativement stable d'un événement à l'autre, de l'ordre d'une vingtaine de minutes en moyenne, et varie peu selon le type d'opération. La seconde est l'*aftercare* : l'ensemble des tâches de post-traitement qui gravitent autour de l'événement sans être exécutées dans Loan IQ — contrôles de cohérence, réconciliations entre systèmes, contrôles de *closing*, audits, gestion des exceptions et interactions avec le Middle Office. Contrairement au booking, l'*aftercare* est fortement variable : il dépend du rôle de la banque (Agent, Participant, Bilatéral), de la complexité du deal et de la période. C'est cette composante, largement invisible dans les systèmes d'information, qui explique l'essentiel de la variabilité de la charge — et donc du coût — entre deals comparables en volume. Cette distinction est décisive : le temps de *booking*, seul enregistré dans Loan IQ, ne suffit pas à mesurer la charge réelle. Toute mesure fiable doit capturer les deux composantes, ce que le protocole de collecte présenté au chapitre ?? s'attache à faire.

L'automatisation modifie le périmètre de cette typologie. Les solutions de RPA déployées au sein de GCO ont permis d'automatiser partiellement certaines opérations à faible valeur ajoutée — extraction de données, pré-remplissage de champs dans Loan IQ, génération de confirmations standardisées. Ces tâches, qui figuraient autrefois dans la charge des opérateurs, sortent progressivement du périmètre du travail humain. En contrepartie, le travail résiduel se concentre sur les événements complexes, les cas d'exception et les contrôles qualitatifs — précisément les opérations dont le temps de traitement est le plus variable et le plus difficile à modéliser. Toute mesure de la




FIGURE 4 – Répartition de la charge entre traitement manuel, partiellement automatisé et entièrement automatisé (RPA), par famille d'événements ; estimation issue d'entretiens avec les équipes Loan Servicing de GCO. Les modifications contractuelles restent quasi exclusivement manuelles.

charge doit donc intégrer cette distinction entre événements automatisés, partiellement automatisés et manuels, sous peine de surestimer ou sous-estimer la charge réelle supportée par les équipes.

2.3 Définition du concept de charge de travail

Avant d'en donner une définition, il importe de rappeler pourquoi cette mesure est construite. La charge de travail n'est pas ici étudiée pour elle-même : elle constitue la grandeur intermédiaire qui permet de reconstruire le *coût opérationnel* d'un contrat de crédit, puis — rapporté au gain connu du Front Office — sa *rentabilité réelle*. Mesurer la charge, c'est mesurer la brique élémentaire du coût.

La charge de travail est un concept en apparence intuitif — chaque manager sait reconnaître une équipe « débordée » — mais dont la formalisation exige de lever une ambiguïté fondamentale : celle entre la charge *unitaire* d'un événement et la charge *totale* supportée par une équipe. Confondre les deux conduit à des raisonnements erronés ; les distinguer est la clé du modèle.

La charge de travail d'un événement opérationnel est le temps

de traitement effectif requis pour l'exécuter dans le respect des standards de qualité. Elle se compose de deux temps distincts : le booking dans Loan IQ (saisie et exécution de l'opération) et l'aftercare (contrôles, réconciliations et post-traitement consécutifs à l'opération). La charge totale supportée par une équipe sur une période donnée est la somme des charges unitaires des événements traités sur cette période : elle croît avec le volume d'événements, à charge unitaire constante.

Cette définition appelle deux précisions, articulées autour de la distinction unitaire / total.

La charge unitaire. Chaque événement opérationnel consomme une durée de travail qui dépend de sa nature (tirage, amendement, clôture), de ses caractéristiques intrinsèques (devise, syndication, clauses spécifiques) et des conditions d'exécution. Cette charge unitaire est **indépendante du volume** : un tirage standard requiert le même temps de traitement un jour creux ou en période de pic. Elle se décompose en deux temps complémentaires :

- le *booking* dans Loan IQ ($T_{LIQ,i}$) : la saisie et l'exécution de l'opération dans le progiciel, dont la durée moyenne observée est remarquablement stable, de l'ordre de vingt minutes quel que soit le type d'événement ;
- l'*aftercare* ($T_{AC,i}$) : les contrôles, réconciliations et post-traitements qui suivent le *booking*, dont la durée est bien plus variable et dépend fortement de la complexité du deal.

La charge unitaire d'un événement i est donc la somme de ces deux composantes :

$$T_{s,i} = T_{LIQ,i} + T_{AC,i} \quad (1)$$

Le temps brut ne suffit toutefois pas à mesurer chacune de ces composantes : un opérateur peut consacrer trente minutes à un *booking* standard parce qu'il est interrompu, ou l'exécuter en dix minutes sans interruption. Il faut donc, pour chaque composante, distinguer le *temps effectif de traitement* — réellement consacré à l'exécution — du *temps écoulé*, qui inclut interruptions et attentes :

$$T_{\text{eff}} = T_{\text{écoulé}} - T_{\text{interruptions}} - T_{\text{attente}} \quad (2)$$

C'est ce temps effectif, chronométré puis standardisé par type d'événement et par composante, que nous agrégeons dans $T_{s,i}$.

La charge totale. La charge supportée par une équipe sur une période $[t_0, t_1]$ est la somme des charges unitaires des événements traités sur cette période :

$$W_{[t_0, t_1]} = \sum_{i=1}^N T_{s,i} \quad (3)$$

où N est le volume d'événements traités. C'est cette charge totale — et elle seule — qui varie avec l'activité : les pics observés en fin de trimestre (*quarter-ends*) résultent de l'augmentation du volume N , non d'une variation de la charge unitaire $T_{s,i}$. Cette distinction est essentielle pour le pilotage : dimensionner une équipe, anticiper un pic ou arbitrer une allocation de ressources relève de la dynamique du **volume** et de la capacité de traitement disponible — questions traitées au chapitre ?? — et non de la mesure de la charge unitaire, qui en constitue seulement le facteur multiplicatif stable.




FIGURE 5 – Chaîne de mesure, de la charge unitaire au coût du deal. La charge unitaire T_s agrège le *booking* Loan IQ (stable, ~ 20 min) et l'*aftercare* (variable selon la complexité). Multipliée par le volume d'événements N de la période, elle donne la charge totale W_N ; valorisée au coût horaire chargé w_s , différencié par site, elle donne le coût opérationnel du deal. Seul le volume N porte la variabilité saisonnière ; la charge unitaire reste stable.

Cette décomposition éclaire un résultat central : le temps de *booking* dans Loan IQ, stable autour de vingt minutes, ne constitue qu'une composante marginale du coût total. Les deux véritables déterminants de la charge — et donc du coût — sont le **volume d'événements** d'un deal et le poids de son

aftercare, ce dernier variant fortement avec la complexité de l’opération. Réduire la charge à son seul temps de saisie conduirait ainsi à sous-estimer massivement le coût réel des deals les plus complexes.

De la charge au coût. Exprimée en unités de temps, la charge totale se convertit directement en coût opérationnel dès lors qu’on lui associe un coût horaire chargé w (salaire, charges et frais de structure), différencié par site pour refléter les écarts *onshore* / *nearshore* :

$$C = \sum_{i=1}^N T_{s,i} \times w_{s(i)} \quad (4)$$

où $w_{s(i)}$ est le coût horaire du site s traitant l’événement i . Rapporté au gain connu du Front Office, ce coût opérationnel ouvre la voie à une mesure de la *rentabilité réelle* du deal — objectif ultime développé au chapitre ?? . La charge de travail apparaît ainsi comme le **levier de mesure** du coût, et non comme une fin en soi.

La portée de cette formulation apparaît à l’échelle du deal : parce que le coût combine un volume d’événements et une charge unitaire elle-même pondérée par la complexité, deux deals peuvent présenter des coûts opérationnels dans un rapport de plusieurs dizaines. L’analyse empirique du chapitre ?? met en évidence une variance allant, sur une même année, de quelques milliers à plusieurs centaines de milliers d’euros par deal — confirmant, à l’échelle du contrat, l’écart de charge déjà observé à l’échelle de l’événement entre un tirage standard et un amendement complexe.

Cette formulation — charge unitaire stable, charge totale portée par le volume, coût obtenu par valorisation — fonde la démarche de ce mémoire : construire une mesure fiable de la charge unitaire par événement, articulant données de chronométrage, caractéristiques objectives des événements et facteurs contextuels, puis la recomposer en coût opérationnel au service du pilotage de la rentabilité.

3 État de l’art

Ce chapitre poursuit un objectif unique, subordonné à la finalité du mémoire : identifier, parmi les approches existantes, celles qui permettent d’établir une mesure fiable de la charge de travail des équipes Loan

Servicing et d'en déduire le coût d'un deal — rétrospectivement, pour un deal traité, et de façon prédictive, pour un deal futur. La charge de travail n'est pas étudiée pour elle-même : elle est la grandeur intermédiaire qui, mesurée puis valorisée, donne accès au coût, puis à la rentabilité. Cet objectif recoupe celui assigné à la mission : « estimer avec précision le coût associé à un nouveau deal » et obtenir « un coût par événement et par deal pour chaque équipe LS ».

Plutôt que de juxtaposer les disciplines, nous les ordonnons le long d'un fil unique — de la mesure du temps au coût — et n'évaluons chaque méthode que par sa contribution à ce fil, selon trois questions : mesure-t-elle le temps par événement ? résiste-t-elle à un back office nearshore, automatisé et hétérogène ? conduit-elle à un coût imputable au deal ? Le périmètre se resserre ainsi sur deux finalités articulées par un socle commun — le temps unitaire par événement : **mesurer** le coût d'un deal traité (§3.1–3.2), et le **prédire** pour un deal futur (§3.3).

3.1 Du coût des activités au coût par événement : ABC et TDABC

3.1.1 Le principe de l'Activity-Based Costing

Toute méthode de coût doit répondre à une question : comment répartir des charges *indirectes* — salaires d'un back office, systèmes, encadrement — sur les objets qui les consomment ? La comptabilité traditionnelle répond par des clés grossières : on répartit au prorata d'un volume ou d'heures de main-d'œuvre. Le défaut est connu : un deal simple à fort volume et un deal complexe à faible volume reçoivent une part de coût sans rapport avec les ressources qu'ils exigent réellement. L'*Activity-Based Costing* (ABC), formalisé par Kaplan et Cooper à la fin des années 1980, corrige ce biais en interposant les **activités** : on trace d'abord le coût des ressources vers les activités qu'elles servent (*resource drivers*), puis le coût des activités vers les objets qui les déclenchent (*activity drivers*) [8]. La littérature distingue à ce titre deux natures d'inducteurs : les *transaction drivers*, qui comptent le nombre de fois qu'une activité survient, et les *duration drivers*, qui mesurent le temps qu'elle consomme — ces derniers étant plus précis lorsque les occurrences d'une même activité n'ont pas toutes la même durée. En banque, l'ABC a montré qu'il révèle des clients ou produits dont le service consomme un back office disproportionné par rapport aux revenus qu'ils génèrent —

exactement notre problème de rentabilité par deal.

Pertinence et limite pour notre contexte. Le principe de l’ABC est directement pertinent : notre « objet » est le deal, nos « activités » sont les événements Loan Servicing, et nous cherchons un *duration driver* — le temps par événement. Mais l’ABC classique a une faiblesse qui le disqualifie en l’état : il estime le temps par activité au moyen d’**enquêtes déclaratives**, où chaque opérateur indique le pourcentage de son temps consacré à chaque tâche. Ces enquêtes sont coûteuses à mener, subjectives, et surtout se périment dès que les processus changent — ce qui, sous déploiement continu de RPA, est notre quotidien. De plus, l’ABC suppose implicitement que la capacité est utilisée à 100 %, et noie donc le coût de la capacité inutilisée dans des taux gonflés. Ces deux défauts — coût de maintenance et cécité à la capacité oisive — sont précisément ceux que la variante suivante corrige.

3.1.2 Le Time-Driven ABC : deux paramètres, une équation

Kaplan et Anderson introduisent en 2004 le *Time-Driven Activity-Based Costing* (TDABC), qui réduit toute la mécanique de l’ABC à **deux paramètres** par groupe de ressources [7]. Le premier est le **taux de coût de capacité** (*capacity cost rate*) : le coût total du groupe (salaires, encadrement, systèmes, locaux) divisé par sa *capacité pratique* — non pas le temps théoriquement disponible, mais celui réellement travaillé, estimé à environ 80–85 % du théorique une fois retranchés pauses, formations et aléas. On obtient un coût par minute. Le second est un ensemble d’**équations de temps** (*time equations*) qui estiment la durée d’une transaction à partir de ses caractéristiques : un temps de base, augmenté d’incrémentes pour chaque facteur qui l’allonge. La forme canonique est :

$$t = \beta_0 + \sum_k \beta_k x_k \quad (5)$$

où β_0 est le temps de base, x_k les caractéristiques de la transaction (par exemple : contrôle manuel requis, expédition à l’export) et β_k le temps additionnel qu’elles imposent. Le coût de l’objet est alors la somme, sur tous ses événements, du temps consommé multiplié par le taux de coût de capacité :

$$C = \sum_{i=1}^N t_i \times c_u \quad (6)$$

Cette équation est, à la notation près, **celle que notre analyse terrain a établie** — $C = (T_{\text{LIQ}} + T_{\text{AC}}) \times N \times w_s$ (chapitre 1). Le TDABC est donc le socle de notre finalité rétrospective. Il présente deux vertus supplémentaires décisives. D’une part, il rend *visible la capacité inutilisée* : comme on a valorisé la capacité *fournie*, la différence entre minutes disponibles et minutes réellement consommées apparaît comme une ligne propre — information cruciale pour dimensionner les équipes FR/PT. D’autre part, l’équation 6 est *nativement prédictive* : connaître les temps unitaires permet de simuler le coût d’un volume ou d’un mix futurs, ce qui fait le pont vers notre seconde finalité.

La limite critique — et c’est notre gap. La littérature postérieure, moins promotionnelle que les textes fondateurs, pointe une faiblesse unique mais décisive : *la précision du TDABC dépend entièrement de la qualité des estimations de temps*, et la méthode s’applique mal au *knowledge work* non routinier, où le temps d’une tâche est un mauvais proxy de la ressource consommée. Le cas le plus proche du nôtre est documenté en santé : Koster *et al.* (2023) montrent que l’hétérogénéité des patients rend les temps par activité non ponctuels mais variables, au point de devoir remplacer les estimations uniques par une logique floue capturant un intervalle du meilleur au pire cas [9]. La transposition est immédiate : nos deals sont à nos équipes ce que les patients multimorbides sont aux soignants — une population hétérogène pour laquelle un temps unitaire figé ne suffit pas. C’est exactement ce que la mission nomme « *wide possibilities of post operation process which make the workload difficult to predict* ». Estimer ce temps unitaire fiable, en environnement hétérogène et automatisé, est le verrou que ce mémoire doit lever — et qui justifie d’examiner les méthodes de mesure du temps.

3.2 Mesurer le temps par événement

3.2.1 L’étude des temps (Taylor) : chronométrer et normaliser

La méthode fondatrice de mesure du travail est l’*étude des temps*, formalisée par Taylor (1911) [14, 4]. Son principe : décomposer une tâche en éléments observables, chronométrer chacun sur plusieurs cycles pour obtenir un *temps observé* T_o , puis le corriger en deux étapes. On applique d’abord un **facteur d’allure** F_a — jugement porté par l’analyste sur le rythme de l’opérateur par rapport à une cadence « normale » (un opérateur rapide se

voit affecter $F_a > 1$) — pour obtenir un *temps normal* $T_n = T_o \times F_a$. On ajoute ensuite des **majorations** A pour les aléas incompressibles (fatigue, pauses, interruptions), d'où le *temps standard* :

$$T_s = T_o \times F_a \times (1 + A) \quad (7)$$

Ben-Gal *et al.* (2010) ont établi que ce principe reste valide dans les services, à condition d'adapter la granularité de décomposition aux tâches informatisées [1].

Pertinence et limites pour notre contexte. Le principe est le bon : il produit exactement le t_i qu'exige le TDABC, et l'idée de décomposer un traitement en événements chronométrables fonde notre *clocking*. Mais le *protocole* tayloriste échoue sur trois points précis dans un back office nearshore. *Premièrement*, le facteur d'allure F_a repose sur l'observation directe d'un analyste : dans des équipes réparties entre Paris et Lisbonne, cette observation est rarement praticable, et l'auto-déclaration réintroduit un biais de désirabilité sociale. *Deuxièmement*, l'étude des temps suppose une « méthode standard » stabilisée ; or l'automatisation redéfinit la façon d'exécuter un même événement d'un trimestre à l'autre, rendant tout temps standard rapidement obsolète. *Troisièmement*, elle suppose des tâches nettement délimitées, alors que le travail réel est entrelacé — plusieurs deals menés de front, interrompus par des requêtes *ad hoc* — ce qui brouille la mesure du temps effectif. Conclusion : on garde le principe (chronométrer par événement), on abandonne le protocole (observation + jugement d'allure) au profit d'une mesure ancrée dans les traces système.




FIGURE 6 – Protocole de l’étude des temps (Taylor, 1911). Les étapes 2 et 3 — observation directe et jugement d’allure — sont celles qui résistent le moins à un back office distribué.

3.2.2 Le MTM : des temps prédéterminés, mais pour des gestes

Frank et Lillian Gilbreth déplacent l’attention de la durée vers le *mouvement* : ils décomposent tout geste en unités élémentaires (les *therbligs* — saisir, positionner, relâcher). De là naît le *Methods-Time Measurement* (MTM), formalisé par Maynard *et al.* (1948) [3, 11] : un système de temps *prédéterminés* qui attribue *a priori* une valeur temporelle normalisée à chaque mouvement élémentaire, si bien qu’on peut estimer la durée d’une opération *avant* de l’exécuter, par simple addition, sans chronométrer.

Pertinence et limites pour notre contexte. L’attrait est réel : le MTM promettrait d’estimer t_i sans campagne de mesure. Mais il présuppose que le travail se réduit à des gestes physiques catalogables — vrai à l’atelier, faux au back office. Les « mouvements » d’un opérateur Loan Servicing sont des séquences *cognitives et numériques* : naviguer entre écrans Loan IQ, interpréter une clause, arbitrer entre instructions contradictoires. Leur durée ne dépend pas d’une mécanique gestuelle mais du *contenu informationnel* du deal : un tirage bilatéral en euros et un tirage syndiqué multidevise à vingt participants sollicitent les mêmes écrans pour des durées radicalement diffé-

rentes. Aucune table MTM générique ne capture cette variabilité. Le MTM confirme donc, par son échec, que notre référentiel de temps doit être *reconstitué empiriquement* à partir de données réelles, non dérivé d’un catalogue.

3.2.3 Le Process Mining : lire le temps dans les traces système

Le *Process Mining*, formalisé par van der Aalst (2016), résout le problème par un tout autre angle : au lieu d’observer l’opérateur, il exploite les **logs d’événements** déjà enregistrés par les systèmes d’information [15]. Chaque ligne de log fournit au minimum un triplet (case_id, activité, timestamp) : l’identifiant du cas (ici, le deal), l’activité réalisée, et l’horodatage. En recomposant ces triplets, le Process Mining *découvre* le processus réellement suivi (et non le processus théorique), mesure les durées entre activités, et met au jour ce que les cartographies déclaratives masquent : boucles de reprise, approbations redondantes, temps d’attente entre étapes. Jans *et al.* (2013) en démontrent la valeur dans une organisation financière pour l’analyse multifacette des processus et la détection d’anomalies [6].

Pertinence et limites pour notre contexte. C’est le candidat le plus solide pour alimenter le t_i du TDABC, car il lève les deux premières failles du chronométrage tayloriste : il ne requiert ni observateur ni jugement d’al-lure (il lit des horodatages objectifs), et il se met à jour automatiquement à mesure que les processus évoluent — répondant directement au problème de l’obsolescence sous automatisation. Mais il souffre d’une limite qui recoupe précisément la nôtre : l’horodatage mesure un **temps écoulé** entre deux transactions, non un **temps effectif** de travail. Entre le *timestamp* d’ouverture et celui de clôture d’un événement dans Loan IQ, l’opérateur a pu être interrompu, traiter un autre deal, ou attendre une validation. Le Process Mining fournit donc une *borne supérieure bruitée* du temps unitaire. D’où l’articulation que retient notre méthodologie, et qui constitue une réponse directe au gap : le Process Mining pour la *couverture exhaustive* de tous les événements, calibré par un *clocking* manuel ciblé qui mesure, sur un échantillon, le rapport entre temps effectif et temps écoulé.

3.3 Prédire le coût d'un deal futur : méthodes de modélisation

Mesurer le coût d'un deal traité résout la première finalité. La seconde — estimer le coût d'un deal *avant* son traitement, à partir de ses seules caractéristiques connues à la signature — prolonge naturellement le TDABC, dont l'équation de temps (5) est déjà une fonction que l'on peut *apprendre* sur l'historique. Là où le TDABC calcule un coût *a posteriori* en observant le volume et l'*aftercare* réellement consommés, un modèle prédictif estime :

$$\hat{C}_{\text{deal}} = f(x_1, \dots, x_p) \quad (8)$$

où f est appris sur les deals passés et où les x_j sont les caractéristiques disponibles dès la signature : nombre de prêteurs, devise, nombre de facilités, rôle (agent, participant, bilatéral), produit. Cette section examine les familles de modèles candidates pour f , de la plus interprétable à la plus performante, en pesant pour chacune le compromis *précision* / *interprétabilité* — compromis central, car un modèle destiné à arbitrer la rentabilité d'un deal devant le Front Office doit être non seulement juste, mais explicable.

3.3.1 La régression linéaire multiple : le modèle de référence

Le modèle le plus simple postule que le coût (ou le temps) est une combinaison linéaire des caractéristiques :

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \varepsilon \quad (9)$$

où Y est la variable à prédire, les β_j des coefficients estimés par moindres carrés, et ε un terme d'erreur. Sa force est l'**interprétabilité par conception** : chaque coefficient β_j se lit directement comme la contribution marginale d'un facteur — « un prêteur supplémentaire ajoute β minutes de traitement ». C'est un argument de poids pour la communication managériale, et cela répond directement au sous-objectif de la mission : « *understand the impact of each parameter of the LS workload* ».

Hypothèses et pourquoi elles se brisent ici. Cette lisibilité repose sur des hypothèses que notre contexte viole. La régression suppose la **linéarité** (l'effet d'un facteur est constant, quel que soit son niveau) et surtout l'**additivité** (l'effet total est la somme des effets individuels). Or nos données

terrain montrent des **interactions** : un deal *à la fois* syndiqué, multidevise et à clauses spéciales génère une charge supérieure à la somme des trois effets pris isolément — la complexité se *multiplie*, elle ne s’additionne pas. La régression sous-estimerait donc systématiquement les deals les plus complexes, précisément ceux dont le coût importe le plus. On peut ajouter manuellement des termes d’interaction ($x_1 \times x_2$), mais leur nombre explose et leur choix devient arbitraire. La régression reste donc un *étalon* de référence et un outil de communication, mais insuffisante comme modèle final.

3.3.2 Les arbres de décision (CART) : capturer les interactions

L’arbre de décision de type CART (*Classification and Regression Trees*) adopte une logique inverse : au lieu de poser une équation globale, il **partitionne récursivement** l’espace des caractéristiques. À chaque nœud, l’algorithme cherche la question binaire (par exemple « nombre de prêteurs > 50 ? ») qui sépare le mieux les données, puis recommence sur chaque sous-groupe, jusqu’à des feuilles où la prédiction est la moyenne des cas qu’y tombent. Pour une cible continue comme le temps, le « meilleur » découpage est celui qui **minimise la variance** intra-groupe — on cherche le seuil qui rend les deux sous-groupes les plus homogènes possible. La réduction de variance obtenue par un découpage s’écrit :

$$\Delta = \text{Var}(S) - \frac{|S_L|}{|S|} \text{Var}(S_L) - \frac{|S_R|}{|S|} \text{Var}(S_R) \quad (10)$$

où S est le groupe parent, S_L et S_R les deux sous-groupes issus du découpage, et $|\cdot|$ leur effectif. L’algorithme retient, à chaque nœud, le découpage qui maximise Δ .

Pertinence et limites. L’arbre a deux vertus majeures pour nous. Il capture **nativement les interactions** : en enchaînant « si rôle = agent *puis* si multidevise = oui », il modélise exactement l’effet multiplicatif que la régression manque, sans qu’on ait à le spécifier. Et il est **lisible** : un chemin de la racine à une feuille se lit comme une règle métier explicite. Mais un arbre unique souffre de deux défauts. Il est **instable** (une variation minime des données change toute sa structure — *high variance*), et il ne sait pas **extrapoler** : entraîné sur des deals de 2 à 1000 prêteurs, il plafonnera sa prédiction pour un deal à 1500 prêteurs à la valeur de sa feuille la plus haute. Seul, il sur-apprend et généralise mal : il faut l’agréger.

3.3.3 Random Forest et gradient boosting : agréger pour fiabiliser

Deux stratégies d'agrégation d'arbres dominent la pratique sur données tabulaires comme les nôtres. Le **Random Forest** entraîne des centaines d'arbres *en parallèle*, chacun sur un échantillon aléatoire des données et des variables, puis *moyenne* leurs prédictions :

$$\hat{f}(x) = \frac{1}{B} \sum_{b=1}^B T_b(x) \quad (11)$$

où T_b est le b -ième arbre. En moyennant des arbres décorrélés, la forêt annule leur instabilité individuelle : elle est robuste, demande peu de réglage, et fournit une mesure d'*importance des variables* (via la réduction de variance cumulée qu'apporte chaque variable) — utile pour hiérarchiser les inducteurs de charge. Le **gradient boosting** (dont XGBoost est l'implémentation de référence) procède au contraire *séquentiellement* : chaque nouvel arbre corrige les erreurs résiduelles des précédents. Cette correction ciblée le rend généralement plus précis que la forêt sur données tabulaires structurées, au prix d'un réglage plus délicat (un boosting mal réglé sur-apprend). Le compromis pratique est clair : Random Forest pour la robustesse et la simplicité de mise en œuvre ; gradient boosting pour la performance maximale quand on peut investir dans le réglage.

Le prix à payer : l'interprétabilité, et comment la restaurer. Ces ensembles gommant la lisibilité de l'arbre unique : on ne peut plus lire une règle, seulement constater une performance. C'est un vrai problème dans un contexte bancaire, où une estimation de coût opposée au Front Office doit être justifiable. La littérature sur l'*interpretable machine learning* répond par des méthodes d'explication *post-hoc*, appliquées après l'entraînement, indépendamment du modèle. La plus établie est celle des **valeurs de Shapley** (SHAP), issue de la théorie des jeux coopératifs [10]. L'idée : traiter chaque caractéristique comme un « joueur » contribuant à la prédiction, et lui allouer équitablement sa part de l'écart entre la prédiction et la moyenne. La valeur SHAP ϕ_j d'une variable j est sa contribution marginale moyenne, calculée sur tous les ordres d'entrée possibles des variables :

$$\phi_j = \sum_{S \subseteq N \setminus \{j\}} \frac{|S|! (|N| - |S| - 1)!}{|N|!} [f(S \cup \{j\}) - f(S)] \quad (12)$$

où N est l'ensemble des variables et S un sous-ensemble n'incluant pas j . Une propriété fondamentale rend SHAP idéal pour notre usage : les valeurs SHAP sont **additives** et somment exactement à l'écart entre la prédiction du deal et le coût moyen. On peut donc présenter au Front Office une décomposition intelligible : « ce deal coûte 180 K€, soit 90 K€ au-dessus de la moyenne ; +50 K€ viennent du nombre de prêteurs, +30 K€ du rôle d'agent, +10 K€ du multidevise ». On obtient ainsi le meilleur des deux mondes : la *précision* d'un modèle non linéaire et une *explication* par deal aussi lisible qu'une régression.

Le pilotage temporel, en appui. Enfin, la part de coût liée au *volume* et à sa saisonnalité (pics de *quarter-end*) relève de l'analyse de séries temporelles. Les modèles classiques (ARIMA, SARIMAX) y ajoutent des variables exogènes (pipeline commercial, calendrier réglementaire), mais la littérature récente souligne leurs limites — linéarité imposée, horizons fixes — et leur préfère désormais des ensembles d'arbres et des approches sous contrainte pour des demandes hétérogènes à horizon variable [12]. Ces approches restent en appui de nos deux finalités : elles prédisent le *volume* N , non le temps unitaire, qui demeure stable.

Une mise en garde de niveau. Deux erreurs guettent l'usage de ces modèles, et structurent notre méthodologie. D'abord, le modèle prédit le coût *total* d'un deal (fonction du volume et des caractéristiques), *non* le temps de *booking* unitaire, qui reste stable autour de vingt minutes : confondre les deux niveaux serait une faute d'analyse. Ensuite, et surtout, la qualité de toute prédiction est **bornée par celle de la mesure** : un modèle appris sur des temps unitaires mal estimés prédira un coût faux, quelle que soit sa sophistication. La seconde finalité est donc entièrement tributaire de la première — ce qui justifie l'ordre de ce chapitre et le poids que nous mettons sur la mesure du temps.

3.4 Les solutions professionnelles : ce que le marché résout, ce qu'il laisse ouvert

La question n'a pas échappé aux éditeurs, et deux familles de solutions éclairent par contraste notre contribution. Les plateformes de **Back-Office Workforce Management** (Verint, et les suites décrites par les intégrateurs

du secteur) capturent le temps de production réel des opérateurs à travers leurs applications pour équilibrer les charges, suivre les SLA et dimensionner les effectifs [16]. Elles adressent le *pilotage* de la charge, avec des gains documentés ; mais elles raisonnent en *capacité et débit*, non en *coût par objet* : elles disent si une équipe est surchargée, jamais ce que coûte un deal donné. À l’inverse, les **suites de costing** (CostPerform et le TDABC outillé) calculent un coût par activité et par objet, mais supposent l’intrant temps déjà résolu — elles industrialisent l’équation, pas la mesure du t_i .

Un courant professionnel récent, sur les projets d’IA en services financiers, formule la critique la plus utile à notre positionnement : la majorité des projets d’automatisation échouent faute d’avoir mesuré, *au niveau activité*, le travail réel avant d’automatiser — la donnée applicative (« six heures dans le système ») étant inexploitable pour décider, seule la donnée d’activité (« tant de minutes sur telle exception ») l’étant [13]. Ce constat conforte notre séquençage : la mesure fine du temps précède et conditionne toute optimisation. Aucune des deux familles d’outils ne construit le pont qui nous occupe — du temps unitaire mesuré jusqu’au coût, mesuré puis prédit, d’un deal de crédit syndiqué hétérogène.

3.5 Synthèse : un gap resserré sur l’intrant temps du TDABC

L’examen de la littérature ne débouche pas sur le constat commode qu’« aucun auteur n’a tout combiné ». Il désigne un manque unique et localisé. Le **TDABC fournit l’équation juste** (équation 6) pour reconstruire *et* prédire un coût par deal, et notre terrain la confirme. Mais il **suppose résolu son intrant le plus difficile**, le temps unitaire t_i , que la littérature critique désigne unanimement comme son talon d’Achille — d’autant plus en environnement hétérogène, où Koster *et al.* (2023) ont dû recourir à la logique floue pour absorber la variabilité des cas [9]. Les choix retenus dans cette synthèse constituent donc la traduction opérationnelle de l’analyse théorique conduite dans ce chapitre ; leur validité empirique sera ensuite testée puis confirmée sur le terrain aux chapitres 3 et 4. Or cet intrant se heurte, en opérations de crédit, à trois obstacles cumulatifs établis au fil du chapitre : *(i)* les méthodes classiques (Taylor, MTM) reposent sur une observation ou des tables inadaptées à un back office nearshore et automatisé ; *(ii)* le Process Mining lève cet obstacle mais ne livre qu’un temps écoulé bruité,

non effectif ; (iii) la constante d'*Event Processing* ($\bar{t} \approx 20$ min) s'applique strictement à l'exécution des actions standard de booking et de saisie dans Loan IQ, tandis que toute la complexité cognitive, l'interprétation contractuelle et les échanges inter-équipes sont isolés dans la composante *Aftercare* ; (iv) la variabilité du coût ne vient donc pas du temps de *booking*, stable, mais du volume et de l'*aftercare*, que les caractéristiques du deal font varier de façon non additive ; le modèle de régression de l'*Aftercare* peut incorporer des termes d'interaction ($x_i \cdot x_j$) ou des traits polynomiaux pour capter ces multiplicateurs de complexité non additifs tout en demeurant pleinement interprétable.

Le *gap* se formule donc en une phrase : **il n'existe pas de protocole établi permettant d'estimer, pour des opérations de crédit syndiqué hétérogènes et partiellement automatisées, le temps unitaire fiable qu'exige le TDABC — en combinant la couverture des logs (Process Mining) et leur calibration par clocking — puis d'en déduire le coût d'un deal, mesuré rétrospectivement et prédit pour un deal futur au moyen d'un modèle non linéaire rendu interprétable.** Ce chaînon manquant gouverne les deux finalités à la fois : sans lui, ni la mesure ni la prédiction ne sont fiables. C'est lui, et lui seul, que notre contribution construit.

Notre recherche relève ainsi du *design science* [5] : elle produit un artefact — un protocole de mesure du temps unitaire et sa conversion en coût par deal, rétrospectif puis prédictif — dont la validité s'évalue par sa capacité à résoudre un problème organisationnel réel : rendre enfin comparable, deal par deal, le coût back office et le gain front office.

4 Formalisation et construction d'une mesure empirique de la charge de travail

Construire une mesure n'est pas collecter des données : c'est trancher une série de décisions de conception, dont chacune engage la validité de tout ce qui suit. L'état de l'art a montré que le TDABC fournit l'équation du coût mais laisse ouvert son intrant principal : le temps consommé par les activités opérationnelles. Ce chapitre formalise la mesure retenue pour alimenter

cette équation dans le contexte du Loan Servicing. Il justifie cinq arbitrages : retenir l'événement comme unité de charge, séparer l'*Event Processing* et l'*Aftercare*, traiter la séniorité comme une source de biais plutôt que comme une correction de vitesse, conduire une mesure socialement acceptable dans un contexte de nearshoring, et raccorder le temps mesuré à la volumétrie réelle des deals.

La conclusion empirique structurante est volontairement simple : l'*Event Processing* n'est pas modélisé comme une durée individualisée par opérateur ou par niveau de séniorité, mais comme un temps unitaire fixe. Le temps moyen retenu est

$$\bar{t} \approx 20 \text{ minutes} \quad (13)$$

soit environ 500 observations de clocking. Cette constante devient l'intrant standard du calcul de coût : ce qui varie d'un deal à l'autre n'est pas d'abord la vitesse de traitement d'un événement, mais le nombre d'événements que le deal génère et la charge d'aftercare associée.

4.1 Premier arbitrage : l'événement comme unité, contre l'équipe et le deal

Le choix de l'unité de mesure détermine ce qu'on pourra reconstruire ensuite. Trois granularités étaient possibles, et deux sont des impasses. Mesurer la charge au niveau de l'**équipe** — un total d'heures mensuel — est la donnée que fournissent naturellement les systèmes RH, mais elle est inexploitable pour notre finalité : on ne peut pas en redescendre au coût d'un deal, puisqu'un deal ne consomme qu'une fraction non identifiable de ce total. Mesurer directement au niveau du **deal** serait la cible, mais c'est circulaire : le coût d'un deal est justement l'inconnue ; on ne peut pas le chronométrer globalement sans avoir déjà décomposé ce qui le compose.

Le seul niveau qui rende le problème soluble est l'**événement opérationnel**. Il est à la fois assez fin pour être chronométrable de façon homogène, et assez structurant pour que tout deal se recompose comme la somme de ses événements. Ce choix aligne la mesure sur le TDABC, dont l'unité est l'activité dotée d'un *duration driver*. Retenir l'événement, c'est faire le pari qu'une charge complexe et continue peut être reconstruite à partir de briques discrètes et mesurables.

L'enquête de clocking confirme que, pour l'*Event Processing*, ce pari est acceptable. Les observations convergent autour d'un ordre de grandeur stable : un événement de booking consomme en moyenne environ vingt minutes. Les différences fines entre types d'événements existent, mais elles sont moins structurantes, pour le calcul prédictif, que la volumétrie générée par le deal. L'unité pertinente devient donc : « un événement vaut environ vingt minutes », puis le modèle cherche à prédire combien d'événements seront produits.

4.2 Deuxième arbitrage : deux objets, non un — Event Processing et Aftercare

La décision la plus lourde de conséquences est de refuser de traiter la charge unitaire comme un bloc homogène. Une lecture naïve mesurerait « le temps de traitement d'un événement » et s'arrêterait là. Nos observations imposent de scinder la charge en deux objets qui n'obéissent pas aux mêmes lois : l'*Event Processing* et l'*Aftercare*.

Le premier, l'**Event Processing** — le booking dans Loan IQ — correspond à l'exécution opérationnelle d'événements identifiables. Il se prête à une standardisation forte : sur environ 500 clockings, le temps moyen retenu est une constante empirique $\bar{t} \approx 20$ minutes. Le second, l'**Aftercare**, relève d'une logique différente : il ne dépend pas seulement de l'existence d'un événement, mais du volume de sollicitations aval que le deal engendre : courriels, relances, confirmations, réconciliations, interactions avec les prêteurs et reprises opérationnelles. Sa relation aux caractéristiques du deal est quantitative, là où l'Event Processing est traité comme une brique standard multipliée par une volumétrie.

Cette dualité est le cœur analytique de notre construction. Confondre les deux objets rendrait la mesure fautive dans les deux sens. Traiter l'Aftercare comme vingt minutes supplémentaires par événement sous-estimerait massivement les gros deals syndiqués, dont la charge aval explose avec le nombre de prêteurs et de facilités. Inversement, chercher à individualiser chaque minute de booking donnerait une précision apparente mais fragile, là où l'évidence empirique permet d'utiliser une constante robuste. La séparation prépare donc directement la modélisation : prédire le *volume* d'événements pour l'Event Processing, et prédire un *temps* d'Aftercare par régression sur les variables quantitatives du deal.




FIGURE 7 – Décomposition du traitement d’un événement : Event Processing constant et Aftercare transversal

4.3 Troisième arbitrage : écarter la séniorité comme correction de vitesse

Le principe tayloriste du temps standard invite à chronométrer un temps observé, puis à le corriger pour le ramener à une référence comparable. Une tentation naturelle aurait donc été de remplacer le facteur d’allure subjectif par une variable observable : la séniorité. L’hypothèse initiale était simple : un opérateur senior traiterait plus vite qu’un opérateur junior, et il faudrait corriger les temps observés en conséquence.

Cette hypothèse a été abandonnée. La séniorité est trop fortement confondue avec la complexité des dossiers traités. Dans l’organisation observée, les seniors ne prennent pas un échantillon aléatoire de deals : ils prennent plus souvent les dossiers atypiques, sensibles ou complexes, précisément ceux qui génèrent davantage d’événements, davantage d’exceptions et davantage d’Aftercare. Utiliser la séniorité comme facteur de correction reviendrait donc à attribuer à la vitesse individuelle ce qui relève en réalité de la structure du deal.

Le biais est le suivant : si un senior met plus longtemps sur un dossier, ce n’est pas nécessairement parce qu’il est moins rapide, mais parce que le dossier qu’il traite est plus complexe. À l’inverse, un junior peut apparaître

« rapide » parce qu’il traite des opérations plus standardisées. La séniorité ne mesure donc pas proprement une allure ; elle capture simultanément l’expérience, la sélection des dossiers, la criticité opérationnelle et la confiance managériale. C’est un biais de confusion.

Pour cette raison, la séniorité est **écartée comme correction de vitesse**. Elle peut rester utile descriptivement pour comprendre l’organisation du travail, mais elle ne doit pas intervenir dans la formule empirique de coût. La mesure retient au contraire un temps unitaire commun pour l’Event Processing, $\bar{t} \approx 20$ minutes, et laisse la complexité s’exprimer par les variables structurelles du deal : rôle, prêteurs, facilités, produit, volume d’e-mails et volume d’événements.

4.4 Quatrième arbitrage : mesurer un travail dont la mesure menace ceux qui l’exécutent

Les arbitrages précédents étaient techniques. Celui-ci est social, et il conditionne la validité de tous les autres : aucune finesse méthodologique ne rachète des temps collectés dans la défiance. Le projet s’inscrit dans une démarche de *cost to serve*, liée à des objectifs d’efficience, de *hard savings* et de *cost avoidance*. Mesurer le coût d’un deal, c’est aussi mesurer la charge des équipes qui le traitent.

Cette dimension est particulièrement sensible dans un contexte de *near-shoring*. Les transferts d’activité entre sites, notamment de Paris vers Lisbonne, ne sont pas une hypothèse abstraite mais une réalité organisationnelle. Le clocking peut donc être perçu comme un instrument de comparaison entre sites, voire comme une justification future de redimensionnement ou de relocalisation. Cette perception n’est pas un bruit extérieur à la mesure : elle affecte directement ce qui est mesuré.

Le risque principal est l’effet Hawthorne, ou biais de réactivité : le fait d’être observé modifie le comportement observé. Dans le cas présent, le biais peut aller dans plusieurs directions. Un opérateur peut ralentir parce qu’il se sait observé, accélérer pour donner une image favorable, éviter les cas complexes pendant la période de mesure, ou commenter son travail différemment parce qu’il anticipe l’usage managérial des résultats. La donnée de clocking n’est donc jamais une donnée purement mécanique ; elle est produite dans une relation sociale.

Trois précautions en découlent. Premièrement, dissocier explicitement la

mesure de l'évaluation individuelle : l'objet mesuré est le type d'activité, non la performance nominative. Deuxièmement, expliquer la finalité de la démarche : rendre visible une charge souvent invisible, notamment l'Aftercare, et non seulement contrôler la productivité. Troisièmement, interpréter les résultats comme des ordres de grandeur robustes plutôt que comme des chronométrages absolus au dixième de minute. Ce cadrage justifie le choix d'une constante empirique de vingt minutes : elle est plus honnête méthodologiquement qu'une granularité artificielle qui ferait oublier les conditions sociales de production de la donnée.

4.5 Cinquième arbitrage : raccorder le temps standard à la volumétrie réelle

Un temps standard par événement ne dit rien, seul, du coût d'un deal : il faut le multiplier par le nombre d'événements que le deal génère. La dernière décision de conception est donc le raccordement de la mesure issue du clocking à la volumétrie issue des systèmes.

L'architecture retenue sépare ce qui est *mesuré une fois* et ce qui est *prédit ou compté en continu*. Le clocking fournit la constante empirique de temps, $\bar{t} \approx 20$ minutes. Les systèmes opérationnels fournissent les caractéristiques structurelles des deals et leur historique de volumétrie. La modélisation prédictive exploite ensuite ces caractéristiques pour estimer le volume futur d'événements $\hat{N}(x)$, à partir de variables comme le rôle de la banque, le nombre de prêteurs, le nombre de facilités et le produit.

L'Aftercare est raccorder différemment. Il ne se réduit pas à une multiplication par vingt minutes : il est estimé comme un temps propre, $\hat{T}_{AC}(x)$, à partir de variables quantitatives : nombre de prêteurs, nombre de facilités, nombre de mails et nombre d'événements. La mesure produit ainsi deux in-trants distincts pour le chapitre de modélisation : une constante de temps pour l'Event Processing, et une base de variables explicatives pour l'Aftercare.

4.6 Synthèse : une mesure empirique robuste et industrialisable

Les cinq arbitrages se répondent. Le choix de l'événement rend la charge recomposable ; la séparation Event Processing / Aftercare la rend juste ;

l’abandon de la séniorité comme correction évite un biais de confusion ; la prise en compte de l’effet Hawthorne et du nearshoring rend explicites les conditions sociales de production de la donnée ; le raccordement à la volumétrie rend la mesure industrialisable.

La mesure obtenue n’est donc pas une table de temps détaillée par opérateur. C’est un modèle empirique plus parcimonieux et plus robuste : chaque événement d’Event Processing vaut environ vingt minutes, le nombre d’événements est prédit par la structure du deal, et l’Aftercare est estimé séparément. Cette construction fournit l’intrant nécessaire au modèle de coût développé au chapitre suivant.

5 Modélisation prédictive du coût opérationnel

Ce chapitre exploite la base de mesure construite au chapitre 4 pour répondre aux deux finalités du mémoire : reconstruire le coût rétrospectif d’un deal traité, et prédire le coût d’un deal futur avant son traitement. Fidèle à la dualité établie (Event Processing et Aftercare), il construit deux modèles distincts, chacun adapté à la nature de sa composante, puis les recombine en un coût total prédit.

5.1 Reconstruire le coût rétrospectif d’un deal

La première exploitation est directe : appliquer l’équation du TDABC à la base de mesures empiriques. Pour un deal donné, le coût opérationnel est la somme, sur tous ses événements, du temps standard valorisé au coût horaire chargé :

$$C_{\text{deal}} = \sum_{i=1}^N T_{s,i} \times w_s = \underbrace{\sum_{i=1}^N \bar{t} \times w_s}_{\text{Event Processing}} + \underbrace{T_{\text{AC}} \times w_s}_{\text{Aftercare}} \quad (14)$$

où N est le volume d’événements du deal, $\bar{t} \approx 20$ minutes est le temps unitaire empirique d’Event Processing, T_{AC} le temps d’Aftercare, et w_s le coût horaire chargé du site traitant (ici estimé à 60 €/h en moyenne). La force de cette reconstruction est qu’elle rend visible ce qui était opaque : on peut désormais

dire non seulement qu'un deal « coûte cher », mais *pourquoi* — combien de minutes viennent de l'Event Processing, combien de l'Aftercare, quelle part est imputable au volume et quelle part à la structure.

Un résultat structurant : la dispersion extrême des coûts. Appliquée au portefeuille, cette reconstruction révèle une dispersion considérable du coût par deal. Un deal simple — rôle de participant, peu de prêteurs, monodevise, faible volume — se traite pour l'équivalent de quelques milliers d'euros. Un deal complexe — rôle d'agent, plusieurs centaines de prêteurs, multidevise, volume d'événements élevé — peut atteindre plusieurs centaines de milliers d'euros.

Par exemple, une **Deal A** typique (participant, 1 prêteur, 1 facilité, volume standard) coûte environ **4.4 k€**, alors qu'une **Deal B** complexe (agent, 200+ prêteurs, multi-facilités, volume d'événements massif) peut dépasser **259 k€**. L'écart est d'un rapport d'environ 1 à 60. Ce qui est plus frappant encore est la concentration : **1% des deals les plus complexes génèrent environ 30% du volume total d'événements**. Ces cas extrêmes, bien que rares, dominent la charge opérationnelle et justifient à eux seuls l'effort de modélisation prédictive.




FIGURE 8 – Impact de la complexité structurale sur le coût opérationnel et la charge Back Office

Ce que la mesure débloque. En rendant ce coût comparable au gain connu du Front Office, la reconstruction rétrospective répond au constat fondateur : contrairement au Front Office, dont l'activité se mesure en revenus (P&L), le Back Office ne se mesurait qu'en coût global, jamais par deal. Le coût par deal ouvre trois usages immédiats : chiffrer l'impact des initiatives de réduction des coûts (objectifs GTS), comparer le coût de traitement entre sites pour évaluer le *cost avoidance* du nearshoring, et identifier les deals à coût anormalement élevé.

5.2 Identifier les facteurs explicatifs de la charge

Reconstruire le coût ne suffit pas : pour le *prédire* et l'*expliquer*, il faut savoir quels paramètres le déterminent. La séparation des deux composantes impose de distinguer deux ensembles de facteurs, de nature différente.

Les facteurs de l'Event Processing : qualitatifs et catégoriels. Le volume d'événements N dépend de variables essentiellement *qualitatives* définies dès la signature du deal :

- le **rôle** de la banque (agent, participant, bilatéral) ;
- le **nombre de prêteurs** (*lenders*) impliqués ;
- le **nombre de facilités** (*facilities*) ;
- le **produit** et la **ligne de métier** .

Ces facteurs agissent de façon *non additive* : l'effet du rôle d'agent n'est pas le même selon le nombre de prêteurs, et se combine avec lui. C'est cette structure d'interactions qui oriente le choix de modèles à base d'arbres (Random Forest, XGBoost) pour prédire $\hat{N}(x)$, le volume d'événements attendu.

Les facteurs de l'Aftercare : quantitatifs et proportionnels. Le temps d'Aftercare, lui, dépend de variables *quantitatives* qui mesurent le volume de gestion aval :

- le **nombre de prêteurs** (n_{lenders}) ;
- le **nombre de facilités** ($n_{\text{facilities}}$) ;
- le **nombre de courriels** de gestion (n_{mails}) ;
- le **nombre d'événements** (N) .

Leur relation à la charge est approximativement *proportionnelle* : plus un deal compte de prêteurs, plus il génère de documents, de confirmations et de réconciliations. Cette proportionnalité rend la relation modélisable par

une régression (linéaire ou polynomiale) aux coefficients directement interprétables — « chaque prêteur supplémentaire ajoute X minutes d’Aftercare » — langage immédiatement actionnable pour le management.

5.3 Construire un modèle prédictif du coût

La seconde finalité — prédire le coût d’un deal *avant* son traitement — consiste à apprendre, sur l’historique, la fonction qui relie les caractéristiques d’un deal à sa charge. Fidèle à la dualité, nous construisons **deux modèles distincts**, puis les recombinaisons.




FIGURE 9 – Architecture à deux étages du modèle prédictif du coût par deal

5.3.1 Modéliser le volume d’événements : Random Forest et XG-Boost

Les facteurs de volume d’événements étant qualitatifs et en interaction, une régression linéaire échouerait — son hypothèse d’additivité ne tient pas. Nous retenons donc des **méthodes à base d’arbres**, qui capturent nativement les interactions.

- Le **Random Forest** moyenne des centaines d’arbres entraînés sur des échantillons aléatoires : $\hat{N}(x) = \frac{1}{B} \sum_{b=1}^B T_b(x)$. Robuste, peu sen-

sible au réglage, il fournit une mesure d'importance des variables qui hiérarchise les facteurs de volume.

- Le **gradient boosting** (XGBoost) construit les arbres séquentiellement, chacun corrigeant les erreurs du précédent ; généralement plus précis sur données tabulaires, au prix d'un réglage plus fin.

L'interprétabilité perdue par l'agrégation est restaurée *a posteriori* par les valeurs SHAP, qui décomposent chaque prédiction en contributions additives — permettant de présenter au management, pour un deal donné, la part de volume imputable à chaque facteur structurel.

5.3.2 Modéliser l'Aftercare : régression pour l'interprétabilité

Pour l'Aftercare, le choix s'inverse. La relation étant proportionnelle et les variables quantitatives, une **régression** est non seulement suffisante mais préférable. Le modèle de base s'écrit :

$$\hat{T}_{AC} = \beta_0 + \beta_1 n_{lenders} + \beta_2 N + \beta_3 n_{mails} + \beta_4 n_{facilities} + \varepsilon \quad (15)$$

où chaque coefficient β_k se lit directement comme le temps d'Aftercare ajouté par une unité supplémentaire du facteur correspondant. Là où la relation présente une courbure — par exemple un effet d'échelle au-delà d'un certain nombre de prêteurs — une **régression polynomiale** l'absorbe sans sacrifier l'interprétabilité.

5.3.3 Recomposer le coût prédit

Les deux modèles se recombinent en un coût total prédit pour un deal caractérisé par son vecteur d'attributs x :

$$\hat{C}_{deal} = \left[(\hat{N}(x) \times 20 \text{ min}) + \hat{T}_{AC}(x) \right] \times 60 \text{ €/h} \quad (16)$$

où $\hat{N}(x)$ est le volume d'événements prédit par le modèle à base d'arbres, $\hat{T}_{AC}(x)$ est le temps d'Aftercare prédit par la régression, et le facteur 60 €/h est le coût horaire chargé moyen estimé.

Cette équation est le produit central du mémoire du côté prédictif : elle permet, dès la signature d'un deal — lorsqu'on connaît son rôle, son nombre de prêteurs, de facilités et de produit, sans avoir traité le moindre événement — d'estimer ce qu'il coûtera aux opérations. La performance s'évalue par

les métriques usuelles (MAE, RMSE, R^2), en distinguant l'erreur sur chaque composante pour diagnostiquer laquelle limite la précision globale.

5.4 Pilotage opérationnel et usages décisionnels

La double mesure (rétrospective et prédictive) alimente trois leviers de pilotage concrets.

1. Cibler les initiatives de réduction des coûts. Puisque 1% des deals génèrent 30% du volume d'événements, la modélisation permet d'identifier *ex ante* les deals à haut volume probable et de concentrer les efforts d'automatisation ou de simplification processuelle sur cette frange critique. Le gain potentiel est disproportionné : réduire de 10% le volume d'événements sur les deals du top 1% a plus d'impact que la même réduction sur l'ensemble du portefeuille.

2. Évaluer le *cost avoidance* du nearshoring. Le coût par deal étant désormais comparable entre sites (Paris / Lisbonne), on peut simuler le coût d'un même portefeuille traité dans l'une ou l'autre configuration, à structure de deals identique. La différence observée, nette de l'effet volume, quantifie le *cost avoidance* réel du transfert d'activité.

3. Anticiper la charge et dimensionner les équipes. Le modèle prédictif, appliqué au pipeline de deals signés mais pas encore traités, fournit une projection de charge opérationnelle (en ETP et en euros) sur les mois à venir. Cela transforme la planification d'une logique budgétaire statique en une logique dynamique fondée sur la volumétrie attendue.

5.5 Limites et prolongements

Biais résiduels et contextualisation. La mesure porte sur des opérateurs conscients d'être observés, dans un contexte de nearshoring où la mesure peut être perçue comme liée à la maîtrise des coûts. L'effet Hawthorne n'a pas été éliminé, seulement contenu et rendu explicite. Les temps mesurés sont donc des ordres de grandeur robustes, non des chronométrages absolus.

Variables non observées. Certaines caractéristiques influençant la charge ne sont pas dans les données disponibles : complexité juridique du contrat, qualité de la documentation initiale, présence de clauses atypiques, criticité réputationnelle du deal. Ces facteurs contribuent au bruit résiduel des modèles.

Extrapolation et stabilité temporelle. Le modèle prédit pour des deals futurs dont la distribution peut diverger de l'historique (nouveaux produits, changements réglementaires, évolution des pratiques de marché). Une gouvernance de ré-entraînement périodique et de surveillance de la *distribution shift* est nécessaire pour maintenir la validité prédictive.

Prolongements possibles. Les directions naturelles d'extension sont : intégrer les données de Hobart (e-mails) en variables explicatives plus fines pour l'Aftercare ; explorer des modèles hybrides combinant régression et arbres pour capturer conjointement proportionnalité et interactions ; étendre la prédiction à l'horizon multi-mois pour la planification capacitaire ; et tester la transférabilité du modèle à d'autres métiers du Back Office (Trade Finance, Securities Services).

6 Conclusion

Références

- [1] H.C. Ben-Gal and J. Bukchin. The ergonomic design of workplaces using virtual manufacturing and response surface methodology. *IIE Transactions*, 42(10) :725–741, 2010.
- [2] Finance Club. Le crédit syndiqué : structure, acteurs et enjeux. Internal documentation, 2024.
- [3] F.B. Gilbreth and L.M. Gilbreth. *Applied Motion Study*. Sturgis & Walton, 1917.
- [4] M.P. Groover. *Work Systems and the Methods, Measurement, and Management of Work*. Pearson Prentice Hall, 2007.

- [5] A.R. Hevner, S.T. March, J. Park, and S. Ram. Design science in information systems research. *MIS Quarterly*, 28(1) :75–105, 2004.
- [6] M. Jans, M. Alles, and M.A. Vasarhelyi. The case for process mining in auditing. *International Journal of Accounting Information Systems*, 14(1) :1–20, 2013.
- [7] R.S. Kaplan and S.R. Anderson. Time-driven activity-based costing. *Harvard Business Review*, 82(11) :131–138, 2004.
- [8] R.S. Kaplan and R. Cooper. Measure costs right : Make the right decisions. *Harvard Business Review*, 66(5) :96–103, 1988.
- [9] T. Koster, N. Gademann, and F. Eijkenaar. Time-driven activity-based costing for healthcare : A systematic review of methodology and implementation. *Health Policy*, 131 :104770, 2023.
- [10] S.M. Lundberg and S.-I. Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [11] H.B. Maynard, G.J. Stegemerten, and J.L. Schwab. *Methods-Time Measurement*. McGraw-Hill, 1948.
- [12] J. Park. Forecasting heterogeneous demand in financial services : Limits of linear models. *Journal of Financial Data Science*, 2026. Forthcoming/preprint.
- [13] Summit Trails Advisors. Why most ai automation projects fail in financial services. Technical report, Industry Report, 2024.
- [14] F.W. Taylor. *The Principles of Scientific Management*. Harper & Brothers, 1911.
- [15] W.M.P. van der Aalst. *Process Mining : Data Science in Action*. Springer, 2nd edition, 2016.
- [16] Verint Systems Inc. *Back-Office Workforce Management : Product Documentation*. Verint, 2024.